

รายงานปฏิบัติงานสหกิจศึกษา

Japan Advanced Instituted of Science and Technology

KGs-Augmented Test Suite Generation via Re-construct Accident Report

นาย ชัยภัทร ใจน่าน

650510606

สหกิจศึกษานี้เป็นส่วนหนึ่งของการศึกษาหลักสูตรปริญญาวิทยาศาสตรบัณฑิต

สาขาวิชาวิทยาการคอมพิวเตอร์

คณะวิทยาศาสตร์ มหาวิทยาลัยเชียงใหม่

ปีการศึกษา 2565

## รายงานปฏิบัติงานสหกิจศึกษา

### KGs-Augmented Test Suite Generation via Re-construct Accident Report

นาย ชัยภัทร ใจน่าน

650510606

สหกิจศึกษานี้เป็นส่วนหนึ่งของการศึกษาหลักสูตรปริญญาวิทยาศาสตรบัณฑิต

สาขาวิชาวิทยาการคอมพิวเตอร์

คณะวิทยาศาสตร์ มหาวิทยาลัยเชียงใหม่

ปีการศึกษา 2567

คณะกรรมการสอบสหกิจศึกษา

..... ประธานกรรมการ  
( ผศ.ดร.อารีรัตน์ ตรงรัมย์ทอง )

..... กรรมการ  
( ผศ.ดร.เสมอแซ สมหอม )

วันที่ ..... เดือน ..... พ.ศ. ....

หนังสือยินยอมให้ข้อมูลเพื่อการศึกษา

## กิตติกรรมประกาศ

ข้าพเจ้าขอขอบพระคุณอาจารย์ที่ปรึกษาสหกิจศึกษา ผศ.ดร.อารีรัตน์ ตรงรัมย์ทอง ที่ได้ให้คำแนะนำ และช่วยแก้ไขปัญหาดังต่าง ๆ ตลอดระยะเวลาการทำงาน

นาย ชัยภัทร ใจน่าน

650510606

หัวข้อสหกิจศึกษา	การสร้างชุดทดสอบเสริมด้วย Knowledge Graphs ผ่านการสร้างรายงานอุบัติเหตุซ้ำ
สถานประกอบการ	Japan Advanced Instituted of Science and Technology
ผู้ดำเนินการศึกษา	ชัยภัทร ใจน่าน (Chaipat Jainan)
หลักสูตร	วิทยาศาสตร์บัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์
อาจารย์ที่ปรึกษาสหกิจ	ผศ.ดร.อารีรัตน์ ตรงรัศมีทอง

## บทคัดย่อ

งานวิจัยนี้มีวัตถุประสงค์เพื่อแก้ไขปัญหาด้านความน่าเชื่อถือและประสิทธิภาพในการสร้างชุดทดสอบสำหรับระบบขับเคลื่อนอัตโนมัติ (ADS) จากรายงานอุบัติเหตุจริง แม้ว่าโมเดลภาษาขนาดใหญ่ (LLM) จะมีศักยภาพในการสร้างสถานการณ์จำลอง แต่การใช้งานโดยตรงยังขาดกลไกในการมุ่งเน้นไปยังกรณีขอบเขต (Edge-Case) ที่ชัดเจน ซึ่งส่งผลให้เกิดการสร้างสถานการณ์จำลองที่ไม่จำเป็นจำนวนมาก งานวิจัยจึงนำเสนอกรอบการทำงานสำหรับการสร้างชุดทดสอบที่น่าเชื่อถือและมุ่งเน้นเป้าหมาย โดยใช้ Schema-guided LLM ในการสกัดข้อมูลอุบัติเหตุที่มีโครงสร้าง ก่อนนำไปสร้างเป็น Knowledge Graph (KG) เพื่อใช้เป็นโครงสร้างเชิงความหมายที่ช่วยในการอนุมานข้อมูลและความต่อเนื่องเชิงเหตุผล หัวใจสำคัญของกรอบการทำงานนี้คือการบูรณาการ Operational Design Domain (ODD) ที่กำหนดโดย Japan Automobile Manufacturers Association (JAMA) เข้าไปใน KG เพื่อใช้เป็นหลักเกณฑ์ในการกรองและควบคุมการสร้าง Scenario ให้มุ่งเน้นการค้นพบ Edge-Case ใหม่ ๆ ได้อย่างรวดเร็วและมีประสิทธิภาพ ผลลัพธ์ที่ได้คือก้าวสำคัญในการพัฒนาวิธีการสร้างชุดทดสอบที่มีความแม่นยำสูง ซึ่งช่วยลดจำนวนครั้งในการสร้างเหตุการณ์จำลองซ้ำ และสนับสนุนการรับรองความปลอดภัยของระบบ ADS ได้อย่างเป็นรูปธรรม

<b>Title</b>	KGs-Augmented Test Suite Generation via Re-construct Accident Report
<b>Company</b>	Japan Advanced Instituted of Science and Technology
<b>Name</b>	Chaipat Jainan
<b>ID</b>	650510606
<b>Degree</b>	Bachelor of Science in Computer Science
<b>Advisor</b>	Asst. Prof. Areerat Trongratsameethong

## Abstract

Ensuring the safety of Autonomous Driving Systems (ADS) necessitates rigorous testing using simulated scenarios derived from real-world accident reports. While Large Language Models (LLMs) offer a promising approach for generating these scenarios, their direct application in discovering elusive edge-cases is often inefficient and unreliable. This inefficiency stems primarily from the inconsistent nature of the source reports and the LLMs' tendency to generate numerous irrelevant scenarios, leading to an unnecessarily high number of reconstruction efforts before a novel test case is found.

To address this challenge, this study proposes a novel KGs-Augmented Testsuite Generator Framework designed to create reliable and goal-oriented test suites. The framework employs a schema-guided LL to accurately extract structured accident data from unstructured reports. This data is then modeled as a Knowledge Graph (KG), which serves as a semantic backbone, enabling robust inference of missing information and maintaining the causal continuity between events. Crucially, the framework integrates the Operational Design Domain (ODD), utilizing constraints defined by JAMA, directly into the KG structure.

The integration of ODD acts as a powerful filter and guideline, controlling the scenario generation process to focus exclusively on test cases that violate or push the boundaries of the defined operational limits. This targeted approach is the key to the framework's effectiveness, which aims to significantly reduce the number of reconstructed scenarios required to discover a new, challenging edge-case. The resulting structured scenarios are highly reliable and compliant with industry standards (e.g., ASAM OpenSCENARIO), marking a substantial improvement in the efficiency and quality of ADS safety evaluation.

# สารบัญ

กิตติกรรมประกาศ	ก
บทคัดย่อ	ข
Abstract	ค
สารบัญ	ง
สารบัญรูป	ช
สารบัญตาราง	ซ
<b>1 บทนำ</b>	<b>1</b>
1.1 ข้อมูลสถานประกอบการ . . . . .	1
1.1.1 ชื่อองค์กร . . . . .	1
1.1.2 ระยะเวลาการปฏิบัติงาน . . . . .	1
1.1.3 ลักษณะขององค์กร . . . . .	1
1.2 ตำแหน่งและลักษณะงานที่ได้รับมอบหมาย . . . . .	2
1.2.1 ตำแหน่งงานที่ปฏิบัติ . . . . .	2
1.2.2 งานที่ได้รับมอบหมาย . . . . .	2
1.3 หลักการและเหตุผล . . . . .	2
1.4 วัตถุประสงค์ . . . . .	2
1.5 ประโยชน์ที่คาดว่าจะได้รับ . . . . .	3
1.6 ขอบเขต . . . . .	3
1.6.1 ขอบเขตของข้อมูล . . . . .	3
1.6.2 ขอบเขตของงาน . . . . .	4
1.7 เครื่องมือและเทคโนโลยีที่ใช้ . . . . .	4
1.7.1 ฮาร์ดแวร์ที่ใช้ในการปฏิบัติงาน . . . . .	4
1.7.2 ซอฟต์แวร์ที่ใช้ในการปฏิบัติงาน . . . . .	4
1.7.3 ภาษาโปรแกรมที่ใช้ในการพัฒนา . . . . .	5
1.8 แผนปฏิบัติงานสหกิจศึกษา . . . . .	5
<b>2 เอกสารและงานวิจัยที่เกี่ยวข้อง</b>	<b>6</b>
2.1 แนวคิดพื้นฐานและทฤษฎีที่เกี่ยวข้อง . . . . .	6

2.1.1	Operational Design Domain (ODD)	6
2.1.2	Knowledge Graph (KG)	6
2.1.3	การประมวลผลภาษาธรรมชาติ (Natural Language Processing: NLP)	6
2.1.4	Large Language Model	7
2.1.5	Schema-guided Large Language Model (LLM)	7
2.1.6	Edge-Case Discovery Efficiency	8
2.2	งานวิจัยที่เกี่ยวข้อง	8
2.2.1	การสร้าง Scenario จากรายงานอุบัติเหตุ	8
2.2.2	การวิเคราะห์อุบัติเหตุด้วย Knowledge Graph	8
2.2.3	การประยุกต์ใช้ ODD ในการทดสอบ	8
2.2.4	ความแตกต่างและช่องว่างทางการวิจัย	8
2.3	เทคโนโลยีและเครื่องมือที่ใช้	9
2.3.1	เครื่องมือประมวลผลภาษาธรรมชาติและข้อมูล	9
2.3.2	แหล่งข้อมูลอุบัติเหตุ (Accident Data Sources)	9
2.3.3	มาตรฐานและสภาพแวดล้อมจำลอง	9
<b>3</b>	<b>ปัญหาและสมมติฐาน</b>	<b>10</b>
3.1	ปัญหาที่พบในการปฏิบัติงาน	10
3.1.1	ปัญหาด้านการสกัดข้อมูลและการสร้าง Knowledge Graph	10
3.1.2	ปัญหาด้านการบูรณาการ ODD และประสิทธิภาพ	10
3.1.3	ปัญหาด้านผลลัพธ์และการนำไปใช้	11
3.2	การวิเคราะห์ปัญหา	11
3.2.1	การวิเคราะห์ปัญหาด้านข้อมูลและความน่าเชื่อถือ	11
3.2.2	การวิเคราะห์ปัญหาด้านการจัดการ Knowledge Graph และ ODD	12
3.3	สมมติฐานหรือแนวทางในการแก้ไข	12
3.3.1	การเสริมสร้างความน่าเชื่อถือของการสกัดข้อมูล	12
3.3.2	การเพิ่มประสิทธิภาพการค้นพบ Edge-Case	13
3.3.3	การปรับปรุงการส่งออก Scenario	13
3.4	ข้อจำกัดของการศึกษา	13
3.4.1	ข้อจำกัดด้านข้อมูลและเทคโนโลยี	13
3.4.2	ข้อจำกัดด้านขอบเขตการดำเนินงาน	14
<b>4</b>	<b>ขั้นตอนวิธี</b>	<b>15</b>
4.1	ขั้นตอนการดำเนินงานโดยละเอียด	15
4.1.1	ขั้นที่ 1: การสกัดข้อมูลอุบัติเหตุที่มีโครงสร้าง (Structured Data Extraction)	15
4.1.2	ขั้นที่ 2: การสร้าง Knowledge Graph (KG Modeling)	15
4.1.3	ขั้นที่ 3: การบูรณาการ ODD และการค้นหา Edge-Case	16
4.1.4	ขั้นที่ 4: การสร้างไฟล์ Scenario มาตรฐาน (Standard Scenario Generation)	16
4.2	การวิเคราะห์และออกแบบระบบ	16
4.2.1	สถาปัตยกรรมระบบ	16
4.3	การนำไปใช้งานจริง	17



---

4.4	ปัญหาและอุปสรรคระหว่างการพัฒนา . . . . .	17
<b>5</b>	<b>ผลการศึกษา</b>	<b>19</b>
5.1	ผลการดำเนินงานตามวัตถุประสงค์ . . . . .	19
5.2	ตัวอย่างผลลัพธ์ . . . . .	19
5.3	การเปรียบเทียบก่อนและหลังการพัฒนา . . . . .	19
5.4	การประเมินผล . . . . .	19
<b>6</b>	<b>สรุปผลการศึกษาและวิจารณ์ผลการศึกษา</b>	<b>20</b>
6.1	สรุปผลการดำเนินงาน . . . . .	20
6.2	ข้อสังเกตและข้อวิจารณ์ . . . . .	20
6.3	ข้อเสนอแนะในการพัฒนาต่อไป . . . . .	20
6.4	ประสบการณ์จากการเข้าร่วมโครงการสหกิจศึกษา . . . . .	20
	<b>บรรณานุกรม</b>	<b>21</b>

## សារប័ណ្ណរូប

# สารบัญตาราง

1.1	ตารางสรุปแผนการดำเนินงานวิจัย . . . . .	5
2.1	ตัวอย่างการสกัดข้อมูลโดย Schema-guided LLM: รายงานอุบัติเหตุ C00013 . . . . .	7
2.2	ตารางแสดงแหล่งข้อมูลอุบัติเหตุที่ใช้ในการวิจัย . . . . .	9

# บทที่ 1

## บทนำ

การปฏิบัติงานสหกิจครั้งนี้ผู้จัดทำได้ปฏิบัติงานที่ Japan Advanced Instituted of Science and Technology (JAIST) ซึ่งได้รับมอบหมายงานเกี่ยวกับการออกแบบเฟรมเวิร์ค (Framework) สำหรับการสร้างชุดทดสอบของระบบขับเคลื่อนอัตโนมัติของ รถยนต์โดยนำเอาความรู้เรื่องโครงสร้างกราฟความรู้ (Knowledge Graph) มาประยุกต์ใช้

### 1.1 ข้อมูลสถานประกอบการ

#### 1.1.1 ชื่อองค์กร

Japan Advanced Instituted of Science and Technology (JAIST)

#### 1.1.2 ระยะเวลาการปฏิบัติงาน

ตั้งแต่วันที่ 14 เมษายน พ.ศ.2568 จนถึงวันที่ 30 กันยายน พ.ศ.2568

#### 1.1.3 ลักษณะขององค์กร

Japan Advanced Institute of Science and Technology เป็นมหาวิทยาลัยในประเทศญี่ปุ่นที่จัดการศึกษาในระดับบัณฑิตศึกษา ซึ่งแบ่งสาขาวิชาตามหัวข้อศึกษาหลักที่มีอยู่ 3 หัวข้อดังนี้

- 1.) Knowledge Science: สาขาวิชาที่บูรณาการความรู้เกี่ยวกับวิธีการออกแบบ การจัดการธุรกิจ วิทยาศาสตร์ระบบ (System Science) และความรู้อื่นๆ ที่เกี่ยวข้องกับปัญหาของมนุษย์ องค์กร หรือสังคมเพื่อเสนอวิธีแก้ปัญหาลำต้นและพิจารณาว่าจะทำให้วิธีแก้ปัญหานั้นรูปธรรมได้อย่างไร
- 2.) Information Science: เป็นสาขาวิชาที่มุ่งเน้นการแก้ไขปัญหาสำหรับมนุษย์และสังคม การสร้างทฤษฎีพื้นฐานใหม่ๆ ที่เป็นนวัตกรรมและการประยุกต์การประมวลผลข้อมูลเข้ากับการสื่อสารเพื่อรองรับสังคมยุคใหม่ที่ขับเคลื่อนด้วยข้อมูล
- 3.) Material Science: เป็นสาขาวิชาการที่มุ่งผลิตวัสดุใหม่และนวัตกรรมโดยมุ่งแก้ปัญหาให้กับมนุษยชาติและสังคม และบุกเบิกสาขาที่ยังไม่มีการสำรวจบนพื้นฐานของฟิสิกส์ เคมี ชีววิทยา และวิทยาศาสตร์และเทคโนโลยีที่เกี่ยวข้อง

## 1.2 ตำแหน่งและลักษณะงานที่ได้รับมอบหมาย

### 1.2.1 ตำแหน่งที่ปฏิบัติ

Research Intern

### 1.2.2 งานที่ได้รับมอบหมาย

ออกแบบเฟรมเวิร์ค (Framework) สำหรับการสร้างชุดทดสอบประสิทธิภาพการทำงานของระบบ ขับเคลื่อนอัตโนมัติของรถยนต์ เพื่อให้ผู้พัฒนาระบบขับเคลื่อนอัตโนมัติสามารถสร้างชุดทดสอบของตนเอง เพื่อนำไป ปรับปรุง ปรับใช้ และทดสอบระบบของตนเอง

## 1.3 หลักการและเหตุผล

งานวิจัย KGs-Augmented Test Suite Generation via Re-construct Accident Report มุ่งเน้นการแก้ปัญหาหลักในการทดสอบระบบขับเคลื่อนอัตโนมัติ (ADS) นั่นคือ ต้องสร้างเคสจำลองจำนวนมากจนกว่าจะพบ Edge-Case ใหม่ ปัจจุบัน การใช้ Large Language Models (LLMs) เพื่อสร้างสถานการณ์จำลองจากรายงานอุบัติเหตุจริงยังคงมีข้อจำกัดด้านความน่าเชื่อถือ เนื่องจากขาดโครงสร้างข้อมูลที่ชัดเจนและเป้าหมายการทดสอบที่สอดคล้องกับขอบเขตการทำงานของระบบ (ADS) ที่กำหนดไว้ ซึ่งส่งผลให้มีการสร้าง Scenario ที่ไม่จำเป็นจำนวนมาก จนกว่าจะพบเคสที่ทำหายระบบจริง งานวิจัยนี้จึงถือกำเนิดขึ้นเพื่อพัฒนาแนวทางที่เป็นระบบ โดยมีวัตถุประสงค์หลักเพื่อ ลดจำนวนเหตุการณ์ที่ต้องสร้างใหม่ ให้ได้มากที่สุด และเพิ่มอัตราส่วนการค้นพบ Edge-Case

กรอบการทำงานที่นำเสนอประกอบด้วยการทำงานร่วมกันของเทคโนโลยีหลักสามส่วนเพื่อเพิ่มประสิทธิภาพดังกล่าว: 1) Schema-guided LLM ถูกใช้เพื่อสกัดข้อมูลอุบัติเหตุจากรายงานข้อความให้อยู่ในรูปแบบที่มีโครงสร้าง 2) Knowledge Graph (KG) ถูกใช้เป็นโครงสร้างเชิงความหมาย (Semantic Backbone) ในการจัดเก็บข้อมูล ทำให้สามารถอนุมานข้อมูลที่ขาดหายไปและรักษาความต่อเนื่องเชิงเหตุผลของเหตุการณ์ได้อย่างแม่นยำ และที่สำคัญที่สุดคือ 3) การผสมผสานรวม Operational Design Domain (ODD) ที่กำหนดโดย JAMA เข้าไปใน KG โดย ODD นี้ทำหน้าที่เป็นไกด์ไลน์และตัวกรอง เพื่อจำกัดการสร้าง Scenario ให้มุ่งเน้นเฉพาะสถานการณ์ที่อยู่ในขอบเขตการทำงานของ ADS เท่านั้น ซึ่งถือเป็นการควบคุมทิศทางการสร้างชุดทดสอบให้ มุ่งเป้าหมายสู่ Edge-Case ที่เกี่ยวข้อง โดยตรง

ผลลัพธ์ที่คาดว่าจะได้รับจากโครงการนี้คือ กรอบการทำงานที่เชื่อถือได้และมีประสิทธิภาพสูง ในการสร้างชุดทดสอบสำหรับ ADS ประโยชน์ที่สำคัญที่สุดคือการช่วยให้นักวิจัยและผู้พัฒนาสามารถ เพิ่มความเร็วในการค้นพบสถานการณ์ทดสอบที่สำคัญ ด้วยทรัพยากรที่น้อยลง ชุดทดสอบที่สร้างขึ้นจะมีความน่าเชื่อถือสูง เนื่องจากมีโครงสร้างและมีความสอดคล้องกับเงื่อนไข ODD ทำให้การประเมินความปลอดภัยของระบบ ADS มีความเข้มงวดและมีคุณภาพมากขึ้น ซึ่งเป็นการวางรากฐานสำคัญสำหรับการรับรองความปลอดภัยของยานยนต์อัตโนมัติในอนาคต

## 1.4 วัตถุประสงค์

- 1.) พัฒนารอบการสร้างชุดทดสอบที่มีความน่าเชื่อถือที่เรียกว่า KGs-Augmented Testsuite Generator ซึ่งสามารถสกัดข้อมูลอุบัติเหตุแบบมีโครงสร้างจากรายงานที่เป็นข้อความโดยใช้ Schema-guided LLM และสร้างเป็น Knowledge Graph (KG) เพื่อใช้เป็นรากฐานเชิง

---

ความหมายของข้อมูลอุบัติเหตุ

- 2.) เพิ่มประสิทธิภาพการค้นพบ Edge-Case โดยการบูรณาการ Operational Design Domain (ODD) ที่กำหนดโดย JAMA เข้ากับ Knowledge Graph เพื่อใช้เป็นตัวกรองและหลักเกณฑ์ในการควบคุมการสร้าง Scenario ให้มุ่งเน้นเฉพาะสถานการณ์ที่ท้าทายระบบ (Edge-Case) ซึ่งเป็นไปตามวัตถุประสงค์หลักของงานวิจัยคือ การลดจำนวนเหตุการณ์ที่จำเป็นต้องสร้างใหม่จนกว่าจะพบเคสใหม่
- 3.) สร้างชุดทดสอบอุบัติเหตุที่มีโครงสร้างที่สมบูรณ์และถูกต้องตามหลักเหตุผล ซึ่งสามารถส่งออกในรูปแบบมาตรฐาน เช่น ASAM OpenSCENARIO เพื่อนำไปใช้งานในการจำลองการทดสอบ ระบบขับเคลื่อนอัตโนมัติได้อย่างมีประสิทธิภาพและตรงเป้าหมาย

## 1.5 ประโยชน์ที่คาดว่าจะได้รับ

- 1.) การเพิ่มประสิทธิภาพในการค้นพบ Edge-Case: กรอบการทำงานนี้จะช่วยให้นักวิจัยและผู้พัฒนาระบบสามารถลดจำนวนเหตุการณ์จำลองที่ไม่จำเป็นลงได้อย่างมาก เนื่องจากการใช้ ODD เป็นไกด์ไลน์ในการกรองและควบคุมการสร้าง Scenario ให้มุ่งเน้นเฉพาะสถานการณ์ที่อยู่ในขอบเขตการทำงานของ ADS และท้าทายระบบจริง ๆ เท่านั้น ซึ่งนำไปสู่การประหยัดเวลาและทรัพยากรในการทดสอบ
- 2.) การยกระดับความน่าเชื่อถือของชุดทดสอบ: ชุดทดสอบที่สร้างขึ้นจาก Knowledge Graph มีความถูกต้องเชิงโครงสร้างและรักษาความต่อเนื่องเชิงเหตุผล (Causal Continuity) ของเหตุการณ์อุบัติเหตุ ทำให้ผลการประเมินระบบขับเคลื่อนอัตโนมัติมีความน่าเชื่อถือและสอดคล้องกับความเป็นจริงมากขึ้น
- 3.) การเป็นรากฐานสำหรับงานวิจัยต่อยอด: Knowledge Graph ที่สร้างขึ้นจากข้อมูลอุบัติเหตุจริงและผสมผสานร่วมกับเงื่อนไข ODD สามารถทำหน้าที่เป็นแหล่งข้อมูลความรู้เชิงความหมายที่มีโครงสร้าง ซึ่งเป็นประโยชน์อย่างยิ่งในการพัฒนากฎความปลอดภัย (Safety Rules) การสร้าง Ontology สำหรับการขับเคลื่อนอัตโนมัติ หรือการพัฒนาเครื่องมือประเมินความเสี่ยงอื่น ๆ ในอนาคต
- 4.) การสนับสนุนการรับรองความปลอดภัยตามมาตรฐาน: กรอบการทำงานนี้จะช่วยให้มั่นใจได้ว่า Scenario ที่ใช้ในการทดสอบมีความสอดคล้องกับเงื่อนไขการปฏิบัติงานที่กำหนด (ODD) ของ JAMA ซึ่งเป็นปัจจัยสำคัญในการดำเนินการและสนับสนุนกระบวนการขอการรับรองความปลอดภัยของยานยนต์อัตโนมัติ

## 1.6 ขอบเขต

### 1.6.1 ขอบเขตของข้อมูล

รายงานจาก CIREN (Crash Injury Research and Engineering Network) ของสหรัฐอเมริกา และรายงานจาก GIDAS (German In-Depth Accident Study) ข้อมูลนำเข้าเหล่านี้อยู่ในรูปแบบของรายงานอุบัติเหตุที่เป็นข้อความแบบไม่มีโครงสร้าง (Unstructured Text Reports) ซึ่งจำเป็นต้องผ่านกระบวนการสกัดข้อมูลที่มีโครงสร้าง (Structured Data Extraction) โดยใช้ Schema-guided LLM ก่อนนำไปสร้างเป็น

---

Knowledge Graph ทั้งนี้ ข้อจำกัดด้านการใช้งานคือ ข้อมูลทั้งหมดจะถูกใช้เพื่อสกัดเอนทิตี ความสัมพันธ์ และเงื่อนไขที่จำเป็นสำหรับการสร้าง Knowledge Graph และ Scenario จำลองเท่านั้น โดยไม่รวมถึงข้อมูลส่วนบุคคลหรือข้อมูลระบุตัวตนอื่น ๆ ที่เกี่ยวข้องกับบุคคลในรายงาน

### 1.6.2 ขอบเขตของงาน

ขอบเขตของงานวิจัยนี้ครอบคลุมกิจกรรมหลักตั้งแต่การประมวลผลข้อมูลอุบัติเหตุไปจนถึงการสร้างชุดทดสอบที่มีโครงสร้างที่มุ่งเน้นเป้าหมาย โดยสามารถสรุปขอบเขตของการดำเนินงานได้ดังนี้:

- 1.) การพัฒนารอบการทำงาน KGs-Augmented Testsuite Generator ซึ่งใช้ Schema-guided LLM ในการสกัดข้อมูล และใช้ Knowledge Graph (KG) ในการจัดเก็บข้อมูลเชิงความหมายพร้อมรองรับ Inference Engine
- 2.) การบูรณาการ ODD: นำ Operational Design Domain (ODD) ที่กำหนดโดย JAMA มาผสมรวมเข้ากับ Knowledge Graph เพื่อทำหน้าที่เป็นเงื่อนไขในการกรองและควบคุมการสร้าง Scenario ให้มุ่งเป้าหมายเฉพาะ Edge-Case ที่เกี่ยวข้องกับขอบเขตการทำงานของระบบ
- 3.) การสร้างผลลัพธ์: สร้างชุดข้อมูล Scenario อุบัติเหตุที่มีโครงสร้างสมบูรณ์ ซึ่งสามารถส่งออกในรูปแบบมาตรฐานของอุตสาหกรรม เช่น ASAM OpenSCENARIO ที่พร้อมนำไปใช้งานในสภาพแวดล้อมจำลอง

## 1.7 เครื่องมือและเทคโนโลยีที่ใช้

### 1.7.1 ฮาร์ดแวร์ที่ใช้ในการปฏิบัติงาน

- Operating System: Ubuntu 24.04.2 LTS
- Processor: AMD Ryzen 7 5700G
- Graphic card: Nvidia RTX 4000 Ada generation
- Memory: 46GB
- Storage: 1TB

### 1.7.2 ซอฟต์แวร์ที่ใช้ในการปฏิบัติงาน

- 1.) Protégé: ใช้ในการออกแบบ Schema ของ Knowledge Graph
- 2.) Carla: เป็นโปรแกรมจำลองสถานการณ์การขับขี่แบบ Open
- 3.) MATLAB: ใช้สำหรับงานวิเคราะห์ข้อมูลโครงสร้างและเครือข่ายของถนน

- 4.) Large Language Models (LLMs): ใช้ GPT-4o ใช้สำหรับงานประมวลผลภาษาธรรมชาติ เพื่อช่วยในการ สร้าง (generation) และจัดการ ข้อมูลสำหรับสถานการณ์จำลอง และการสร้าง Knowledge Graph ตามที่ ระบุในแผนภาพระบบ

### 1.7.3 ภาษาโปรแกรมที่ใช้ในการพัฒนา

- 1.) Python: ใช้สำหรับการพัฒนา Framework หลักในการสกัดข้อมูลอุบัติเหตุ การสร้าง Knowledge Graph และการผสมรวม ODD
- 2.) Cypher: ใช้สำหรับการสืบค้นและจัดการข้อมูลในฐานข้อมูล Knowledge Graph
- 3.) SQL: ใช้สำหรับการจัดการและสืบค้นข้อมูลในฐานข้อมูลเชิงสัมพันธ์ (Relational Database)
- 4.) Shell Scripting: ใช้สำหรับการจัดการงานอัตโนมัติและการตั้งค่าสภาพแวดล้อมการพัฒนา
- 5.) LaTeX: ใช้สำหรับการจัดทำรายงานและเอกสารทางวิชาการ
- 6.) MATLAB: ใช้สำหรับการวิเคราะห์ข้อมูลโครงสร้างและเครือข่ายของถนน

## 1.8 แผนปฏิบัติงานสหกิจศึกษา

ตารางที่ 1.1: ตารางสรุปแผนการดำเนินงานวิจัย

ลำดับ	กิจกรรมหลัก	พ.ค.	มิ.ย.	ก.ค.	ส.ค.	ก.ย.
1	การเรียนรู้พื้นฐานและการทบทวนงานวิจัย (LLM, KG, ODD)					
2	การ สรุป แผน วิจัย โดยละเอียด และ การ ออกแบบ Schema/ Ontology สำหรับอุบัติเหตุ					
3	การจัดการและเตรียมชุดข้อมูลอุบัติเหตุ (CIREN/GIDAS) สำหรับการสกัด					
4	การ พัฒนา Schema-guided LLM สำหรับการ สกัด ข้อมูล อุบัติเหตุที่มีโครงสร้าง					
5	การสร้าง Knowledge Graph (KG) และการพัฒนา Inference Engine (รวม ODD)					
6	การบูรณาการระบบทั้งหมด (LLM → KG → Inference) และ การสร้างชุดสถานการณ์ทดสอบเบื้องต้น					
7	การทดสอบหลัก (Main Experiment) และการสร้าง Edge-Case Scenario จำนวนมาก					
8	การประเมินผลสถานการณ์ที่สร้างขึ้นและการวิเคราะห์สรุปผล					
9	การเขียนรายงานฉบับสมบูรณ์และการเตรียมการเพื่อเผยแพร่ผลงานวิจัย					



## บทที่ 2

### เอกสารและงานวิจัยที่เกี่ยวข้อง

บทนี้เป็นบททบทวนวรรณกรรม เอกสาร และงานวิจัยที่เกี่ยวข้องกับแนวคิดหลักและวิธีการที่ใช้ในการวิจัยนี้ โดยมีจุดมุ่งหมายเพื่อสร้างฐานความรู้ที่แข็งแกร่งและระบุช่องว่างทางการวิจัยที่โครงการนี้มุ่งเน้นแก้ไข เนื้อหาจะแบ่งออกเป็นแนวคิดพื้นฐานเกี่ยวกับระบบขับเคลื่อนอัตโนมัติ การสร้าง Scenario โครงสร้างข้อมูล Knowledge Graph และการใช้ LLM ในการประมวลผลภาษาธรรมชาติ

#### 2.1 แนวคิดพื้นฐานและทฤษฎีที่เกี่ยวข้อง

##### 2.1.1 Operational Design Domain (ODD)

Operational Design Domain (ODD) คือชุดของเงื่อนไขการปฏิบัติงานที่กำหนดไว้ล่วงหน้า เช่น สภาพภูมิอากาศ สภาพถนน ความเร็วสูงสุด ซึ่งระบบขับเคลื่อนอัตโนมัติ (ADS) ได้รับการออกแบบมาให้ทำงานได้อย่างปลอดภัย ODD เป็นแนวคิดที่สำคัญอย่างยิ่งในการประเมินความปลอดภัย เนื่องจากช่วยกำหนดขอบเขตการทดสอบให้ชัดเจน งานวิจัยนี้ได้ใช้ ODD ที่กำหนดโดย **Japan Automobile Manufacturers Association (JAMA)** เป็นข้อกำหนดหลักในการกรองและสร้าง Scenario เพื่อให้ชุดทดสอบมีความสอดคล้องกับขีดความสามารถของระบบที่กำลังประเมิน

##### 2.1.2 Knowledge Graph (KG)

Knowledge Graph (KG) เป็นรูปแบบการนำเสนอข้อมูลเชิงความหมาย (Semantic Data Structure) ที่ใช้โหนด (Nodes) และขอบ (Edges/Relationships) เพื่อแสดงถึงเอนทิตี (Entities) และความสัมพันธ์ระหว่างเอนทิตีเหล่านั้น บทบาทของ KG ในงานวิจัยนี้คือการทำหน้าที่เป็น **Semantic Backbone** สำหรับข้อมูลอุบัติเหตุ ทำให้สามารถจัดเก็บข้อมูลที่สกัดจากรายงานอุบัติเหตุในรูปแบบที่มีโครงสร้างและอนุมาน (Inference) ข้อมูลที่ขาดหายไปได้นอกจากนี้ยังช่วยรักษาความต่อเนื่องเชิงเหตุผล (Causal Continuity) ของเหตุการณ์ที่เกิดขึ้นในอุบัติเหตุ

##### 2.1.3 การประมวลผลภาษาธรรมชาติ (Natural Language Processing: NLP)

การประมวลผลภาษาธรรมชาติ หรือ **Natural Language Processing (NLP)** เป็นสาขาย่อยหนึ่งของปัญญาประดิษฐ์ (AI) และวิทยาการคอมพิวเตอร์ ที่มุ่งเน้นการสร้างปฏิสัมพันธ์ระหว่างคอมพิวเตอร์กับภาษามนุษย์ เป้าหมายหลักของ NLP คือการทำให้คอมพิวเตอร์สามารถ "เข้าใจ" ติความ และสร้างภาษาของมนุษย์ได้ในลักษณะที่มีประโยชน์ ซึ่งครอบคลุมงานหลากหลายประเภท เช่น การสกัดข้อมูล (Information Extraction) การแปลภาษาด้วยเครื่อง (Machine Translation) และการวิเคราะห์ความรู้สึก (Sentiment Analysis) ในงานวิจัยนี้ เทคนิค NLP เป็นหัวใจสำคัญ

ในการแปลงรายงานอุบัติเหตุที่อยู่ในรูปแบบข้อความที่ไม่มีโครงสร้าง ให้กลายเป็นข้อมูลเชิงลึกที่มีความหมายและนำไปใช้ได้

#### 2.1.4 Large Language Model

Large Language Model (LLM) เป็นโมเดลปัญญาประดิษฐ์ที่ได้รับการฝึกฝนด้วยข้อมูลจำนวนมากมหาศาล เพื่อทำความเข้าใจและสร้างภาษาธรรมชาติ LLM มีความสามารถในการสกัดข้อมูลที่ซับซ้อนจากข้อความที่ไม่มีโครงสร้าง (Unstructured Text) งานวิจัยนี้ใช้ LLM ในการสกัดข้อมูลอุบัติเหตุจากรายงานที่เป็นข้อความ โดยมีการนำเทคนิค Schema-guided LLM มาใช้เพื่อเพิ่มความน่าเชื่อถือและความสม่ำเสมอของข้อมูลที่สกัดได้

#### 2.1.5 Schema-guided Large Language Model (LLM)

LLM เป็นเครื่องมือที่มีประสิทธิภาพในการประมวลผลภาษาธรรมชาติ (NLP) [1] งานวิจัยนี้ใช้เทคนิค Schema-guided LLM เพื่อควบคุมและกำหนดทิศทางการสกัดข้อมูลจากรายงานอุบัติเหตุที่เป็นข้อความ (Unstructured Text) ให้เป็นข้อมูลที่มีโครงสร้าง (Structured Data) ตาม Schema ที่ออกแบบไว้ล่วงหน้า [2] การควบคุมด้วย Schema นี้ช่วยเพิ่มความน่าเชื่อถือและความสม่ำเสมอของข้อมูลที่สกัดได้ ก่อนนำไปสร้างเป็น Knowledge Graph [2]

Schema-guided LLM ถูกใช้เพื่อแก้ไขปัญหาความไม่สมบูรณ์และความกำกวมของข้อมูลในรายงานอุบัติเหตุจริง (เช่น CIREN หรือ GIDAS) [3, 4] ซึ่งรายงานเหล่านี้มักถูกบันทึกในรูปแบบข้อความอิสระ (Free Text) ที่ขาดมาตรฐาน การใช้ Schema เป็น Blueprint หรือ Ontology ที่กำหนดไว้ล่วงหน้าจะทำหน้าที่เป็น "สัญญา" ในการสกัดเอนทิตี, คุณลักษณะ, และความสัมพันธ์ที่จำเป็นให้ครบถ้วน

เพื่อเพิ่มความเข้าใจในกระบวนการสกัดข้อมูลโดย Schema-guided LLM ขอนำเสนอตัวอย่างการแปลงรายงานอุบัติเหตุที่ไม่มีโครงสร้าง (Narrative) ให้อยู่ในรูปแบบข้อมูลที่มีโครงสร้าง (Extracted Feature) ซึ่งเป็นขั้นตอนสำคัญก่อนการสร้าง Knowledge Graph [5]:

ตารางที่ 2.1: ตัวอย่างการสกัดข้อมูลโดย Schema-guided LLM: รายงานอุบัติเหตุ C00013

รายงานอุบัติเหตุ (Unstructured Text: Case C00013)	ข้อมูลที่มีโครงสร้าง (Structured Data/Extracted Feature)
A two-vehicle collision occurred at a <b>signalized urban intersection</b> during <b>daylight hours</b> . Vehicle 1, a red fire truck traveling eastbound, entered on a green signal but came to a complete stop in the middle of the intersection. <b>Vehicle 2</b> , a white Honda compact SUV traveling southbound, <b>entered against a red signal</b> and struck the right passenger side of Vehicle 1.	<b>1. World/Environment:</b> <ul style="list-style-type: none"><li>● Road Type: Urban intersection</li><li>● Signal Status: Functioning properly</li><li>● Time of Day: Daylight hours</li><li>● Road Condition: Dry</li></ul> <b>2. Actors:</b> <ul style="list-style-type: none"><li>● Vehicle 1 (Target): Fire truck, traveling eastbound</li><li>● Vehicle 2 (Ego/ADS Candidate): White Honda compact SUV, traveling southbound</li></ul> <b>3. Scenario Sequence (Events):</b> <ul style="list-style-type: none"><li>● Event 1 (V1): Stop in intersection (despite green light)</li><li>● Event 2 (V2): Encroachment (entered against red light)</li><li>● Event 3: Collision (V2 struck V1's right passenger side)</li></ul> <b>4. Outcome Metrics:</b> <ul style="list-style-type: none"><li>● Injury Severity (V1 Driver): Moderate</li><li>● Injury Severity (V2 Driver): Minor</li></ul>

---

ข้อมูลที่มีโครงสร้างดังกล่าว (ซึ่งอาจถูกเรียกว่า Extracted Feature หรือ JSON/XML output) เป็นรากฐานสำคัญที่ช่วยให้การแปลงเป็น Knowledge Graph ในขั้นตอนถัดไปเป็นไปได้อย่างแม่นยำและสม่ำเสมอ นอกจากนี้ การใช้ Schema ยังช่วยลดปัญหาความผิดพลาดในการอนุมานของ LLM (Hallucination) โดยเฉพาะในการสกัดความสัมพันธ์เชิงเหตุผลที่ซับซ้อน

#### 2.1.6 Edge-Case Discovery Efficiency

Edge-Case หมายถึงสถานการณ์ที่อยู่ขอบเขตการทำงานของระบบ ซึ่งมีโอกาสที่จะทำให้ระบบ ADS ล้มเหลวหรือทำงานผิดพลาด แนวคิดนี้เน้นไปที่การเพิ่ม **ประสิทธิภาพการค้นพบ (Discoverability Efficiency)** ซึ่งหมายถึงการลดจำนวน Scenario ที่ต้องสร้างขึ้นทั้งหมดจนกว่าจะพบ Edge-Case ใหม่ที่ท้าทายระบบจริง

### 2.2 งานวิจัยที่เกี่ยวข้อง

#### 2.2.1 การสร้าง Scenario จากรายงานอุบัติเหตุ

งานวิจัยก่อนหน้าได้สำรวจการใช้โมเดลภาษาขนาดใหญ่เพื่อแปลงรายงานอุบัติเหตุเป็นสถานการณ์จำลองสำหรับการทดสอบ ADS [1] อย่างไรก็ตาม วิธีการเหล่านี้มักประสบปัญหาความไม่น่าเชื่อถือของ Scenario ที่สร้างขึ้น และขาดกลไกที่ชัดเจนในการมุ่งเน้นการสร้างเฉพาะ Edge-Case ที่เกี่ยวข้องกับขอบเขตของ ADS

#### 2.2.2 การวิเคราะห์อุบัติเหตุด้วย Knowledge Graph

มีการประยุกต์ใช้ Knowledge Graph ในการวิเคราะห์อุบัติเหตุจราจร เพื่อแสดงความสัมพันธ์เชิงสาเหตุของปัจจัยต่าง ๆ ที่นำไปสู่อุบัติเหตุ [2] ซึ่งการใช้ KG นี้ช่วยในการอนุมานข้อมูลที่ขาดหายไปและเพิ่มความเข้าใจในโครงสร้างของอุบัติเหตุ อย่างไรก็ตาม งานเหล่านี้มักมุ่งเน้นที่การวิเคราะห์มากกว่าการประยุกต์ใช้เพื่อสร้างชุดทดสอบที่มีเป้าหมายเฉพาะ

#### 2.2.3 การประยุกต์ใช้ ODD ในการทดสอบ

งานวิจัยบางส่วนได้เสนอแนวคิดในการใช้ออนโทโลยี (Ontology) หรือ ODD เพื่อจัดหมวดหมู่และกำหนดขอบเขตของการสร้าง Scenario สำหรับยานยนต์อัตโนมัติ [5] แนวทางนี้ช่วยให้การทดสอบมีเป้าหมายที่ชัดเจน อย่างไรก็ตาม ยังไม่มีการผสมผสานรวม ODD เข้ากับโครงสร้าง Knowledge Graph และ LLM อย่างเป็นระบบ เพื่อแก้ไขปัญหาประสิทธิภาพในการค้นพบ Edge-Case

#### 2.2.4 ความแตกต่างและช่องว่างทางการวิจัย

งานวิจัยนี้เติมเต็มช่องว่างที่งานวิจัยก่อนหน้ายังขาดอยู่ โดยการ **รวมเอาความน่าเชื่อถือของ Knowledge Graph เข้ากับ ความสามารถในการสกัดข้อมูลของ Schema-guided LLM และ การกำหนดขอบเขตที่ชัดเจนของ ODD เข้าไว้ในกรอบการทำงานเดียว** ทำให้เป็นแนวทางแรก ๆ ที่มุ่งเน้นการแก้ไขปัญหา Edge-Case Discovery Efficiency โดยเฉพาะ

## 2.3 เทคโนโลยีและเครื่องมือที่ใช้

### 2.3.1 เครื่องมือประมวลผลภาษาธรรมชาติและข้อมูล

- **Large Language Model (LLM):** ใช้ในการทำ Schema-guided Extraction เพื่อสกัดข้อมูลอุบัติเหตุจากรายงานที่เป็นข้อความ (Unstructured Reports)
- **Knowledge Graph Database:** แพลตฟอร์มฐานข้อมูลเชิงกราฟ (เช่น Neo4j, RDF Triple Store) ใช้ในการจัดเก็บ KG และรองรับการทำ Inference Engine เพื่อตรวจสอบข้อจำกัดของ ODD

### 2.3.2 แหล่งข้อมูลอุบัติเหตุ (Accident Data Sources)

งานวิจัยนี้อาศัยข้อมูลจากฐานข้อมูลอุบัติเหตุจริงที่เปิดเผยต่อสาธารณะ เพื่อเป็นข้อมูลนำเข้าในการสกัด Scenario:

ตารางที่ 2.2: ตารางแสดงแหล่งข้อมูลอุบัติเหตุที่ใช้ในการวิจัย

แหล่งข้อมูล	ชื่อเต็ม	ลักษณะข้อมูล
CIREN [3]	Crash Injury Research and Engineering Network	รายงานอุบัติเหตุฉบับสมบูรณ์จากสหรัฐอเมริกา
GIDAS [4]	German In-Depth Accident Study	ข้อมูลเชิงลึกของอุบัติเหตุในเยอรมนี

จากตาราง 2.2 ข้อมูลที่ได้จากทั้งสองแหล่งมีความละเอียดเพียงพอต่อการสกัดเอนทิตีและความสัมพันธ์เพื่อสร้างเป็น Knowledge Graph ได้อย่างสมบูรณ์

### 2.3.3 มาตรฐานและสภาพแวดล้อมจำลอง

ผลลัพธ์ของงานวิจัยถูกออกแบบให้สามารถส่งออก Scenario ในรูปแบบที่เข้ากันได้กับมาตรฐานอุตสาหกรรม (เช่น ASAM OpenSCENARIO) เพื่อนำไปใช้งานในสภาพแวดล้อมจำลอง (Simulation Environment) สำหรับการประเมิน ADS ต่อไป

## บทที่ 3

### ปัญหาและสมมติฐาน

#### 3.1 ปัญหาที่พบในการปฏิบัติงาน

ในการดำเนินงานตามกรอบการทำงาน KGs-Augmented Testsuite Generator Framework มีความท้าทายและปัญหาทางเทคนิคหลายประการที่เกิดขึ้น ซึ่งเกี่ยวข้องกับการจัดการข้อมูลที่ซับซ้อน การทำงานร่วมกันของเทคโนโลยีที่แตกต่างกัน และคุณภาพของข้อมูลนำเข้า โดยสามารถสรุปปัญหาหลักที่พบได้ดังนี้:

##### 3.1.1 ปัญหาด้านการสกัดข้อมูลและการสร้าง Knowledge Graph

1. ความไม่สมบูรณ์ของข้อมูลในรายงานอุบัติเหตุ: รายงานอุบัติเหตุที่มาจากแหล่งข้อมูลอย่าง CIREN หรือ GIDAS มักมีข้อมูลบางส่วนที่ขาดหายไป กำกวม หรือขัดแย้งกันเอง ซึ่งทำให้การสกัดข้อมูลโดยใช้ Schema-guided LLM มีความท้าทายอย่างมากในการรับรองความถูกต้อง (Fidelity) และความน่าเชื่อถือของเอนทิตีที่ถูกสกัด
2. ความผิดพลาดในการอนุมานของ LLM: แม้จะใช้ Schema-guided LLM เพื่อควบคุมทิศทางในการสกัดข้อมูลแล้ว แต่โมเดลภาษาขนาดใหญ่ก็ยังคงมีแนวโน้มที่จะสร้างข้อความที่ผิดพลาดหรือข้อมูลที่ไม่สอดคล้องกับความเป็นจริง (Hallucination) โดยเฉพาะเมื่อต้องสกัดความสัมพันธ์เชิงเหตุผล (Causal Relationships) ที่ซับซ้อน
3. ความท้าทายในการสร้าง Knowledge Graph ที่สม่ำเสมอ: การแปลงข้อมูลที่มีโครงสร้างที่ถูกสกัดมาให้อยู่ในรูปแบบ Knowledge Graph ที่สอดคล้องและสม่ำเสมอ (Consistent Schema) นั้นทำได้ยาก เนื่องจากข้อมูลอุบัติเหตุแต่ละกรณีมีความแตกต่างกันอย่างมาก ทำให้ต้องมีการปรับแก้โครงสร้างกราฟและกฎการสร้างความสัมพันธ์ (Triples) อยู่เสมอ

##### 3.1.2 ปัญหาด้านการบูรณาการ ODD และประสิทธิภาพ

1. ความซับซ้อนของการกำหนดกฎ ODD: การกำหนดกฎเชิงตรรกะที่เข้มงวดของ Operational Design Domain (ODD) ให้เป็นเงื่อนไขที่ใช้ในการสืบค้น (Inference Query) ภายใน Knowledge Graph นั้นมีความซับซ้อนสูง หากกำหนดกฎไม่ละเอียดพอ อาจทำให้เกิดการกรองที่หลวมเกินไป และยังคงสร้าง Scenario ที่ไม่เกี่ยวข้อง หรือหากกำหนดกฎที่เข้มงวดเกินไป อาจทำให้พลาด Edge-Case ที่มีความสำคัญไป

- 
- ประสิทธิภาพของการประมวลผลกราฟ: เมื่อ Knowledge Graph มีขนาดใหญ่ขึ้น การเรียกใช้ Inference Engine เพื่อประเมินและค้นหา Scenario ที่ละเมิดกฎ ODD หรือสอดคล้องกับ Edge-Case จะใช้ทรัพยากรการประมวลผลและเวลาที่เพิ่มขึ้นอย่างมาก ซึ่งส่งผลกระทบต่อประสิทธิภาพโดยรวมของกรอบการทำงานในการค้นพบ Edge-Case ใหม่ ๆ

### 3.1.3 ปัญหาด้านผลลัพธ์และการนำไปใช้

- ความท้าทายในการส่งออกรูปแบบมาตรฐาน: การแปลงข้อมูล Scenario จากโครงสร้าง Knowledge Graph ที่มีความละเอียดสูง ไปสู่รูปแบบไฟล์มาตรฐานของอุตสาหกรรม (เช่น ASAM OpenSCENARIO) ต้องอาศัยการทำ Mapping ที่แม่นยำเพื่อรับประกันว่า Scenario ที่สร้างขึ้นจะสามารถรันในสภาพแวดล้อมจำลองได้อย่างถูกต้อง โดยไม่เกิดข้อผิดพลาดในการแปลความหมายของตัวแปรและเอนทิตี

## 3.2 การวิเคราะห์ปัญหา

การวิเคราะห์ปัญหาที่เกิดขึ้นในการปฏิบัติงานมีความจำเป็นอย่างยิ่ง เพื่อให้สามารถระบุแนวทางแก้ไขที่เหมาะสมและปรับปรุงประสิทธิภาพของกรอบการทำงาน KGs-Augmented Testsuite Generator ได้อย่างตรงจุด การวิเคราะห์ปัญหาหลัก ๆ ที่พบมีดังนี้:

### 3.2.1 การวิเคราะห์ปัญหาด้านข้อมูลและความน่าเชื่อถือ

- ปัญหาจากความไม่สมบูรณ์และกำกวมของข้อมูล:
  - สาเหตุ: รายงานอุบัติเหตุจริง (CIREN, GIDAS) ถูกบันทึกโดยมนุษย์ในรูปแบบข้อความอิสระ (Free Text) ซึ่งมีลักษณะเป็นการตีความและสังเกตการณ์ที่แตกต่างกัน ทำให้ขาดมาตรฐานในการให้ข้อมูลที่สม่ำเสมอ และมีโอกาสเกิดการละเว้นข้อมูลบางส่วนที่สำคัญต่อการสร้าง Scenario
  - ผลกระทบ: ทำให้ Schema-guided LLM ไม่สามารถสกัดข้อมูลที่มีโครงสร้างได้อย่างสมบูรณ์ และส่งผลให้ Knowledge Graph ที่สร้างขึ้นมีช่องว่างของข้อมูล (Missing Triples) ซึ่งลดความน่าเชื่อถือและความแม่นยำของ Scenario จำลองที่ต้องอาศัยความต่อเนื่องเชิงเหตุผล
- ปัญหาความผิดพลาดในการอนุมานของ LLM:
  - สาเหตุ: แม้จะมีการใช้ Schema เป็นแนวทาง แต่ LLM ยังมีข้อจำกัดในการทำความเข้าใจบริบททางฟิสิกส์ (Physical Constraints) หรือกฎหมายที่ซับซ้อน ทำให้เกิดการสร้างข้อมูลที่ผิดพลาด (Hallucination) หรือการสกัดความสัมพันธ์เชิงเหตุผลที่ไม่ถูกต้อง
  - ผลกระทบ: ทำให้ Knowledge Graph มีข้อมูลที่ผิดพลาดแฝงอยู่ ซึ่งหากนำไปสร้างเป็น Scenario จะทำให้ได้ชุดทดสอบที่ไม่มีความสมจริงหรือไม่สามารถเกิดขึ้นได้จริงในทางปฏิบัติ ส่งผลให้ประสิทธิภาพในการประเมิน ADS ลดลง

### 3.2.2 การวิเคราะห์ปัญหาในการจัดการ Knowledge Graph และ ODD

#### 1. ปัญหาความซับซ้อนของการกำหนดกฎ ODD:

- สาเหตุ: การเปลี่ยนนิยามของ Operational Design Domain (ODD) ซึ่งเป็นแนวคิดที่ค่อนข้างเป็นนามธรรม ให้เป็นกฎเชิงตรรกะที่เข้มงวดสำหรับการสืบค้นใน Knowledge Graph (KG) นั้นต้องอาศัยความเชี่ยวชาญและการตีความที่แม่นยำ
- ผลกระทบ: หากการกำหนดกฎไม่แม่นยำ จะส่งผลกระทบต่อวัตถุประสงค์หลักของงานวิจัย กล่าวคือ การกรอง Scenario ที่ไม่เกี่ยวข้องออกไปทำไม่ได้ไม่ดีพอ (เกิด False Positives) ทำให้จำนวนเหตุการณ์ที่ต้องสร้างใหม่จนกว่าจะพบ Edge-Case ใหม่ยังคงสูงอยู่

#### 2. ปัญหาประสิทธิภาพการประมวลผลกราฟขนาดใหญ่:

- สาเหตุ: การทำงานของ Inference Engine บน Knowledge Graph ที่ขยายตัวอย่างต่อเนื่อง (เมื่อมีการเพิ่มรายงานอุบัติเหตุเข้าไป) จำเป็นต้องมีการประมวลผลความสัมพันธ์จำนวนมากมหาศาลเพื่อหา Scenario ที่สอดคล้องกับกฎ ODD หรือละเมิดความปลอดภัย
- ผลกระทบ: ประสิทธิภาพการสืบค้นและเวลาในการตอบสนอง (Query Latency) ลดลงอย่างมีนัยสำคัญ เมื่อฐานข้อมูล Knowledge Graph เติบโตขึ้น ซึ่งเป็นอุปสรรคต่อการนำกรอบการทำงานนี้ไปใช้ในระดับอุตสาหกรรมที่ต้องมีการประมวลผลข้อมูลจำนวนมากแบบเรียลไทม์หรือเกือบเรียลไทม์

## 3.3 สมมติฐานหรือแนวทางในการแก้ไข

จากปัญหาที่ได้วิเคราะห์ไว้ในกระบวนการพัฒนาระบบการศึกษา (Scenario) โดยใช้ KGs-Augmented Testsuite Generator Framework มีสมมติฐานและแนวทางแก้ไขหลายประการที่ถูกลำมาพิจารณาและประยุกต์ใช้เพื่อเพิ่มประสิทธิภาพ ความน่าเชื่อถือ และความสามารถในการค้นพบ Edge-Case ของระบบ:

### 3.3.1 การเสริมสร้างความน่าเชื่อถือของการสกัดข้อมูล

- การใช้เทคนิค Multi-Step Prompting สำหรับ LLM: เพื่อแก้ไขปัญหาความผิดพลาดในการอนุมานของ LLM และความไม่สมบูรณ์ของข้อมูล มีการตั้งสมมติฐานว่าการแยกกระบวนการสกัดข้อมูลที่ซับซ้อนออกเป็นขั้นตอนย่อย ๆ (เช่น สกัดเอนทิตี, สกัดความสัมพันธ์, ตรวจสอบความสอดคล้องเชิงฟิสิกส์) จะช่วยให้ LLM มีความแม่นยำสูงขึ้นในการสกัดข้อมูลและการสร้างความสัมพันธ์เชิงเหตุผล
- การใช้ Cross-Validation โดยผู้เชี่ยวชาญ: กำหนดให้มีการตรวจสอบความถูกต้องของข้อมูล (Data Fidelity) ที่ถูกสกัดจาก LLM โดยผู้เชี่ยวชาญด้านการวิเคราะห์อุบัติเหตุหรือวิศวกรความปลอดภัย เพื่อปรับปรุง Schema และกฎการสกัดข้อมูลให้มีความแม่นยำสูงขึ้นก่อนนำเข้า Knowledge Graph

3. การสร้าง Ontology สำหรับอุบัติเหตุ: พัฒนาระบบ Ontology ที่มีรายละเอียดเฉพาะสำหรับ Domain อุบัติเหตุจราจร เพื่อใช้เป็น Schema ที่เข้มงวดและเป็นมาตรฐานในการกำหนดนิยามเอนทิตีและความสัมพันธ์ใน Knowledge Graph ซึ่งจะช่วยลดปัญหาความไม่สม่ำเสมอของโครงสร้างกราฟ

### 3.3.2 การเพิ่มประสิทธิภาพการค้นพบ Edge-Case

1. การใช้กฎ ODD แบบลำดับชั้น (Hierarchical ODD Rules): เพื่อแก้ไขปัญหาความซับซ้อนในการกำหนดกฎ ODD มีสมมติฐานว่าการจัดโครงสร้างกฎ ODD ให้เป็นลำดับชั้น (เช่น เงื่อนไขทั่วไป, เงื่อนไขเฉพาะ, เงื่อนไขขอบเขต) จะช่วยให้ Inference Engine สามารถประมวลผลการกรอง Edge-Case ได้อย่างมีประสิทธิภาพมากขึ้น และลดโอกาสที่จะเกิดการกรองที่ผิดพลาด (False Filtering)
2. การใช้ Partitioning และ Indexing ใน Knowledge Graph: เพื่อจัดการกับปัญหาประสิทธิภาพของการประมวลผลกราฟขนาดใหญ่ มีการนำเทคนิคการแบ่งส่วนข้อมูล (Partitioning) หรือการสร้างดัชนี (Indexing) เฉพาะสำหรับเอนทิตีที่เกี่ยวข้องกับ ODD และ Edge-Case เข้ามาใช้ในการค้นหา Knowledge Graph เพื่อลดภาระการคำนวณของ Inference Engine ในระหว่างการสืบค้น (Query)
3. การพัฒนา Metric ในการให้คะแนน Edge-Case (Edge-Case Scoring Metric): สร้างมาตรวัดเชิงปริมาณ (Quantitative Metric) เพื่อให้คะแนนความเสียหาย (Severity) ของ Scenario ที่สร้างขึ้น ซึ่งจะช่วยให้สามารถจัดลำดับความสำคัญของ Scenario ที่ถูกสร้างขึ้น และมุ่งเน้นการสร้างซ้ำเฉพาะในกลุ่มที่มีคะแนน Edge-Case สูง เพื่อให้การค้นพบเคสใหม่มีความรวดเร็วและเป็นไปตามวัตถุประสงค์ของการวิจัย

### 3.3.3 การปรับปรุงการส่งออก Scenario

1. การพัฒนาระบบ Mapping อัตโนมัติ: พัฒนาเครื่องมือ Mapping อัตโนมัติที่แข็งแกร่งเพื่อแปลงความสัมพันธ์และคุณสมบัติต่าง ๆ จาก Knowledge Graph ให้เป็นรูปแบบ ASAM OpenSCENARIO ที่ถูกต้องแม่นยำ โดยมีการตรวจสอบความสอดคล้องกับ Schema ของมาตรฐาน ASAM เพื่อลดข้อผิดพลาดในการแปลความหมายของ Scenario ก่อนนำไปใช้ในการจำลอง

## 3.4 ข้อจำกัดของการศึกษา

การวิจัยนี้มุ่งเน้นการพัฒนากรอบการทำงานที่เป็นแนวคิดใหม่ในการสร้างชุดทดสอบ แต่ก็มีข้อจำกัดหลายประการที่ต้องนำมาพิจารณา ซึ่งส่วนใหญ่เกี่ยวข้องกับคุณภาพของข้อมูลนำเข้า ความจำกัดของเทคโนโลยีที่ใช้ และขอบเขตการดำเนินงานที่ถูกกำหนดไว้ล่วงหน้า ดังนี้:

### 3.4.1 ข้อจำกัดด้านข้อมูลและเทคโนโลยี

1. การพึ่งพาข้อมูลอุบัติเหตุในอดีต: การศึกษานี้ขึ้นอยู่กับรายงานอุบัติเหตุจริงจากฐานข้อมูลสาธารณะ (เช่น CIREN และ GIDAS) ซึ่งเป็นข้อมูลในอดีตและมีลักษณะที่ไม่สมบูรณ์ รวมถึงมีความเป็นอัตวิสัย (Subjectivity) ในการบันทึกของผู้รายงาน ข้อจำกัดนี้ส่งผลโดยตรงต่อคุณภาพและความแม่นยำของ Knowledge Graph ที่ถูกสร้างขึ้น



- 
2. ความท้าทายด้านความน่าเชื่อถือของ LLM: แม้จะมีการใช้ Schema-guided LLM เพื่อสกัดข้อมูล แต่โมเดลภาษายังคงมีแนวโน้มที่จะสร้างข้อมูลที่ผิดพลาด (Hallucination) หรือความสัมพันธ์เชิงเหตุผลที่ไม่ถูกต้อง โดยเฉพาะในสถานการณ์อุบัติเหตุที่มีความซับซ้อน ซึ่งทำให้ต้องอาศัยการตรวจสอบและปรับแก้จากผู้เชี่ยวชาญเพิ่มเติม
  3. ข้อจำกัดในการสรุปผล ODD: Operational Design Domain (ODD) ที่ใช้ในการวิจัยนี้อ้างอิงตามมาตรฐานของ JAMA เป็นหลัก ดังนั้นชุดทดสอบและผลลัพธ์ที่ได้จึงอาจไม่สามารถนำไปสรุปผลหรือนำไปประยุกต์ใช้โดยตรงกับระบบขับเคลื่อนอัตโนมัติ (ADS) ที่ถูกออกแบบมาภายใต้มาตรฐาน ODD ของผู้ผลิตหรือองค์กรอื่นที่มีนิยามที่แตกต่างกัน
  4. ปัญหาด้านการประมวลผลของ Knowledge Graph: เมื่อ Knowledge Graph เติบโตขึ้นตามจำนวนรายงานอุบัติเหตุที่เพิ่มขึ้น ประสิทธิภาพในการประมวลผลของ Inference Engine เพื่อสืบค้นและประเมินกฎ ODD จะลดลง ซึ่งอาจเป็นข้อจำกัดในการนำกรอบการทำงานนี้ไปใช้งานในระดับอุตสาหกรรมขนาดใหญ่ที่ต้องการความเร็ว

#### 3.4.2 ข้อจำกัดด้านขอบเขตการดำเนินงาน

1. การขาดการประเมินในสภาพแวดล้อมจริง: ขอบเขตของโครงการสิ้นสุดที่การสร้างไฟล์ Scenario ที่มีโครงสร้างมาตรฐาน (เช่น ASAM OpenSCENARIO) และไม่ได้รวมถึงการดำเนินการจำลองสถานการณ์ (Simulation) หรือการทดสอบภาคสนามจริง ดังนั้น การประเมินผลกระทบที่แท้จริงของชุดทดสอบต่อประสิทธิภาพของระบบ ADS จึงอยู่นอกเหนือขอบเขตของการศึกษานี้
2. การละเลยปัจจัยมนุษย์ในระดับละเอียด: Scenario ที่สร้างขึ้นเน้นการจับภาพเหตุการณ์ทางกายภาพและสภาพแวดล้อมเป็นหลัก แม้จะมีการเก็บข้อมูลพฤติกรรม แต่การวิเคราะห์และจำลองปัจจัยด้านมนุษย์ (Human Factors) เช่น ความผิดพลาดทางสติปัญญา หรือการตอบสนองทางอารมณ์ของผู้ขับขี่อย่างละเอียด ยังคงเป็นสิ่งที่ซับซ้อนและไม่ได้เป็นจุดเน้นหลักของกรอบการทำงานนี้

## บทที่ 4

### ขั้นตอนวิธี

#### 4.1 ขั้นตอนการดำเนินงานโดยละเอียด

กระบวนการดำเนินงานของโครงการวิจัยนี้เป็นไปตามกรอบการทำงาน KGs-Augmented Testsuite Generator Framework ซึ่งแบ่งออกเป็น 4 ขั้นตอนหลักที่ทำต่อเนื่องกันอย่างเป็นระบบ โดยมีเป้าหมายเพื่อเปลี่ยนรายงานอุบัติเหตุที่เป็นข้อความให้เป็น Scenario ทดสอบที่มีโครงสร้างและมุ่งเน้น Edge-Case:

##### 4.1.1 ขั้นที่ 1: การสกัดข้อมูลอุบัติเหตุที่มีโครงสร้าง (Structured Data Extraction)

1. การเลือกแหล่งข้อมูล: กำหนดให้ใช้รายงานอุบัติเหตุเชิงลึกจากฐานข้อมูล CIREN และ GIDAS เป็นข้อมูลนำเข้า
2. การออกแบบ Schema: ออกแบบ Schema ที่กำหนดเอนทิตี (เช่น ยานพาหนะ, ผู้ขับขี่, สภาพแวดล้อม) คุณลักษณะ (Attribute) และความสัมพันธ์ (Relationship) ที่จำเป็นต่อการสร้าง Knowledge Graph
3. การใช้ Schema-guided LLM: ใช้โมเดลภาษาขนาดใหญ่ (LLM) ที่ถูกนำทางด้วย Schema ที่กำหนดไว้ เพื่ออ่านรายงานอุบัติเหตุ และสกัดข้อมูลสำคัญให้อยู่ในรูปแบบโครงสร้าง (Structured Data) โดยเฉพาะอย่างยิ่งการสกัดความสัมพันธ์เชิงเหตุผล (Causal Relationships)

##### 4.1.2 ขั้นที่ 2: การสร้าง Knowledge Graph (KG Modeling)

1. การแปลงเป็น Triples: นำข้อมูลที่มีโครงสร้างที่ได้จากขั้นที่ 1 มาแปลงเป็น Triple Sets (Subject-Predicate-Object) เพื่อนำเข้าฐานข้อมูลกราฟ
2. การสร้าง KG Backbone: สร้าง Knowledge Graph ซึ่งทำหน้าที่เป็น Semantic Backbone สำหรับข้อมูลอุบัติเหตุ โดยการเชื่อมโยงเอนทิตีและคุณลักษณะต่าง ๆ เข้าด้วยกัน เพื่อให้สามารถจัดเก็บข้อมูลที่ซับซ้อนได้อย่างเป็นระเบียบและรักษาความต่อเนื่องของเหตุการณ์
3. การอนุมานข้อมูลที่ขาดหายไป: ใช้กฎการอนุมาน (Inference Rules) พื้นฐานภายใน KG เพื่อเติมเต็มช่องว่างของข้อมูลบางส่วนที่อาจขาดหายไปจากรายงานต้นฉบับ

#### 4.1.3 ขั้นที่ 3: การบูรณาการ ODD และการค้นหา Edge-Case

1. การกำหนดกฎ ODD: แปลงเงื่อนไข Operational Design Domain (ODD) ที่กำหนดโดย JAMA ให้เป็นกฎเชิงตรรกะที่สามารถสืบค้นได้ (Inference Query) ภายใน Knowledge Graph
2. การผสาน ODD เข้ากับ KG: สร้างความสัมพันธ์ใหม่ใน KG เพื่อระบุสถานการณ์หรือเหตุการณ์ที่เข้าข่ายเงื่อนไข ODD ที่ท้าทาย (Edge-Case Conditions) หรือละเมิดกฎความปลอดภัย
3. การใช้ Inference Engine: เรียกใช้ Inference Engine เพื่อสืบค้น (Query) Knowledge Graph โดยใช้กฎ ODD ที่สร้างขึ้น เพื่อกรองและเลือกเฉพาะ Scenario ที่มุ่งเป้าหมายไปยัง Edge-Case ที่เกี่ยวข้องกับขอบเขตการทำงานของระบบขับเคลื่อนอัตโนมัติ

#### 4.1.4 ขั้นที่ 4: การสร้างไฟล์ Scenario มาตรฐาน (Standard Scenario Generation)

1. การทำ Mapping ข้อมูล: แปลงข้อมูล Scenario ที่ผ่านการกรอง Edge-Case แล้วจากโครงสร้าง KG ให้เข้ากับรูปแบบไฟล์มาตรฐานที่กำหนดโดยอุตสาหกรรม (เช่น ASAM OpenSCENARIO หรือ OpenDRIVE)
2. การสร้างไฟล์ผลลัพธ์: ส่งออก Scenario ที่มีโครงสร้างสมบูรณ์และถูกต้องตามเหตุผลในรูปแบบที่พร้อมใช้งานสำหรับการจำลอง (Simulation)

### 4.2 การวิเคราะห์และออกแบบระบบ

ระบบที่พัฒนาขึ้นมีชื่อว่า KGs-Augmented Testsuite Generator Framework ซึ่งถูกออกแบบมาในลักษณะของระบบประมวลผลข้อมูลหลายขั้นตอน (Multi-Stage Processing System) โดยมีองค์ประกอบหลักดังนี้:

#### 4.2.1 สถาปัตยกรรมระบบ

1. Input Layer: รับข้อมูลนำเข้าจากรายงานอุบัติเหตุที่เป็นข้อความ (Unstructured Text Reports) จากแหล่งข้อมูล CIREN และ GIDAS
2. Processing Layer: เป็นหัวใจของระบบ ประกอบด้วย:
  - Schema-guided LLM Module: ทำหน้าที่เป็นตัวสกัดข้อมูลอัจฉริยะ โดยถูกควบคุมด้วย Ontology Schema เพื่อให้ได้ข้อมูลที่มีโครงสร้าง
  - Knowledge Graph Database: ฐานข้อมูลเชิงกราฟที่จัดเก็บข้อมูลอุบัติเหตุในรูปแบบโหนดและความสัมพันธ์ และทำหน้าที่เป็นตัวจัดเก็บกฎ ODD และความสัมพันธ์เชิงอนุมาน
  - Inference Engine: กลไกประมวลผลที่ใช้กฎ ODD เพื่อประเมิน Knowledge Graph และระบุ Edge-Case ที่เกี่ยวข้อง ซึ่งเป็นการลดจำนวน Scenario ที่ไม่จำเป็น

- 
3. Output Layer: ส่งออก Scenario ที่ผ่านการประมวลผลแล้วในรูปแบบไฟล์มาตรฐาน (ASAM OpenSCENARIO) เพื่อเชื่อมต่อกับสภาพแวดล้อมจำลอง (Simulation Environment)

#### 4.3 การนำไปใช้งานจริง

การนำกรอบการทำงานนี้ไปใช้งานจริงมุ่งเน้นที่การสร้างชุดทดสอบที่มีคุณภาพสูงสำหรับผู้พัฒนาระบบขับเคลื่อนอัตโนมัติ:

1. การติดตั้งระบบ: ระบบถูกติดตั้งในสภาพแวดล้อมการประมวลผลที่มีทรัพยากรสูง เพื่อรองรับการทำงานของ LLM และฐานข้อมูล Knowledge Graph ขนาดใหญ่
2. การประยุกต์ใช้: วิศวกรความปลอดภัยสามารถนำเข้าชุดรายงานอุบัติเหตุใหม่ ๆ เข้าสู่ระบบ เพื่อสร้างชุด Scenario ทดสอบที่มุ่งเน้น Edge-Case ได้อย่างรวดเร็ว โดย Scenario ที่ได้จะอยู่ในรูปแบบไฟล์ OpenSCENARIO
3. การใช้งานกับ Simulation: ไฟล์ Scenario ที่ถูกส่งออกจะถูกนำเข้าสู่แพลตฟอร์มจำลอง (เช่น Carla, Apollo) เพื่อดำเนินการทดสอบ (Run Test Cases) กับระบบขับเคลื่อนอัตโนมัติ (ADS Agent) และประเมินพฤติกรรมของระบบในสถานการณ์วิกฤตที่ตรงตามขอบเขต ODD
4. การเผยแพร่: ผลลัพธ์และวิธีการที่ใช้ในการสร้างชุดทดสอบมีเป้าหมายเพื่อเผยแพร่ในงานประชุมวิชาการ เพื่อให้เป็นแนวทางสำหรับชุมชนนักวิจัยและอุตสาหกรรม

#### 4.4 ปัญหาและอุปสรรคระหว่างการพัฒนา

ในการพัฒนาและดำเนินการโครงการ มีปัญหาและอุปสรรคหลักที่ต้องเผชิญและแก้ไข ดังนี้:

1. ความไม่น่าเชื่อถือของข้อมูลเริ่มต้น: ปัญหาหลักคือความไม่สมบูรณ์และความกำกวมของข้อมูลในรายงานอุบัติเหตุ ซึ่งทำให้ Schema-guided LLM สกัดข้อมูลที่มีความผิดพลาดหรือข้อมูลขาดหายไป ซึ่งต้องแก้ไขโดยการออกแบบ Schema ให้ละเอียดและมีการตรวจสอบความถูกต้องโดยมนุษย์เพิ่มเติม
2. ข้อจำกัดของ LLM ในการอนุมาน: แม้จะใช้ Schema เข้าช่วย แต่ LLM ยังคงสร้างความสัมพันธ์เชิงเหตุผลที่ไม่สอดคล้องกับข้อจำกัดทางฟิสิกส์ (Hallucination) ซึ่งต้องแก้ไขโดยใช้เทคนิค Multi-Step Prompting เพื่อแยกขั้นตอนการตรวจสอบความสอดคล้องออกจากขั้นตอนการสกัดข้อมูล
3. ประสิทธิภาพการประมวลผล Knowledge Graph ขนาดใหญ่: เมื่อจำนวน Scenario ที่ถูกสกัดและนำเข้า KG เพิ่มขึ้น ประสิทธิภาพของ Inference Engine ในการสืบค้น Edge-Case ตามกฎ ODD จะลดลงอย่างมาก แนวทางแก้ไขคือการใช้เทคนิคการทำ Indexing และ Partitioning ในฐานข้อมูลกราฟเพื่อเพิ่มความเร็วในการประมวลผล

- 
4. ความซับซ้อนในการทำ Mapping ผลลัพธ์: การแปลงข้อมูลจากโครงสร้าง Knowledge Graph ที่ซับซ้อนไปยังรูปแบบมาตรฐาน ASAM OpenSCENARIO ต้องอาศัยการทำ Mapping ที่แม่นยำและถูกตรวจสอบ เพื่อป้องกันข้อผิดพลาดในการแปลความหมายของ Scenario ที่นำไปใช้ในการจำลองจริง

## บทที่ 5

### ผลการศึกษา

#### 5.1 ผลการดำเนินงานตามวัตถุประสงค์

แสดงวัตถุประสงค์แต่ละข้อและผลที่ได้ว่าสอดคล้องกันหรือไม่

#### 5.2 ตัวอย่างผลลัพธ์

แสดงผลลัพธ์ที่ได้จากระบบ เช่น หน้าจอโปรแกรม ตาราง หรือกราฟ

#### 5.3 การเปรียบเทียบก่อนและหลังการพัฒนา

เปรียบเทียบประสิทธิภาพหรือกระบวนการก่อนและหลังมีระบบ

#### 5.4 การประเมินผล

รายงานผลการประเมินจากผู้ใช้หรือเกณฑ์ทางเทคนิคที่กำหนด

## บทที่ 6

### สรุปผลการศึกษาและวิจารณ์ผลการศึกษา

#### 6.1 สรุปผลการดำเนินงาน

สรุปผลสำเร็จของโครงการอย่างกระชับและครอบคลุม

#### 6.2 ข้อสังเกตและข้อวิจารณ์

สะท้อนถึงประเด็นที่น่าสนใจหรือจุดที่ยังควรปรับปรุง

#### 6.3 ข้อเสนอแนะในการพัฒนาต่อไป

เสนอแนวทางหรือฟีเจอร์เพิ่มเติมที่ควรมีในอนาคต

#### 6.4 ประสพการณ์จากการเข้าร่วมโครงการสหกิจศึกษา

ถ่ายทอดสิ่งที่ผู้เขียนได้เรียนรู้จากการทำงานจริงในองค์กร

## บรรณานุกรม

- [1] T. Khot, S. G. Ugare, M. Goenka, S. Singh, H. R. Trivedi, A. Sabharwal, *et al.*, "Prompting large language models with divide-and-conquer program for discerning problem solving." arXiv preprint arXiv:2310.03153, 2024. Accessed: Aug 31, 2025.
- [2] L. Zhang, M. Tang, J. Ma, J. Duan, X. Sun, J. Hu, X. Xu, and X. Suchuan, "Analysis of traffic accident based on knowledge graph," *Journal of Advanced Transportation*, vol. 2022, 2022.
- [3] National Highway Traffic Safety Administration (NHTSA), "Crash Injury Research and Engineering Network (CIREN) Database." U.S. Department of Transportation, 2025. Accessed: Aug 28, 2025.
- [4] German In-Depth Accident Study (GIDAS), "German In-Depth Accident Study (GIDAS)," 2025. Accessed: Aug 28, 2025.
- [5] G. Bagschik, T. Menzel, and M. Maurer, "Ontology based scene creation for the development of automated vehicles," in *2018 21st International Conference on Intelligent Transportation Systems (ITSC)*, pp. 756–761, IEEE, 2018.