

รายงานปฏิบัติงานสหกิจศึกษา

Japan Advanced Instituted of Science and Technology

KGs-Augmented Test Suite Generation via Re-construct Accident Report

นาย ชัยภัทร ใจน่าน

650510606

สหกิจศึกษานี้เป็นส่วนหนึ่งของการศึกษาหลักสูตรปริญญาวิทยาศาสตรบัณฑิต

สาขาวิชาวิทยาการคอมพิวเตอร์

คณะวิทยาศาสตร์ มหาวิทยาลัยเชียงใหม่

ปีการศึกษา 2565

รายงานปฏิบัติงานสหกิจศึกษา

KGs-Augmented Test Suite Generation via Re-construct Accident Report

นาย ชัยภัทร ใจน่าน

650510606

สหกิจศึกษานี้เป็นส่วนหนึ่งของการศึกษาหลักสูตรปริญญาวิทยาศาสตรบัณฑิต

สาขาวิชาวิทยาการคอมพิวเตอร์

คณะวิทยาศาสตร์ มหาวิทยาลัยเชียงใหม่

ปีการศึกษา 2567

คณะกรรมการสอบสหกิจศึกษา

..... ประธานกรรมการ
(ผศ.ดร.อารีรัตน์ ตรงรัมย์ทอง)

..... กรรมการ
(ผศ.ดร.เสมอแหะ สมหอม)

วันที่ เดือน พ.ศ.

หนังสือยินยอมให้ข้อมูลเพื่อการศึกษา

กิตติกรรมประกาศ

รายงานสหกิจศึกษาฉบับนี้สำเร็จลุล่วงไปได้ด้วยดี เนื่องด้วยความกรุณา การสนับสนุน และคำแนะนำอันทรงคุณค่าจากหลายท่าน ข้าพเจ้าขอกราบขอบพระคุณทุกท่านเป็นอย่างสูงมา ณ โอกาสนี้

ขอกราบขอบพระคุณ ผศ.ดร.อารีรัตน์ ตรงรัมย์ทอง อาจารย์ที่ปรึกษาโครงการสหกิจศึกษา ที่ได้กรุณาให้คำปรึกษา ชี้แนะแนวทาง และช่วยแก้ไขข้อบกพร่องต่างๆ ด้วยความเอาใจใส่มาโดยตลอด ตั้งแต่เริ่มต้นจนกระทั่งการปฏิบัติงานเสร็จสมบูรณ์

ขอกราบขอบพระคุณ Associate Professor Natthawut Kertkeidkachorn อาจารย์พี่เลี้ยงและที่ปรึกษาโครงการ ณ Japan Advanced Institute of Science and Technology (JAIST) สำหรับการดูแลและให้คำปรึกษาอย่างใกล้ชิด การชี้แนะแนวทางด้านเทคนิค และการอภิปรายที่เป็นประโยชน์อย่างยิ่ง ซึ่งมีส่วนสำคัญอย่างยิ่งต่อความสำเร็จของโครงการวิจัยนี้

ขอกราบขอบพระคุณ Professor Toshiaki Aoki ที่ได้กรุณาสละเวลาให้คำแนะนำอันเป็นประโยชน์เกี่ยวกับแนวคิดการทดสอบยานยนต์อัตโนมัติ (AV Testing) ซึ่งช่วยให้งานวิจัยนี้มีทิศทางที่ชัดเจนและสมบูรณ์มากยิ่งขึ้น

ท้ายที่สุดนี้ ข้าพเจ้าขอขอบคุณ Japan Advanced Institute of Science and Technology (JAIST) ที่ได้มอบโอกาสในการเข้าปฏิบัติงานสหกิจศึกษาและมอบประสบการณ์การทำงานวิจัยอันล้ำค่า รวมถึงสภาพแวดล้อมที่เอื้อต่อการเรียนรู้ และขอขอบคุณคณาจารย์ภาควิชาวิทยาการคอมพิวเตอร์ ครอบครั้ว และเพื่อนๆ ทุกท่านที่เป็นกำลังใจและให้การสนับสนุนอยู่เบื้องหลังเสมอมา

นาย ชัยภัทร ใจน่าน

650510606

หัวข้อสหกิจศึกษา	การสร้างชุดทดสอบเสริมด้วย Knowledge Graphs ผ่านการสร้างรายงานอุบัติเหตุซ้ำ
สถานประกอบการ	Japan Advanced Instituted of Science and Technology
ผู้ดำเนินการศึกษา	ชัยภัทร ใจน่าน (Chaipat Jainan)
หลักสูตร	วิทยาศาสตร์บัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์
อาจารย์ที่ปรึกษาสหกิจ	ผศ.ดร.อารีรัตน์ ตรงรัศมีทอง

บทคัดย่อ

งานวิจัยนี้มีวัตถุประสงค์เพื่อแก้ไขปัญหาด้านความน่าเชื่อถือและประสิทธิภาพในการสร้างชุดทดสอบสำหรับระบบขับเคลื่อนอัตโนมัติ (ADS) จากรายงานอุบัติเหตุจริง แม้ว่าโมเดลภาษาขนาดใหญ่ (LLM) จะมีศักยภาพในการสร้างสถานการณ์จำลอง แต่การใช้งานโดยตรงยังขาดกลไกในการมุ่งเน้นไปยังกรณีขอบเขต (Edge-Case) ที่ชัดเจน ซึ่งส่งผลให้เกิดการสร้างสถานการณ์จำลองที่ไม่จำเป็นจำนวนมาก งานวิจัยจึงนำเสนอกรอบการทำงานสำหรับการสร้างชุดทดสอบที่น่าเชื่อถือและมุ่งเน้นเป้าหมาย โดยใช้ Schema-guided LLM ในการสกัดข้อมูลอุบัติเหตุที่มีโครงสร้าง ก่อนนำไปสร้างเป็น Knowledge Graph (KG) เพื่อใช้เป็นโครงสร้างเชิงความหมายที่ช่วยในการอนุมานข้อมูลและความต่อเนื่องเชิงเหตุผล หัวใจสำคัญของกรอบการทำงานนี้คือการบูรณาการ Operational Design Domain (ODD) ที่กำหนดโดย Japan Automobile Manufacturers Association (JAMA) เข้าไปใน KG เพื่อใช้เป็นหลักเกณฑ์ในการกรองและควบคุมการสร้าง Scenario ให้มุ่งเน้นการค้นพบ Edge-Case ใหม่ ๆ ได้อย่างรวดเร็วและมีประสิทธิภาพ ผลลัพธ์ที่ได้คือก้าวสำคัญในการพัฒนาวิธีการสร้างชุดทดสอบที่มีความแม่นยำสูง ซึ่งช่วยลดจำนวนครั้งในการสร้างเหตุการณ์จำลองซ้ำ และสนับสนุนการรับรองความปลอดภัยของระบบ ADS ได้อย่างเป็นรูปธรรม

Title	KGs-Augmented Test Suite Generation via Re-construct Accident Report
Company	Japan Advanced Instituted of Science and Technology
Name	Chaipat Jainan
ID	650510606
Degree	Bachelor of Science in Computer Science
Advisor	Asst. Prof. Areerat Trongratsameethong

Abstract

Ensuring the safety of Autonomous Driving Systems (ADS) necessitates rigorous testing using simulated scenarios derived from real-world accident reports. While Large Language Models (LLMs) offer a promising approach for generating these scenarios, their direct application in discovering elusive edge-cases is often inefficient and unreliable. This inefficiency stems primarily from the inconsistent nature of the source reports and the LLMs' tendency to generate numerous irrelevant scenarios, leading to an unnecessarily high number of reconstruction efforts before a novel test case is found.

To address this challenge, this study proposes a novel KGs-Augmented Testsuite Generator Framework designed to create reliable and goal-oriented test suites. The framework employs a schema-guided LL to accurately extract structured accident data from unstructured reports. This data is then modeled as a Knowledge Graph (KG), which serves as a semantic backbone, enabling robust inference of missing information and maintaining the causal continuity between events. Crucially, the framework integrates the Operational Design Domain (ODD), utilizing constraints defined by JAMA, directly into the KG structure.

The integration of ODD acts as a powerful filter and guideline, controlling the scenario generation process to focus exclusively on test cases that violate or push the boundaries of the defined operational limits. This targeted approach is the key to the framework's effectiveness, which aims to significantly reduce the number of reconstructed scenarios required to discover a new, challenging edge-case. The resulting structured scenarios are highly reliable and compliant with industry standards (e.g., ASAM OpenSCENARIO), marking a substantial improvement in the efficiency and quality of ADS safety evaluation.

สารบัญ

กิตติกรรมประกาศ	ก
บทคัดย่อ	ข
Abstract	ค
สารบัญ	ง
สารบัญรูป	ช
สารบัญตาราง	ซ
1 บทนำ	1
1.1 ข้อมูลสถานประกอบการ	1
1.1.1 ชื่อองค์กร	1
1.1.2 ระยะเวลาการปฏิบัติงาน	1
1.1.3 ลักษณะขององค์กร	1
1.2 ตำแหน่งและลักษณะงานที่ได้รับมอบหมาย	2
1.2.1 ตำแหน่งงานที่ปฏิบัติ	2
1.2.2 งานที่ได้รับมอบหมาย	2
1.3 หลักการและเหตุผล	2
1.4 วัตถุประสงค์	2
1.5 ประโยชน์ที่คาดว่าจะได้รับ	3
1.6 ขอบเขต	3
1.6.1 ขอบเขตของข้อมูล	3
1.6.2 ขอบเขตของงาน	4
1.7 เครื่องมือและเทคโนโลยีที่ใช้	4
1.7.1 ฮาร์ดแวร์ที่ใช้ในการปฏิบัติงาน	4
1.7.2 ซอฟต์แวร์ที่ใช้ในการปฏิบัติงาน	4
1.7.3 ภาษาโปรแกรมที่ใช้ในการพัฒนา	5
1.8 แผนปฏิบัติงานสหกิจศึกษา	5
2 เอกสารและงานวิจัยที่เกี่ยวข้อง	6
2.1 แนวคิดพื้นฐานและทฤษฎีที่เกี่ยวข้อง	6

2.1.1	Ego Vehicle	6
2.1.2	Operational Design Domain	6
2.1.3	Knowledge Graph	6
2.1.4	การประมวลผลภาษาธรรมชาติ	7
2.1.5	Large Language Model	7
2.1.6	Schema-guided Large Language Model	7
2.1.7	กรณีขอบเขต (Edge Case)	8
2.1.8	ประสิทธิภาพการค้นพบกรณีขอบเขต (Edge-Case Discovery Efficiency)	8
2.2	งานวิจัยที่เกี่ยวข้อง	9
2.2.1	การสร้างสถานการณ์จำลองจากรายงานอุบัติเหตุ	9
2.2.2	การวิเคราะห์อุบัติเหตุด้วย Knowledge Graph	9
2.2.3	การประยุกต์ใช้ ODD ในการทดสอบ	10
2.2.4	ความแตกต่างและช่องว่างทางการวิจัย	11
2.3	เทคโนโลยีและเครื่องมือที่ใช้	13
2.3.1	เครื่องมือประมวลผลภาษาธรรมชาติและข้อมูล	13
2.3.2	แหล่งข้อมูลอุบัติเหตุ	13
2.3.3	มาตรฐานและสภาพแวดล้อมจำลอง	14
3	ปัญหาและสมมติฐาน	17
3.1	ปัญหาที่พบในการปฏิบัติงาน	17
3.1.1	ปัญหาด้านการสกัดข้อมูลและการสร้าง Knowledge Graph	17
3.1.2	ปัญหาด้านการบูรณาการ ODD และประสิทธิภาพ	17
3.1.3	ปัญหาด้านผลลัพธ์และการนำไปใช้	18
3.2	การวิเคราะห์ปัญหา	18
3.2.1	การวิเคราะห์ปัญหาด้านข้อมูลและความน่าเชื่อถือ	18
3.2.2	การวิเคราะห์ปัญหาด้านการจัดการ Knowledge Graph และ ODD	19
3.3	สมมติฐานหรือแนวทางในการแก้ไข	19
3.3.1	การเสริมสร้างความน่าเชื่อถือของการสกัดข้อมูล	19
3.3.2	การเพิ่มประสิทธิภาพการค้นพบ Edge-Case	20
3.3.3	การปรับปรุงการส่งออก Scenario	20
3.4	ข้อจำกัดของการศึกษา	21
3.4.1	ข้อจำกัดด้านข้อมูลและเทคโนโลยี	21
3.4.2	ข้อจำกัดด้านขอบเขตการดำเนินงาน	21
4	ขั้นตอนวิธี	22
4.1	ภาพรวมของขั้นตอนวิธี	22
4.2	ขั้นตอนการดำเนินงานโดยละเอียด	23
4.2.1	ขั้นที่ 1: การสกัดข้อมูลอุบัติเหตุที่มีโครงสร้าง (Structured Data Extraction)	23
4.2.2	ขั้นที่ 2: การสร้าง Knowledge Graph (KG Modeling)	24
4.2.3	ขั้นที่ 3: การบูรณาการ ODD และการค้นหา Edge-Case ด้วย Query Rotation	24
4.2.4	ขั้นที่ 4: การสร้างชุดพารามิเตอร์สำหรับ Scenario Template	26

4.3	ขั้นตอนการประเมินผล: Scenario Completeness Score	27
4.4	ข้อจำกัดของการศึกษา	28
4.4.1	ข้อจำกัดด้านข้อมูลและเทคโนโลยี	28
4.4.2	ข้อจำกัดด้านขอบเขตการดำเนินงาน	28
5	ผลการศึกษา	30
5.1	ผลการดำเนินงานตามวัตถุประสงค์	30
5.2	ตัวอย่างผลลัพธ์	31
5.2.1	ผลการจำแนกประเภทอุบัติเหตุด้วย ODD Modular	31
5.2.2	กรณีศึกษา C00013: Intersection Signalized Conflict	31
5.3	การเปรียบเทียบก่อนและหลังการพัฒนา	33
5.4	การประเมินผล	33
6	สรุปผลการศึกษาและวิจารณ์ผลการศึกษา	34
6.1	สรุปผลการดำเนินงาน	34
6.2	ข้อสังเกตและข้อวิจารณ์	34
6.3	ข้อเสนอแนะในการพัฒนาต่อไป	35
6.4	ประสบการณ์จากการเข้าร่วมโครงการสหกิจศึกษา	35
	บรรณานุกรม	37

สารบัญรูป

2.1	ตัวอย่าง Edge Case ที่ซับซ้อนจากรายงานอุบัติเหตุจริง (CIREN) แสดงลำดับเหตุการณ์ที่นำไปสู่การชนประสานงา	9
2.2	ตัวอย่าง Ontology ของ Knowledge Graph ที่ใช้ในการจำลองความสัมพันธ์ของปัจจัยต่างๆ ในอุบัติเหตุจราจร (ดัดแปลงจาก [1])	10
2.3	ตัวอย่างการจำแนกสถานการณ์ตามกรอบการทำงาน ODD ของ JAMA [2]	11
2.4	การกระจายตัวของสถานการณ์ที่แสดงให้เห็นถึงความหนาแน่นของ Normal Safe Scenarios (กลุ่มสีแดงตรงกลาง) เทียบกับ Extreme Risky Scenarios ที่กระจัดกระจาย ซึ่งชี้ให้เห็นถึงความยากในการค้นพบเหตุการณ์หายาก (ดัดแปลงจาก [3])	12
2.5	แผนภาพสถาปัตยกรรมภาพรวมของกรอบการทำงาน ที่แสดงการบูรณาการ ODD, Knowledge Graph, และ LLM เข้าด้วยกันเพื่อสร้างชุดทดสอบ	12
2.6	ตัวอย่างกรณีศึกษาและคำอธิบายเหตุการณ์จากฐานข้อมูล CIREN (Case #1-10-2017-003-09)	13
2.7	ตัวอย่างกรณีศึกษาและคำอธิบายเหตุการณ์จากฐานข้อมูล GIDAS	14
4.1	ตัวอย่างโครงสร้างข้อมูลที่ได้จากการสกัดรายงานอุบัติเหตุ C00013 โดย Schema-guided LLM	24
4.2	ตัวอย่างส่วนหนึ่งของ Knowledge Graph ที่แสดงความสัมพันธ์ของเอนทิตีในอุบัติเหตุ C00013	25
4.3	Knowledge Graph หลังจากผ่าน Inference Engine โดยมีการสร้างความสัมพันธ์ใหม่ (เส้นสีแดง) เพื่อระบุว่าเหตุการณ์ฝ่าไฟแดงเป็น Edge-Case ที่ตรงกับ ODD Modular "การฝ่าฝืนสัญญาณจราจร"	26
5.1	ตัวอย่างชุดพารามิเตอร์ที่มีโครงสร้างซึ่งถูกสกัดจากรายงานอุบัติเหตุ C00013	32
5.2	ภาพจากสถานการณ์จำลองของกรณีศึกษา C00013 ที่สร้างขึ้นจากพารามิเตอร์ของระบบ (ซ้าย: มุมมองด้านหน้า, ขวา: มุมมองด้านหน้าขณะชน)	32

สารบัญตาราง

1.1	ตารางสรุปแผนการดำเนินงานวิจัย	5
2.1	ตัวอย่างการสกัดข้อมูลโดย Schema-guided LLM: รายงานอุบัติเหตุ C00013	8
4.1	ค่าน้ำหนักของความสัมพันธ์ประเภทต่างๆ ตามความสำคัญต่อความสมจริงของสถานการณ์	27
5.1	ผลการจำแนกประเภทอุบัติเหตุ 318 กรณีศึกษาตามกลุ่ม ODD Modular ทั้ง 21 กลุ่ม	31
5.2	ตัวอย่างผลการประเมิน R-score ในกลุ่ม ODD Modular ต่างๆ	33

บทที่ 1

บทนำ

การปฏิบัติงานสหกิจครั้งนี้ผู้จัดทำได้ปฏิบัติงานที่ Japan Advanced Instituted of Science and Technology (JAIST) ซึ่งได้รับมอบหมายงานเกี่ยวกับการออกแบบเฟรมเวิร์ค (Framework) สำหรับการสร้างชุดทดสอบของระบบขับเคลื่อนอัตโนมัติของ รถยนต์โดยนำเอาความรู้เรื่องโครงสร้างกราฟความรู้ (Knowledge Graph) มาประยุกต์ใช้

1.1 ข้อมูลสถานประกอบการ

1.1.1 ชื่อองค์กร

Japan Advanced Instituted of Science and Technology (JAIST)

1.1.2 ระยะเวลาการปฏิบัติงาน

ตั้งแต่วันที่ 14 เมษายน พ.ศ.2568 จนถึงวันที่ 30 กันยายน พ.ศ.2568

1.1.3 ลักษณะขององค์กร

Japan Advanced Institute of Science and Technology เป็นมหาวิทยาลัยในประเทศญี่ปุ่นที่จัดการศึกษาในระดับบัณฑิตศึกษา ซึ่งแบ่งสาขาวิชาตามหัวข้อศึกษาหลักที่มีอยู่ 3 หัวข้อดังนี้

- 1.) Knowledge Science: สาขาวิชาที่บูรณาการความรู้เกี่ยวกับวิธีการออกแบบ การจัดการธุรกิจ วิทยาศาสตร์ระบบ (System Science) และความรู้อื่นๆ ที่เกี่ยวข้องกับปัญหาของมนุษย์ องค์กร หรือสังคมเพื่อเสนอวิธีแก้ปัญหาลำต้นและพิจารณาว่าจะทำให้วิธีแก้ปัญหานั้นบรรลุผลได้อย่างไร
- 2.) Information Science: เป็นสาขาวิชาที่มุ่งเน้นการแก้ไขปัญหาสำหรับมนุษย์และสังคม การสร้างทฤษฎีพื้นฐานใหม่ๆ ที่เป็นนวัตกรรมและการประยุกต์การประมวลผลข้อมูลเข้ากับการสื่อสารเพื่อรองรับสังคมยุคใหม่ที่ขับเคลื่อนด้วยข้อมูล
- 3.) Material Science: เป็นสาขาวิชาการที่มุ่งผลิตวัสดุใหม่และนวัตกรรมโดยมุ่งแก้ปัญหาให้กับมนุษยชาติและสังคม และบุกเบิกสาขาที่ยังไม่มีการสำรวจบนพื้นฐานของฟิสิกส์ เคมี ชีววิทยา และวิทยาศาสตร์และเทคโนโลยีที่เกี่ยวข้อง

1.2 ตำแหน่งและลักษณะงานที่ได้รับมอบหมาย

1.2.1 ตำแหน่งที่ปฏิบัติ

Research Intern

1.2.2 งานที่ได้รับมอบหมาย

ออกแบบเฟรมเวิร์ก (Framework) สำหรับการสร้างชุดทดสอบประสิทธิภาพการทำงานของระบบ ขับเคลื่อนอัตโนมัติของรถยนต์ เพื่อให้ผู้พัฒนาระบบขับเคลื่อนอัตโนมัติสามารถสร้างชุดทดสอบของตนเอง เพื่อนำไป ปรับปรุง ปรับใช้ และทดสอบระบบของตนเอง

1.3 หลักการและเหตุผล

งานวิจัย KGs-Augmented Test Suite Generation via Re-construct Accident Report มุ่งเน้นการแก้ปัญหาหลักในการทดสอบระบบขับเคลื่อนอัตโนมัติ (ADS) นั่นคือ ต้องสร้างเคสจำลองจำนวนมากจนกว่าจะพบ Edge-Case ใหม่ ปัจจุบัน การใช้ Large Language Models (LLMs) เพื่อสร้างสถานการณ์จำลองจากรายงานอุบัติเหตุจริงยังคงมีข้อจำกัดด้านความน่าเชื่อถือ เนื่องจากขาดโครงสร้างข้อมูลที่ชัดเจนและเป้าหมายการทดสอบที่สอดคล้องกับขอบเขตการทำงานของระบบ (ADS) ที่กำหนดไว้ ซึ่งส่งผลให้มีการสร้าง Scenario ที่ไม่จำเป็นจำนวนมาก จนกว่าจะพบเคสที่ทำหายระบบจริง งานวิจัยนี้จึงถือกำเนิดขึ้นเพื่อพัฒนาแนวทางที่เป็นระบบ โดยมีวัตถุประสงค์หลักเพื่อ ลดจำนวนเหตุการณ์ที่ต้องสร้างใหม่ ให้ได้มากที่สุด และเพิ่มอัตราส่วนการค้นพบ Edge-Case

กรอบการทำงานที่นำเสนอประกอบด้วยการทำงานร่วมกันของเทคโนโลยีหลักสามส่วนเพื่อเพิ่มประสิทธิภาพดังกล่าว: 1) Schema-guided LLM ถูกใช้เพื่อสกัดข้อมูลอุบัติเหตุจากรายงานข้อความให้อยู่ในรูปแบบที่มีโครงสร้าง 2) Knowledge Graph (KG) ถูกใช้เป็นโครงสร้างเชิงความหมาย (Semantic Backbone) ในการจัดเก็บข้อมูล ทำให้สามารถอนุมานข้อมูลที่ขาดหายไปและรักษาความต่อเนื่องเชิงเหตุผลของเหตุการณ์ได้อย่างแม่นยำ และที่สำคัญที่สุดคือ 3) การผสมผสานรวม Operational Design Domain (ODD) ที่กำหนดโดย JAMA เข้าไปใน KG โดย ODD นี้ทำหน้าที่เป็นไกด์ไลน์และตัวกรอง เพื่อจำกัดการสร้าง Scenario ให้มุ่งเน้นเฉพาะสถานการณ์ที่อยู่ในขอบเขตการทำงานของ ADS เท่านั้น ซึ่งถือเป็นการควบคุมทิศทางการสร้างชุดทดสอบให้ มุ่งเป้าหมายสู่ Edge-Case ที่เกี่ยวข้อง โดยตรง

ผลลัพธ์ที่คาดว่าจะได้รับจากโครงการนี้คือ กรอบการทำงานที่เชื่อถือได้และมีประสิทธิภาพสูง ในการสร้างชุดทดสอบสำหรับ ADS ประโยชน์ที่สำคัญที่สุดคือการช่วยให้นักวิจัยและผู้พัฒนาสามารถ เพิ่มความเร็วในการค้นพบสถานการณ์ทดสอบที่สำคัญ ด้วยทรัพยากรที่น้อยลง ชุดทดสอบที่สร้างขึ้นจะมีความน่าเชื่อถือสูง เนื่องจากมีโครงสร้างและมีความสอดคล้องกับเงื่อนไข ODD ทำให้การประเมินความปลอดภัยของระบบ ADS มีความเข้มงวดและมีคุณภาพมากขึ้น ซึ่งเป็นการวางรากฐานสำคัญสำหรับการรับรองความปลอดภัยของยานยนต์อัตโนมัติในอนาคต

1.4 วัตถุประสงค์

- 1.) พัฒนารอบการสร้างชุดทดสอบที่มีความน่าเชื่อถือที่เรียกว่า KGs-Augmented Testsuite Generator ซึ่งสามารถสกัดข้อมูลอุบัติเหตุแบบมีโครงสร้างจากรายงานที่เป็นข้อความโดยใช้ Schema-guided LLM และสร้างเป็น Knowledge Graph (KG) เพื่อใช้เป็นรากฐานเชิง

ความหมายของข้อมูลอุบัติเหตุ

- 2.) เพิ่มประสิทธิภาพการค้นพบ Edge-Case โดยการบูรณาการ Operational Design Domain (ODD) ที่กำหนดโดย JAMA เข้ากับ Knowledge Graph เพื่อใช้เป็นตัวกรองและหลักเกณฑ์ในการควบคุมการสร้าง Scenario ให้มุ่งเน้นเฉพาะสถานการณ์ที่ท้าทายระบบ (Edge-Case) ซึ่งเป็นไปตามวัตถุประสงค์หลักของงานวิจัยคือ การลดจำนวนเหตุการณ์ที่จำเป็นต้องสร้างใหม่จนกว่าจะพบเคสใหม่
- 3.) สร้างชุดทดสอบอุบัติเหตุที่มีโครงสร้างที่สมบูรณ์และถูกต้องตามหลักเหตุผล ซึ่งสามารถส่งออกในรูปแบบมาตรฐาน เช่น ASAM OpenSCENARIO เพื่อนำไปใช้งานในการจำลองการทดสอบ ระบบขับเคลื่อนอัตโนมัติได้อย่างมีประสิทธิภาพและตรงเป้าหมาย

1.5 ประโยชน์ที่คาดว่าจะได้รับ

- 1.) การเพิ่มประสิทธิภาพในการค้นพบ Edge-Case: กรอบการทำงานนี้จะช่วยให้นักวิจัยและผู้พัฒนาระบบสามารถลดจำนวนเหตุการณ์จำลองที่ไม่จำเป็นลงได้อย่างมาก เนื่องจากการใช้ ODD เป็นไกด์ไลน์ในการกรองและควบคุมการสร้าง Scenario ให้มุ่งเน้นเฉพาะสถานการณ์ที่อยู่ในขอบเขตการทำงานของ ADS และท้าทายระบบจริง ๆ เท่านั้น ซึ่งนำไปสู่การประหยัดเวลาและทรัพยากรในการทดสอบ
- 2.) การยกระดับความน่าเชื่อถือของชุดทดสอบ: ชุดทดสอบที่สร้างขึ้นจาก Knowledge Graph มีความถูกต้องเชิงโครงสร้างและรักษาความต่อเนื่องเชิงเหตุผล (Causal Continuity) ของเหตุการณ์อุบัติเหตุ ทำให้ผลการประเมินระบบขับเคลื่อนอัตโนมัติมีความน่าเชื่อถือและสอดคล้องกับความเป็นจริงมากขึ้น
- 3.) การเป็นรากฐานสำหรับงานวิจัยต่อยอด: Knowledge Graph ที่สร้างขึ้นจากข้อมูลอุบัติเหตุจริงและผสมผสานร่วมกับเงื่อนไข ODD สามารถทำหน้าที่เป็นแหล่งข้อมูลความรู้เชิงความหมายที่มีโครงสร้าง ซึ่งเป็นประโยชน์อย่างยิ่งในการพัฒนากฎความปลอดภัย (Safety Rules) การสร้าง Ontology สำหรับการขับเคลื่อนอัตโนมัติ หรือการพัฒนาเครื่องมือประเมินความเสี่ยงอื่น ๆ ในอนาคต
- 4.) การสนับสนุนการรับรองความปลอดภัยตามมาตรฐาน: กรอบการทำงานนี้จะช่วยให้มั่นใจได้ว่า Scenario ที่ใช้ในการทดสอบมีความสอดคล้องกับเงื่อนไขการปฏิบัติงานที่กำหนด (ODD) ของ JAMA ซึ่งเป็นปัจจัยสำคัญในการดำเนินการและสนับสนุนกระบวนการขอการรับรองความปลอดภัยของยานยนต์อัตโนมัติ

1.6 ขอบเขต

1.6.1 ขอบเขตของข้อมูล

รายงานจาก CIREN (Crash Injury Research and Engineering Network) ของสหรัฐอเมริกา และรายงานจาก GIDAS (German In-Depth Accident Study) ข้อมูลนำเข้าเหล่านี้อยู่ในรูปแบบของรายงานอุบัติเหตุที่เป็นข้อความแบบไม่มีโครงสร้าง (Unstructured Text Reports) ซึ่งจำเป็นต้องผ่านกระบวนการสกัดข้อมูลที่มีโครงสร้าง (Structured Data Extraction) โดยใช้ Schema-guided LLM ก่อนนำไปสร้างเป็น

Knowledge Graph ทั้งนี้ ข้อจำกัดด้านการใช้งานคือ ข้อมูลทั้งหมดจะถูกใช้เพื่อสกัดเอนทิตี ความสัมพันธ์ และเงื่อนไขที่จำเป็นสำหรับการสร้าง Knowledge Graph และ Scenario จำลองเท่านั้น โดยไม่รวมถึงข้อมูลส่วนบุคคลหรือข้อมูลระบุตัวตนอื่น ๆ ที่เกี่ยวข้องกับบุคคลในรายงาน

1.6.2 ขอบเขตของงาน

ขอบเขตของงานวิจัยนี้ครอบคลุมกิจกรรมหลักตั้งแต่การประมวลผลข้อมูลอุบัติเหตุไปจนถึงการสร้างชุดทดสอบที่มีโครงสร้างที่มุ่งเน้นเป้าหมาย โดยสามารถสรุปขอบเขตของการดำเนินงานได้ดังนี้:

- 1.) การพัฒนารอบการทำงาน KGs-Augmented Testsuite Generator ซึ่งใช้ Schema-guided LLM ในการสกัดข้อมูล และใช้ Knowledge Graph (KG) ในการจัดเก็บข้อมูลเชิงความหมายพร้อมรองรับ Inference Engine
- 2.) การบูรณาการ ODD: นำ Operational Design Domain (ODD) ที่กำหนดโดย JAMA มาผสมรวมเข้ากับ Knowledge Graph เพื่อทำหน้าที่เป็นเงื่อนไขในการกรองและควบคุมการสร้าง Scenario ให้มุ่งเป้าหมายเฉพาะ Edge-Case ที่เกี่ยวข้องกับขอบเขตการทำงานของระบบ
- 3.) การสร้างผลลัพธ์: สร้างชุดข้อมูล Scenario อุบัติเหตุที่มีโครงสร้างสมบูรณ์ ซึ่งสามารถส่งออกในรูปแบบมาตรฐานของอุตสาหกรรม เช่น ASAM OpenSCENARIO ที่พร้อมนำไปใช้งานในสภาพแวดล้อมจำลอง

1.7 เครื่องมือและเทคโนโลยีที่ใช้

1.7.1 ฮาร์ดแวร์ที่ใช้ในการปฏิบัติงาน

- Operating System: Ubuntu 24.04.2 LTS
- Processor: AMD Ryzen 7 5700G
- Graphic card: Nvidia RTX 4000 Ada generation
- Memory: 46GB
- Storage: 1TB

1.7.2 ซอฟต์แวร์ที่ใช้ในการปฏิบัติงาน

- 1.) Protégé: ใช้ในการออกแบบ Schema ของ Knowledge Graph
- 2.) Carla: เป็นโปรแกรมจำลองสถานการณ์การขับขี่แบบ Open
- 3.) MATLAB: ใช้สำหรับงานวิเคราะห์ข้อมูลโครงสร้างและเครือข่ายของถนน

- 4.) Large Language Models (LLMs): ใช้ GPT-4o ใช้สำหรับงานประมวลผลภาษาธรรมชาติ เพื่อช่วยในการ สร้าง (generation) และจัดการ ข้อมูลสำหรับสถานการณ์จำลอง และการสร้าง Knowledge Graph ตามที่ ระบุในแผนภาพระบบ

1.7.3 ภาษาโปรแกรมที่ใช้ในการพัฒนา

- 1.) Python: ใช้สำหรับการพัฒนา Framework หลักในการสกัดข้อมูลอุบัติเหตุ การสร้าง Knowledge Graph และการผสมรวม ODD
- 2.) Cypher: ใช้สำหรับการสืบค้นและจัดการข้อมูลในฐานข้อมูล Knowledge Graph
- 3.) SQL: ใช้สำหรับการจัดการและสืบค้นข้อมูลในฐานข้อมูลเชิงสัมพันธ์ (Relational Database)
- 4.) Shell Scripting: ใช้สำหรับการจัดการงานอัตโนมัติและการตั้งค่าสภาพแวดล้อมการพัฒนา
- 5.) LaTeX: ใช้สำหรับการจัดทำรายงานและเอกสารทางวิชาการ
- 6.) MATLAB: ใช้สำหรับการวิเคราะห์ข้อมูลโครงสร้างและเครือข่ายของถนน

1.8 แผนปฏิบัติงานสหกิจศึกษา

ตารางที่ 1.1: ตารางสรุปแผนการดำเนินงานวิจัย

ลำดับ	กิจกรรมหลัก	พ.ค.	มิ.ย.	ก.ค.	ส.ค.	ก.ย.
1	การเรียนรู้พื้นฐานและการทบทวนงานวิจัย (LLM, KG, ODD)					
2	การ สรุป แผน วิจัย โดยละเอียด และ การ ออกแบบ Schema/ Ontology สำหรับอุบัติเหตุ					
3	การจัดการและเตรียมชุดข้อมูลอุบัติเหตุ (CIREN/GIDAS) สำหรับการสกัด					
4	การ พัฒนา Schema-guided LLM สำหรับการ สกัด ข้อมูล อุบัติเหตุที่มีโครงสร้าง					
5	การสร้าง Knowledge Graph (KG) และการพัฒนา Inference Engine (รวม ODD)					
6	การบูรณาการระบบทั้งหมด (LLM → KG → Inference) และ การสร้างชุดสถานการณ์ทดสอบเบื้องต้น					
7	การทดสอบหลัก (Main Experiment) และการสร้าง Edge-Case Scenario จำนวนมาก					
8	การประเมินผลสถานการณ์ที่สร้างขึ้นและการวิเคราะห์สรุปผล					
9	การเขียนรายงานฉบับสมบูรณ์และการเตรียมการเพื่อเผยแพร่ผลงานวิจัย					

บทที่ 2

เอกสารและงานวิจัยที่เกี่ยวข้อง

บทนี้เป็นบททบทวนวรรณกรรม เอกสาร และงานวิจัยที่เกี่ยวข้องกับแนวคิดหลักและวิธีการที่ใช้ในการวิจัยนี้ โดยมีจุดมุ่งหมายเพื่อสร้างฐานความรู้ที่แข็งแกร่งและระบุช่องว่างทางการวิจัยที่โครงการนี้มุ่งเน้นแก้ไข เนื้อหาจะแบ่งออกเป็นแนวคิดพื้นฐานเกี่ยวกับระบบขับเคลื่อนอัตโนมัติ การสร้าง Scenario โครงสร้างข้อมูล Knowledge Graph และการใช้ LLM ในการประมวลผลภาษาธรรมชาติ

2.1 แนวคิดพื้นฐานและทฤษฎีที่เกี่ยวข้อง

2.1.1 Ego Vehicle

ในบริบทของการจำลองสถานการณ์และการทดสอบระบบขับเคลื่อนอัตโนมัติ คำว่า Ego vehicle หมายถึง ยานพาหนะหลักที่กำลังถูกทดสอบหรือประเมินผล Ego Vehicle คือรถยนต์ที่ติดตั้งระบบขับเคลื่อนอัตโนมัติ (ADS) ซึ่งเป็นหัวใจสำคัญของการทดลอง โดยมุมมอง, การรับรู้, การตัดสินใจ, และการกระทำทั้งหมดของรถคันนี้จะถูกบันทึกและวิเคราะห์เพื่อประเมินประสิทธิภาพและความปลอดภัยของระบบ

2.1.2 Operational Design Domain

Operational Design Domain (ODD) คือชุดของเงื่อนไขการปฏิบัติงานที่กำหนดไว้ล่วงหน้า เช่น สภาพภูมิอากาศ สภาพถนน ความเร็วสูงสุด ซึ่งระบบขับเคลื่อนอัตโนมัติ (ADS) ได้รับการออกแบบมาให้ทำงานได้อย่างปลอดภัย ODD เป็นแนวคิดที่สำคัญอย่างยิ่งในการประเมินความปลอดภัย เนื่องจากช่วยกำหนดขอบเขตการทดสอบให้ชัดเจน งานวิจัยนี้ได้ใช้ ODD ที่กำหนดโดย Japan Automobile Manufacturers Association (JAMA) เป็นข้อกำหนดหลักในการกรองและสร้าง Scenario เพื่อให้ชุดทดสอบมีความสอดคล้องกับขีดความสามารถของระบบที่กำลังประเมิน

2.1.3 Knowledge Graph

Knowledge Graph เป็นรูปแบบการนำเสนอข้อมูลเชิงความหมาย (Semantic Data Structure) ที่ใช้โหนด (Nodes) และขอบ (Edges/Relationships) เพื่อแสดงถึงเอนทิตี (Entities) และความสัมพันธ์ระหว่างเอนทิตีเหล่านั้น บทบาทของ KG ในงานวิจัยนี้คือการทำหน้าที่เป็น Semantic Backbone สำหรับข้อมูลอุบัติเหตุนั้น ทำให้สามารถจัดเก็บข้อมูลที่สกัดจากรายงานอุบัติเหตุนั้นในรูปแบบที่มีโครงสร้างและอนุมาน (Inference) ข้อมูลที่ขาดหายไป นอกจากนี้ยังช่วยรักษาความต่อเนื่องเชิงเหตุผล (Causal Continuity) ของเหตุการณ์ที่เกิดขึ้นในอุบัติเหตุนั้น

2.1.4 การประมวลผลภาษาธรรมชาติ

การประมวลผลภาษาธรรมชาติ หรือ Natural Language Processing (NLP) เป็นสาขาย่อยหนึ่งของปัญญาประดิษฐ์ (AI) และวิทยาการคอมพิวเตอร์ ที่มุ่งเน้นการสร้างปฏิสัมพันธ์ระหว่างคอมพิวเตอร์กับภาษามนุษย์ เป้าหมายหลักของ NLP คือการทำให้คอมพิวเตอร์สามารถ "เข้าใจ" ติความ และสร้างภาษาของมนุษย์ได้ในลักษณะที่มีประโยชน์ ซึ่งครอบคลุมงานหลากหลายประเภท เช่น การสกัดข้อมูล (Information Extraction) การแปลภาษาด้วยเครื่อง (Machine Translation) และการวิเคราะห์ความรู้สึก (Sentiment Analysis) ในงานวิจัยนี้ เทคนิค NLP เป็นหัวใจสำคัญในการแปลงรายงานอุบัติเหตุที่อยู่ในรูปแบบข้อความที่ไม่มีโครงสร้าง ให้กลายเป็นข้อมูลเชิงลึกที่มีความหมายและนำไปใช้ได้

2.1.5 Large Language Model

Large Language Model (LLM) เป็นโมเดลปัญญาประดิษฐ์ที่ได้รับการฝึกฝนด้วยข้อมูลจำนวนมากมหาศาล เพื่อทำความเข้าใจและสร้างภาษาธรรมชาติ LLM มีความสามารถในการสกัดข้อมูลที่ซับซ้อนจากข้อความที่ไม่มีโครงสร้าง (Unstructured Text) งานวิจัยนี้ใช้ LLM ในการสกัดข้อมูลอุบัติเหตุจากรายงานที่เป็นข้อความ โดยมีการนำเทคนิค Schema-guided LLM มาใช้เพื่อเพิ่มความน่าเชื่อถือและความสม่ำเสมอของข้อมูลที่สกัดได้

2.1.6 Schema-guided Large Language Model

LLM เป็นเครื่องมือที่มีประสิทธิภาพในการประมวลผลภาษาธรรมชาติ (NLP) [4] งานวิจัยนี้ใช้เทคนิค Schema-guided LLM เพื่อควบคุมและกำหนดทิศทางการสกัดข้อมูลจากรายงานอุบัติเหตุที่เป็นข้อความ (Unstructured Text) ให้เป็นข้อมูลที่มีโครงสร้าง (Structured Data) ตาม Schema ที่ออกแบบไว้ล่วงหน้า [1] การควบคุมด้วย Schema นี้ช่วยเพิ่มความน่าเชื่อถือและความสม่ำเสมอของข้อมูลที่สกัดได้ ก่อนนำไปสร้างเป็น Knowledge Graph [1]

Schema-guided LLM ถูกใช้เพื่อแก้ไขปัญหาความไม่สมบูรณ์และความกำกวมของข้อมูลในรายงานอุบัติเหตุจริง (เช่น CIREN หรือ GIDAS) [5, 6] ซึ่งรายงานเหล่านี้มักถูกบันทึกในรูปแบบข้อความอิสระ (Free Text) ที่ขาดมาตรฐาน การใช้ Schema เป็น Blueprint หรือ Ontology ที่กำหนดไว้ล่วงหน้าจะทำหน้าที่เป็น "สัญญา" ในการสกัดเอนทิตี, คุณลักษณะ, และความสัมพันธ์ที่จำเป็นให้ครบถ้วน

เพื่อเพิ่มความเข้าใจในกระบวนการสกัดข้อมูลโดย Schema-guided LLM ขอนำเสนอตัวอย่างการแปลงรายงานอุบัติเหตุที่ไม่มีโครงสร้าง (Narrative) ให้อยู่ในรูปแบบข้อมูลที่มีโครงสร้าง (Extracted Feature) ซึ่งเป็นขั้นตอนสำคัญก่อนการสร้าง Knowledge Graph [7]:

ข้อมูลที่มีโครงสร้างดังกล่าว (ซึ่งอาจถูกเรียกว่า Extracted Feature หรือ JSON/XML output) เป็นรากฐานสำคัญที่ช่วยให้การแปลงเป็น Knowledge Graph ในขั้นตอนถัดไปเป็นไปได้อย่างแม่นยำและสม่ำเสมอ นอกจากนี้ การใช้ Schema ยังช่วยลดปัญหาความผิดพลาดในการอนุมานของ LLM (Hallucination) โดยเฉพาะในการสกัดความสัมพันธ์เชิงเหตุผลที่ซับซ้อน

ตารางที่ 2.1: ตัวอย่างการสกัดข้อมูลโดย Schema-guided LLM: รายงานอุบัติเหตุ C00013

รายงานอุบัติเหตุ (Unstructured Text: Case C00013)	ข้อมูลที่มีโครงสร้าง (Structured Data/Extracted Feature)
A two-vehicle collision occurred at a signalized urban intersection during daylight hours. Vehicle 1, a red fire truck traveling eastbound, entered on a green signal but came to a complete stop in the middle of the intersection. Vehicle 2, a white Honda compact SUV traveling southbound, entered against a red signal and struck the right passenger side of Vehicle 1.	1. World/Environment: <ul style="list-style-type: none"> ● Road Type: Urban intersection ● Signal Status: Functioning properly ● Time of Day: Daylight hours ● Road Condition: Dry 2. Actors: <ul style="list-style-type: none"> ● Vehicle 1 (Target): Fire truck, traveling eastbound ● Vehicle 2 (Ego/ADS Candidate): White Honda compact SUV, traveling southbound 3. Scenario Sequence (Events): <ul style="list-style-type: none"> ● Event 1 (V1): Stop in intersection (despite green light) ● Event 2 (V2): Encroachment (entered against red light) ● Event 3: Collision (V2 struck V1's right passenger side) 4. Outcome Metrics: <ul style="list-style-type: none"> ● Injury Severity (V1 Driver): Moderate ● Injury Severity (V2 Driver): Minor

2.1.7 กรณีขอบเขต (Edge Case)

หนึ่งในความท้าทายที่สำคัญที่สุดในการทดสอบระบบขับเคลื่อนอัตโนมัติ (ADS) คือการค้นหาสถานการณ์ที่เรียกว่า กรณีขอบเขต (Edge Case) ซึ่งหมายถึงสถานการณ์ที่เกิดขึ้นไม่บ่อยนัก มีความซับซ้อน หรืออยู่ ณ ขีดจำกัดของความสามารถที่ระบบได้รับการออกแบบมาให้รับมือ [8] สถานการณ์เหล่านี้คือจุดที่ระบบมีโอกาสล้มเหลวหรือทำงานผิดพลาดได้มากที่สุด ตัวอย่างที่เข้าใจง่ายคือ "คนเดินถนนที่ปรากฏตัวจากมุมอับสายตาหลังรถบัสที่จอดอยู่" ซึ่งเป็นเหตุการณ์ที่คาดเดายากและต้องการการตอบสนองที่รวดเร็วจากระบบ

อย่างไรก็ตาม Edge Case ที่เกิดขึ้นในโลกแห่งความเป็นจริงมักมีความซับซ้อนกว่านั้นมาก โดยอาจประกอบด้วยลำดับเหตุการณ์ที่ต่อเนื่องกัน การตัดสินใจที่ผิดพลาดของผู้ขับขี่หลายคน หรือปัจจัยแวดล้อมที่ไม่ปกติ ดังแสดงในรูปที่ 2.1 ซึ่งเป็นตัวอย่างสถานการณ์ที่สกัดมาจากรายงานอุบัติเหตุจริง สถานการณ์นี้ถือเป็น Edge Case ที่ดีเยี่ยมสำหรับการทดสอบ เนื่องจากเกี่ยวข้องกับการที่ยานพาหนะคันหนึ่งขับข้ามเส้นทึบเข้ามาในเลนสวนทาง ทำให้ผู้ขับขี่ทั้งสองฝ่ายต้องตัดสินใจหลบหลีกพร้อมกันในเวลาอันสั้น และจบลงด้วยการชนประสานงา ซึ่งเป็นสถานการณ์ที่ทดสอบความสามารถของ ADS ในการประเมินความเสี่ยงและเลือกการกระทำที่ลดความรุนแรงของอุบัติเหตุ (Damage Mitigation) ได้เป็นอย่างดี

2.1.8 ประสิทธิภาพการค้นพบกรณีขอบเขต (Edge-Case Discovery Efficiency)


การค้นพบ Edge Case ตามที่กล่าวมาข้างต้นมักขาดประสิทธิภาพ กล่าวคือ ต้องสิ้นเปลืองทรัพยากรและเวลาในการสร้างสถานการณ์จำลอง (Scenario) ทั่วไปที่ไม่ท้าทายระบบเป็นจำนวนมาก เพียงเพื่อจะเจอ Edge Case ที่มีความหมายเพียงไม่กี่กรณี แนวคิดเรื่อง ประสิทธิภาพการค้นพบกรณีขอบเขต (Edge-Case Discovery Efficiency) จึงเกิดขึ้นเพื่อวัดผลความสามารถของกระบวนการทดสอบ โดยนิยามว่าเป็น อัตราส่วนระหว่างจำนวน Edge Case ที่ค้นพบ ต่อจำนวนสถานการณ์จำลองทั้งหมดที่ถูกสร้างขึ้น

Vehicle 1, the 2014 Ford Focus sedan, was being driven by the 32-year-old female driver (CIREN case subject) in the far left, westbound travel lane, attempting to go straight and continue heading west.

Vehicle 2, a 2010 Honda Civic four-door sedan, was traveling eastbound in the single eastbound lane attempting to go straight and continue heading east.

Vehicle 1 crossed the solid double yellow center lane lines into the oncoming traffic lane. The driver of Vehicle 2 noticed the other vehicle encroaching into her lane, applied the vehicle's brakes, and steered left in an attempt to avoid a collision. The driver of Vehicle 1 noticed that she was in the opposing lane and steered right also in an attempt to avoid a collision with Vehicle 2. Both drivers were unsuccessful in avoiding the collision. The front of Vehicle 1 struck the front of Vehicle 2 (event 1). Vehicle 1 rotated clockwise before coming to rest in a northwesterly direction while straddling the solid double yellow lane lines. Vehicle 2 rotated counterclockwise before coming to rest in a northeasterly direction while also straddling the solid double yellow lane lines. Both vehicles were towed from the scene due to damage sustained in the crash.

Represent of



Textual Report

Actual Scene

รูปที่ 2.1: ตัวอย่าง Edge Case ที่ซับซ้อนจากรายงานอุบัติเหตุจริง (CIREN) แสดงลำดับเหตุการณ์ที่นำไปสู่การชนประสานงา

งานวิจัยที่เกี่ยวข้องอย่าง *LLMScenario* ได้แสดงให้เห็นถึงความท้าทายนี้ โดยชี้ว่าชุดข้อมูลการขับขี่จริงส่วนใหญ่มักประกอบด้วยสถานการณ์การขับขี่ปกติและปลอดภัย (Normal Safe Scenarios) แต่สถานการณ์ที่มีความเสี่ยงสูง (Extreme Risky Scenarios) ซึ่งถือเป็น Edge Case นั้นมีจำนวนน้อยมาก [3] เป้าหมายหลักของงานวิจัยนี้จึงเป็นการเพิ่มประสิทธิภาพดังกล่าวให้สูงขึ้น โดยใช้ Knowledge Graph และ Operational Design Domain (ODD) เป็นกลไกสำคัญในการกรองและมุ่งเป้าการสร้างสถานการณ์จำลองไปยังขอบเขตที่ท้าทายระบบโดยตรง เพื่อลดการสร้าง Scenario ที่ไม่จำเป็นและเร่งการค้นพบ Edge Case ใหม่ให้รวดเร็วยิ่งขึ้น


2.2 งานวิจัยที่เกี่ยวข้อง

2.2.1 การสร้างสถานการณ์จำลองจากรายงานอุบัติเหตุ

มีงานวิจัยหลายฉบับที่ได้สำรวจการใช้โมเดลภาษาขนาดใหญ่ (LLM) เพื่อแปลงรายงานอุบัติเหตุเป็นสถานการณ์จำลองสำหรับทดสอบระบบขับขี่อัตโนมัติ (ADS) [4] อย่างไรก็ตาม วิธีการเหล่านี้มักประสบปัญหาสำคัญสองประการคือ ความไม่น่าเชื่อถือของสถานการณ์จำลองที่สร้างขึ้น และการขาดกลไกที่ชัดเจนในการมุ่งเป้าไปยังกรณีขอบเขต (Edge-Case) ที่เกี่ยวข้องกับขอบเขตการทำงานของ ADS โดยตรง ซึ่งงานวิจัยฉบับนี้มุ่งเน้นการแก้ไขปัญหาดังกล่าว

2.2.2 การวิเคราะห์อุบัติเหตุด้วย Knowledge Graph

มีการประยุกต์ใช้ Knowledge Graph (KG) ในการวิเคราะห์อุบัติเหตุจราจร เพื่อจัดระเบียบและแสดงความสัมพันธ์เชิงสาเหตุของปัจจัยต่างๆ ที่นำไปสู่อุบัติเหตุ แนวทางนี้ช่วยให้นักวิจัยสามารถทำความเข้าใจองค์ประกอบที่ซับซ้อนของอุบัติเหตุได้อย่างเป็นระบบ โดยมองแต่ละปัจจัยเป็นเอนทิตี (Entity) ที่เชื่อมโยงกันด้วยความสัมพันธ์ (Relationship) ดังแสดงในรูปที่ 2.2 ซึ่งเป็นตัวอย่าง Ontology สำหรับอุบัติเหตุจากงานวิจัยของ Zhang และคณะ [1]



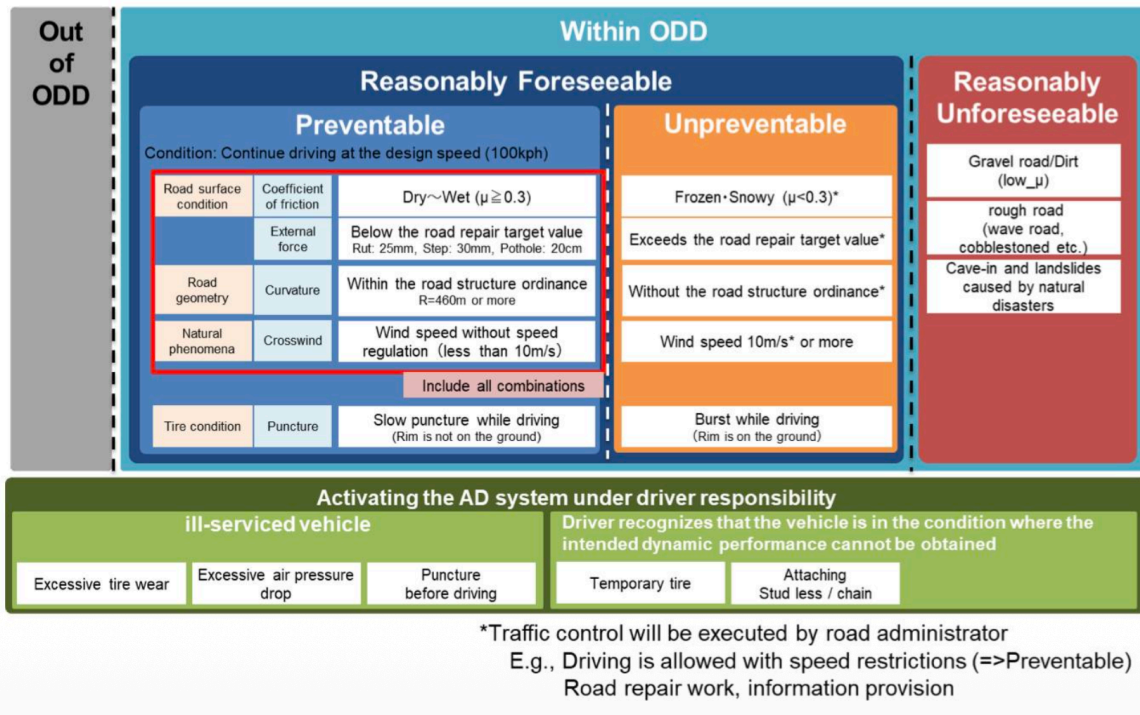
รูปที่ 2.2: ตัวอย่าง Ontology ของ Knowledge Graph ที่ใช้ในการจำลองความสัมพันธ์ของปัจจัยต่างๆ ในอุบัติเหตุจราจร (ดัดแปลงจาก [1])

จากภาพจะเห็นว่า KG สามารถเชื่อมโยงข้อมูลจากหลากหลายมิติเข้าด้วยกัน เช่น **ACCIDENT** (อุบัติเหตุ) เกิดขึ้นกับ **PEOPLE** (บุคคล) และ **VEHICLE** (ยานพาหนะ) ในสภาพ **ENVIRONMENT** (สิ่งแวดล้อม) และ **ROAD** (ถนน) ที่เฉพาะเจาะจง ซึ่งการใช้โครงสร้าง KG นี้ช่วยในการอนุมานข้อมูลที่อาจขาดหายไปและเพิ่มความเข้าใจในภาพรวมของเหตุการณ์ได้เป็นอย่างดี อย่างไรก็ตาม งานวิจัยในกลุ่มนี้มักมุ่งเน้นที่การวิเคราะห์เพื่อความเข้าใจ มากกว่าการนำไปประยุกต์ใช้เพื่อ สร้างชุดทดสอบที่มีเป้าหมายเฉพาะ ซึ่งเป็นช่องว่างที่งานวิจัยฉบับนี้ต้องการจะเติมเต็ม

2.2.3 การประยุกต์ใช้ ODD ในการทดสอบ

มีงานวิจัยและกรอบการทำงานในอุตสาหกรรมหลายฉบับที่ได้เสนอแนวคิดในการใช้ออนโทโลยี (Ontology) หรือ Operational Design Domain (ODD) เพื่อจัดหมวดหมู่และกำหนดขอบเขตของการสร้างสถานการณ์จำลองสำหรับยานยนต์อัตโนมัติ [7] แนวทางนี้ช่วยให้การทดสอบมีเป้าหมายที่ชัดเจนและเป็นระบบมากขึ้น โดยหนึ่งในกรอบการทำงานที่เป็นที่ยอมรับอย่างกว้างขวางคือ **Automated Driving Safety Evaluation Framework** โดย JAMA [2]

กรอบการทำงานของ JAMA ได้แบ่งประเภทของสถานการณ์การขับขี่ตามเงื่อนไขต่างๆ เช่น สภาพถนน, สภาพอากาศ, และรูปทรงของถนน เพื่อกำหนดขอบเขตการทำงานที่ปลอดภัยของระบบ ADS อย่างชัดเจน ดังแสดงในรูปที่ 2.3 ซึ่งจำแนกสถานการณ์ออกเป็น 3 ส่วนหลักคือ: **Preventable** (ป้องกันได้), **Unpreventable** (ป้องกันไม่ได้) ภายในขอบเขตที่คาดการณ์ได้ (Reasonably Foreseeable), และสถานการณ์ที่อยู่นอกขอบเขต ODD โดยสิ้นเชิง (Out of ODD) การจัดหมวดหมู่นี้ช่วยให้ผู้พัฒนาระบบสามารถออกแบบการทดสอบที่สอดคล้องกับความสามารถของ ADS ได้อย่างแม่นยำ



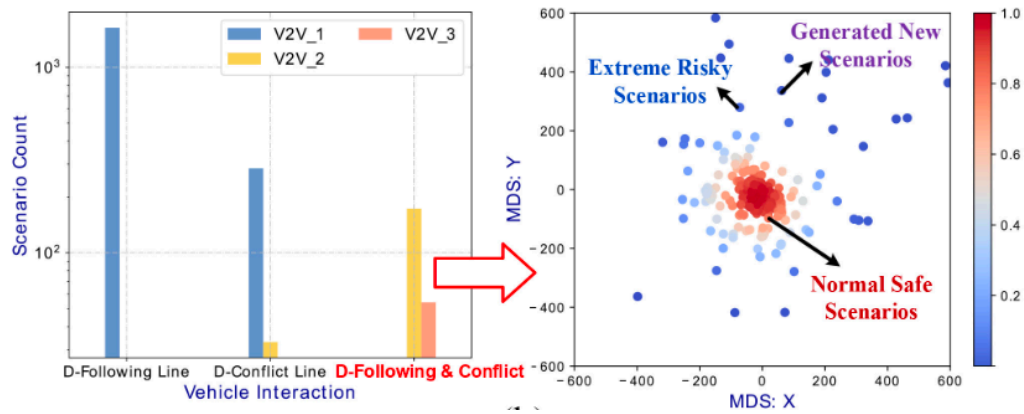
รูปที่ 2.3: ตัวอย่างการจำแนกสถานการณ์ตามกรอบการทำงาน ODD ของ JAMA [2]

อย่างไรก็ตาม แม้แนวทางเหล่านี้จะช่วยกำหนดขอบเขตการทดสอบได้ดี แต่ยังไม่มีการผสมรวม ODD เข้ากับโครงสร้าง Knowledge Graph และ LLM อย่างเป็นระบบ เพื่อแก้ไขปัญหาประสิทธิภาพในการค้นพบ Edge-Case โดยตรง ซึ่งเป็นช่องว่างสำคัญที่งานวิจัยฉบับนี้มุ่งเน้นที่จะพัฒนา

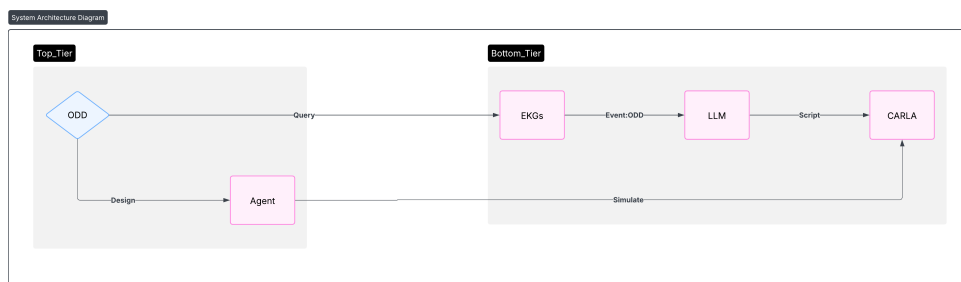
2.2.4 ความแตกต่างและช่องว่างทางการวิจัย

หัวใจสำคัญของปัญหาที่งานวิจัยนี้มุ่งเน้นแก้ไขคือ "ประสิทธิภาพในการค้นพบกรณีขอบเขต" (Edge-Case Discovery Efficiency) ที่ต่ำในวิธีการทั่วไป งานวิจัยก่อนหน้านี้อย่าง *LLMScenario* ได้แสดงให้เห็นอย่างชัดเจนว่าข้อมูลการขับขี่ในโลกแห่งความเป็นจริงส่วนใหญ่มหาศาลประกอบด้วยสถานการณ์ที่ปลอดภัยและเกิดขึ้นเป็นปกติ (Normal Safe Scenarios) ในขณะที่สถานการณ์ที่มีความเสี่ยงสูง (Extreme Risky Scenarios) ซึ่งเป็น Edge-Case ที่มีความสำคัญต่อการทดสอบนั้นมีอยู่น้อยมาก [3] ทำให้การสร้างสถานการณ์จำลองโดยขาดการชี้นำเป้าหมายต้องสร้างเหตุการณ์ซ้ำๆ จำนวนมากจนกว่าจะพบเหตุการณ์ใหม่ที่ท้าทายระบบอย่างแท้จริง ดังแสดงในรูปที่ 2.4

งานวิจัยฉบับนี้จึงเติมเต็มช่องว่างดังกล่าว โดยนำเสนอแนวทางการแก้ปัญหาแบบบูรณาการเป็นครั้งแรก ซึ่งเป็นการสังเคราะห์จุดแข็งของเทคโนโลยีสามส่วนเข้าไว้ด้วยกัน ได้แก่ 1) ความน่าเชื่อถือของ Knowledge Graph, 2) ความสามารถของ Schema-guided LLM, และ 3) การกำหนดขอบเขตที่ชัดเจนของ Operational Design Domain (ODD) การผสมรวมเทคโนโลยีทั้งสามส่วนนี้เข้าไว้ในกรอบการทำงานเดียว (ดังแสดงในรูปที่ 2.5) ทำให้เกิดเป็นแนวทางใหม่ที่มีจุดเน้นการแก้ไขปัญหา Edge-Case Discovery Efficiency โดยเฉพาะ ซึ่งแตกต่างจากงานวิจัยก่อนหน้านี้ มักจะมุ่งเน้นเพียงเทคโนโลยีใดเทคโนโลยีหนึ่งเท่านั้น



รูปที่ 2.4: การกระจายตัวของสถานการณ์ที่แสดงให้เห็นถึงความหนาแน่นของ Normal Safe Scenarios (กลุ่มสีแดงตรงกลาง) เทียบกับ Extreme Risky Scenarios ที่กระจายตัว ซึ่งชี้ให้เห็นถึงความยากในการค้นพบเหตุการณ์หายาก (ดัดแปลงจาก [3])



รูปที่ 2.5: แผนภาพสถาปัตยกรรมภาพรวมของกรอบการทำงาน ที่แสดงการบูรณาการ ODD, Knowledge Graph, และ LLM เข้าด้วยกันเพื่อสร้างชุดทดสอบ

2.3 เทคโนโลยีและเครื่องมือที่ใช้

2.3.1 เครื่องมือประมวลผลภาษาธรรมชาติและข้อมูล


- **Large Language Model (LLM):** งานวิจัยนี้เลือกใช้โมเดล GPT-4o [9] เป็นเครื่องมือหลักในการทำ Schema-guided Extraction เหตุผลสำคัญที่เลือกใช้โมเดลนี้คือความสามารถแบบหลายรูปแบบ (Multimodality) โดยเฉพาะความสามารถในการประมวลผลภาพ (Vision) ซึ่งทำให้ GPT-4o สามารถวิเคราะห์ รายงานที่เป็นข้อความ (Textual Narrative) ได้พร้อมกัน ความสามารถนี้ช่วยเพิ่มความแม่นยำในการสกัดข้อมูลที่มีความสัมพันธ์เชิงพื้นที่ (Spatial Relationship) เช่น ทิศทางการเคลื่อนที่ของรถยนต์ และตำแหน่งที่เกิดการชน ซึ่งเป็นข้อมูลที่อาจก่อกวนหากอ่านจากข้อความเพียงอย่างเดียว
- **Knowledge Graph Database:** ใช้แพลตฟอร์มฐานข้อมูลเชิงกราฟ เช่น Neo4j [10] ซึ่งเหมาะสมกับการจัดเก็บข้อมูลที่มีความสัมพันธ์ซับซ้อนอย่าง KG และรองรับการทำ Inference Engine เพื่อตรวจสอบข้อจำกัดของ ODD

2.3.2 แหล่งข้อมูลอุบัติเหตุ

งานวิจัยนี้อาศัยข้อมูลจากฐานข้อมูลอุบัติเหตุจริงเชิงลึกที่เปิดเผยต่อสาธารณะ เพื่อใช้เป็นข้อมูลนำเข้าในการสกัดสถานการณ์จำลอง แหล่งข้อมูลหลักประกอบด้วยฐานข้อมูลสำคัญสองแห่งคือ CIREN และ GIDAS ซึ่งมีลักษณะและตัวอย่างข้อมูลดังต่อไปนี้

CIREN (Crash Injury Research and Engineering Network)

CIREN เป็นเครือข่ายวิจัยการบาดเจ็บจากอุบัติเหตุของหน่วยงาน NHTSA ในสหรัฐอเมริกา [5] จุดเด่นของ CIREN คือรายงานที่มีความละเอียดสูงมาก ประกอบด้วยคำบรรยายลำดับเหตุการณ์ (Narrative) ข้อมูลเชิงวิศวกรรม และข้อมูลทางการแพทย์อย่างครบถ้วน ดังตัวอย่างกรณีศึกษาในรูปที่ 2.6




V1 was traveling northbound in lane five of a five lane controlled access roadway. V2 was traveling in lane four next to V1. A non-contact Medium-Heavy truck was traveling next to V2 in lane three when it began to change lanes to the left forcing V2 to also change lanes to the left. When changing lanes to the left the left side of V2's trailer contacted the right side of V1. This contact forced V1 to depart the roadway where the left side of V1 contacted a concrete barrier before continuing to travel forward across all five lanes to depart the roadway on the right, where the front of V1 contacted the guardrail face before coming to final rest.

รูปที่ 2.6: ตัวอย่างกรณีศึกษาและคำอธิบายเหตุการณ์จากฐานข้อมูล CIREN (Case #1-10-2017-003-09)

GIDAS (German In-Depth Accident Study)

GIDAS เป็นโครงการรวบรวมข้อมูลอุบัติเหตุเชิงลึกในประเทศเยอรมนี [6] ซึ่งมีขนาดใหญ่และครอบคลุมความรุนแรงของอุบัติเหตุที่หลากหลาย ตั้งแต่กรณีเล็กน้อยไปจนถึงรุนแรง ทำให้เหมาะสำหรับการวิเคราะห์เชิงสถิติเพื่อทำความเข้าใจการกระจายตัวของข้อมูลอุบัติเหตุจริง ดังตัวอย่างกรณีศึกษาในรูปที่ 2.7



Participant 01 (VW Golf) was driving on the K9013 in the direction of Oelsa. He skidded on a downhill section in a right-hand bend on a wet road surface. The vehicle understeers and collides with participant 02 (Volvo XC60), who is driving on the K9013 in the opposite direction. As a result of the collision, the car 02 slides into the embankment. Both occupants of participant 01 and the driver of participant 02 are slightly injured.

รูปที่ 2.7: ตัวอย่างกรณีศึกษาและคำอธิบายเหตุการณ์จากฐานข้อมูล GIDAS

ข้อมูลจากแหล่งข้อมูลทั้งสองดังที่แสดงในตัวอย่าง มีความละเอียดเพียงพอต่อการสกัดเอนทิตีและความสัมพันธ์เพื่อสร้างเป็น Knowledge Graph ได้อย่างสมบูรณ์

2.3.3 มาตรฐานและสภาพแวดล้อมจำลอง

ผลลัพธ์สุดท้ายของกรอบการทำงานวิจัยนี้ ถูกออกแบบให้สามารถส่งออกสถานการณ์จำลอง (Scenario) ในรูปแบบไฟล์ที่เข้ากันได้กับมาตรฐานอุตสาหกรรมยานยนต์ นั่นคือ ASAM OpenSCENARIO ซึ่งเป็นรูปแบบมาตรฐานที่ใช้ในการอธิบายลำดับเหตุการณ์ พฤติกรรมของ Actors, และเงื่อนไขต่างๆ ในการทดสอบระบบขับเคลื่อนอัตโนมัติ การใช้มาตรฐานนี้ช่วยให้ชุดทดสอบที่สร้างขึ้นสามารถนำไปใช้งานในสภาพแวดล้อมจำลอง (Simulation Environment) ที่หลากหลายได้ เช่น CARLA, Esmi, VTD เป็นต้น

เพื่อแสดงให้เห็นภาพผลลัพธ์ที่เป็นรูปธรรม ขอนำเสนอตัวอย่างโค้ดของไฟล์ OpenSCENARIO (`.xosc`) ซึ่งเป็นไฟล์ XML ที่อธิบายสถานการณ์จำลอง "รถยนต์ขับตัดหน้า (Cut-in)" ฉบับย่อ ดังแสดงในโค้ดตัวอย่างที่ 2.1

```

1 <OpenSCENARIO>
2   <Entities>
3     <ScenarioObject name="Ego">
4       <Vehicle name="DefaultVehicle" vehicleCategory="car"/>
5     </ScenarioObject>
6     <ScenarioObject name="Adversary">
7       <Vehicle name="DefaultVehicle" vehicleCategory="car"/>
8     </ScenarioObject>
9   </Entities>
10
11 <Storyboard>
12   <Init>
13     <Actions>
14       <Private entityRef="Ego">
15         </Private>
16       <Private entityRef="Adversary">
17         </Private>
18     </Actions>
19   </Init>
20   <Story name="CutInStory">
21     <Act name="CutInAct">
22       <ManeuverGroup name="AdversaryManeuver">
23         <Actors>
24           <EntityRef entityRef="Adversary"/>
25         </Actors>
26         <Maneuver name="AdversaryCutIn">
27           <Event name="AdversaryLaneChange" priority="parallel">
28             <Action name="LaneChangeAction">
29               <PrivateAction>
30                 <LaneChangeAction>
31                   <LaneChangeTarget>
32                     <RelativeTargetLane entityRef="Ego" value="0"/>
33                   </LaneChangeTarget>
34                 </LaneChangeAction>
35               </PrivateAction>
36             </Action>
37             <StartTrigger>
38               </StartTrigger>
39           </Event>
40         </Maneuver>
41       </ManeuverGroup>
42     </StartTrigger/>
43   </Act>
44 </Story>
45 </Storyboard>
46 </OpenSCENARIO>

```

Listing 2.1: ตัวอย่างโค้ดไฟล์ ASAM OpenSCENARIO ฉบับย่อ ที่อธิบายสถานการณ์ Cut-in

จากโค้ดตัวอย่างจะเห็นองค์ประกอบสำคัญต่างๆ เช่น ส่วน '<Entities>' ใช้สำหรับประกาศ Actors ที่เกี่ยวข้อง (รถ Ego และรถคู่กรณี), ส่วน '<Init>' ใช้วางตำแหน่งเริ่มต้นของรถแต่ละคัน และส่วน '<Storyboard>' ซึ่งเป็นหัวใจหลัก ใช้อธิบายลำดับเหตุการณ์และพฤติกรรมที่จะเกิดขึ้น เช่น การเปลี่ยนเลนเพื่อขับตัดหน้า ('<LaneChangeAction>') กรอบการทำงานวิจัยนี้จะทำหน้าที่สร้างไฟล์ที่มีโครงสร้างลักษณะนี้ขึ้นมาโดยอัตโนมัติจากข้อมูลอุบัติเหตุจริง

บทที่ 3

ปัญหาและสมมติฐาน

3.1 ปัญหาที่พบในการปฏิบัติงาน

ในการดำเนินงานตามกรอบการทำงาน KGs-Augmented Testsuite Generator Framework มีความท้าทายและปัญหาทางเทคนิคหลายประการที่เกิดขึ้น ซึ่งเกี่ยวข้องกับการจัดการข้อมูลที่ซับซ้อน การทำงานร่วมกันของเทคโนโลยีที่แตกต่างกัน และคุณภาพของข้อมูลนำเข้า โดยสามารถสรุปปัญหาหลักที่พบได้ดังนี้:

3.1.1 ปัญหาด้านการสกัดข้อมูลและการสร้าง Knowledge Graph

ปัญหาหลักที่พบในการสกัดข้อมูลจากรายงานอุบัติเหตุและการสร้าง Knowledge Graph มีดังนี้:

- 1.) ความไม่สมบูรณ์ของข้อมูลในรายงานอุบัติเหตุ: รายงานอุบัติเหตุที่มาจากแหล่งข้อมูลอย่าง CIREN หรือ GIDAS มักมีข้อมูลบางส่วนที่ขาดหายไป กำกวม หรือขัดแย้งกันเอง ซึ่งทำให้การสกัดข้อมูลโดยใช้ Schema-guided LLM มีความท้าทายอย่างมากในการรับรองความถูกต้อง (Fidelity) และความน่าเชื่อถือของเอนทิตีที่ถูกสกัด
- 2.) ความผิดพลาดในการอนุมานของ LLM: แม้จะใช้ Schema-guided LLM เพื่อควบคุมทิศทางการสกัดข้อมูลแล้ว แต่โมเดลภาษานี้ขนาดใหญ่ก็ยังคงมีแนวโน้มที่จะสร้างข้อความที่ผิดพลาดหรือข้อมูลที่ไม่สอดคล้องกับความเป็นจริง (Hallucination) โดยเฉพาะเมื่อต้องสกัดความสัมพันธ์เชิงเหตุผล (Causal Relationships) ที่ซับซ้อน
- 3.) ความท้าทายในการสร้าง Knowledge Graph ที่สม่ำเสมอ: การแปลงข้อมูลที่มีโครงสร้างที่ถูกสกัดมาให้อยู่ในรูปแบบ Knowledge Graph ที่สอดคล้องและสม่ำเสมอ (Consistent Schema) นั้นทำได้ยาก เนื่องจากข้อมูลอุบัติเหตุแต่ละกรณีมีความแตกต่างกันอย่างมาก ทำให้ต้องมีการปรับแก้โครงสร้างกราฟและกฎการสร้างความสัมพันธ์ (Triples) อยู่เสมอ

3.1.2 ปัญหาด้านการบูรณาการ ODD และประสิทธิภาพ

- 1.) ความซับซ้อนของการกำหนดกฎ ODD: การกำหนดกฎเชิงตรรกะที่เข้มงวดของ Operational Design Domain (ODD) ให้เป็นเงื่อนไขที่ใช้ในการสืบค้น (Inference Query) ภายใน Knowledge Graph นั้นมีความซับซ้อนสูง หากกำหนดกฎไม่ละเอียดพอ อาจทำให้เกิดการก

รองที่หลวมเกินไป และยังคงสร้าง Scenario ที่ไม่เกี่ยวข้อง หรือหากกำหนดกฎที่เข้มงวดเกินไป อาจทำให้พลาด Edge-Case ที่มีความสำคัญไป

- 2.) ประสิทธิภาพของการประมวลผลกราฟ: เมื่อ Knowledge Graph มีขนาดใหญ่ขึ้น การเรียกใช้ Inference Engine เพื่อประเมินและค้นหา Scenario ที่ละเมิดกฎ ODD หรือสอดคล้องกับ Edge-Case จะใช้ทรัพยากรการประมวลผลและเวลาที่เพิ่มขึ้นอย่างมาก ซึ่งส่งผลต่อประสิทธิภาพโดยรวมของกระบวนการทำงานในการค้นพบ Edge-Case ใหม่ ๆ

3.1.3 ปัญหาด้านผลลัพธ์และการนำไปใช้

ความท้าทายในการส่งออกรูปแบบมาตรฐาน: การแปลงข้อมูล Scenario จากโครงสร้าง Knowledge Graph ที่มีความละเอียดสูง ไปสู่รูปแบบไฟล์มาตรฐานของอุตสาหกรรม เช่น ASAM OpenSCENARIO ต้องอาศัยการทำ Mapping ที่แม่นยำเพื่อรับประกันว่า Scenario ที่สร้างขึ้นจะสามารถรันในสภาพแวดล้อมจำลองได้อย่างถูกต้อง โดยไม่เกิดข้อผิดพลาดในการแปลความหมายของตัวแปรและเอนทิตี

3.2 การวิเคราะห์ปัญหา

การวิเคราะห์ปัญหาที่เกิดขึ้นในการปฏิบัติงานมีความจำเป็นอย่างยิ่ง เพื่อให้สามารถระบุแนวทางแก้ไขที่เหมาะสมและปรับปรุงประสิทธิภาพของกรอบการทำงาน KGs-Augmented Testsuite Generator ได้อย่างตรงจุด การวิเคราะห์ปัญหาหลัก ๆ ที่พบมีดังนี้:

3.2.1 การวิเคราะห์ปัญหาด้านข้อมูลและความน่าเชื่อถือ

จากการวิเคราะห์ปัญหาที่กล่าวมาข้างต้น สามารถสรุปที่มาของปัญหา ได้ดังนี้

1.) ปัญหาจากความไม่สมบูรณ์และกำกวมของข้อมูล:

- สาเหตุ: รายงานอุบัติเหตุจริง CIREN และ GIDAS ถูกบันทึกโดยมนุษย์ในรูปแบบข้อความอิสระ (Free Text) ซึ่งมีลักษณะเป็นการตีความและสังเกตการณ์ที่แตกต่างกัน ทำให้ขาดมาตรฐานในการให้ข้อมูลที่สม่ำเสมอ และมีโอกาสเกิดการละเว้นข้อมูลบางส่วนที่สำคัญต่อการสร้าง Scenario
- ผลกระทบ: ทำให้ Schema-guided LLM ไม่สามารถสกัดข้อมูลที่มีโครงสร้างได้อย่างสมบูรณ์ และส่งผลให้ Knowledge Graph ที่สร้างขึ้นมีช่องว่างของข้อมูล (Missing Triples) ซึ่งลดความน่าเชื่อถือและความแม่นยำของ Scenario จำลองที่ต้องอาศัยความต่อเนื่องเชิงเหตุผล

2.) ปัญหาความผิดพลาดในการอนุมานของ LLM:

- สาเหตุ: แม้จะมีการใช้ Schema เป็นแนวทาง แต่ LLM ยังมีข้อจำกัดในการทำความเข้าใจบริบททางฟิสิกส์ (Physical Constraints) หรือกฎหมายที่ซับซ้อน ทำให้เกิดการสร้างข้อมูลที่ผิดพลาด (Hallucination) หรือการสกัดความสัมพันธ์เชิงเหตุผลที่ไม่ถูกต้อง

- ผลกระทบ: ทำให้ Knowledge Graph มีข้อมูลที่มีผิดพลาดแฝงอยู่ ซึ่งหากนำไปสร้างเป็น Scenario จะทำให้ได้ชุดทดสอบที่ไม่มีความจริงหรือไม่สามารถเกิดขึ้นได้จริงในทางปฏิบัติ ส่งผลให้ประสิทธิภาพในการประเมิน ADS ลดลง

3.2.2 การวิเคราะห์ปัญหาในการจัดการ Knowledge Graph และ ODD

จากการวิเคราะห์ปัญหาที่กล่าวมาข้างต้น สามารถสรุปที่มาของปัญหา ได้ดังนี้

1.) ปัญหาความซับซ้อนของการกำหนดกฎ ODD:

- สาเหตุ: การแปลงคำนิยามของ Operational Design Domain (ODD) ซึ่งเป็นแนวคิดที่ค่อนข้างเป็นนามธรรม ให้เป็นกฎเชิงตรรกะที่เข้มงวดสำหรับการสืบค้นใน Knowledge Graph (KG) นั้นต้องอาศัยความเชี่ยวชาญและการตีความที่แม่นยำ
- ผลกระทบ: หากการกำหนดกฎไม่แม่นยำ จะส่งผลกระทบโดยตรงต่อวัตถุประสงค์หลักของงานวิจัย กล่าวคือ การกรอง Scenario ที่ไม่เกี่ยวข้องออกไปทำไม่ได้ไม่ดีพอ (เกิด False Positives) ทำให้จำนวนเหตุการณ์ที่ต้องสร้างใหม่จนกว่าจะพบ Edge-Case ใหม่ ยังคงสูงอยู่

2.) ปัญหาประสิทธิภาพการประมวลผลกราฟขนาดใหญ่:

- สาเหตุ: การทำงานของ Inference Engine บน Knowledge Graph ที่ขยายตัวอย่างต่อเนื่อง (เมื่อมีการเพิ่มรายงานอุบัติเหตุเข้าไป) จำเป็นต้องมีการประมวลผลความสัมพันธ์จำนวนมหาศาลเพื่อหา Scenario ที่สอดคล้องกับกฎ ODD หรือละเมิดความปลอดภัย
- ผลกระทบ: ประสิทธิภาพการสืบค้นและเวลาในการตอบสนอง (Query Latency) ลดลงอย่างมีนัยสำคัญ เมื่อฐานข้อมูล Knowledge Graph เติบโตขึ้น ซึ่งเป็นอุปสรรคต่อการนำกรอบการทำงานนี้ไปใช้ในระดับอุตสาหกรรมที่ต้องมีการประมวลผลข้อมูลจำนวนมากแบบเรียลไทม์หรือเกือบเรียลไทม์

3.3 สมมติฐานหรือแนวทางในการแก้ไข

จากปัญหาที่ได้วิเคราะห์ไว้ในกระบวนการพัฒนากรณีศึกษา (Scenario) โดยใช้ KGs-Augmented Testsuite Generator Framework มีสมมติฐานและแนวทางแก้ไขหลายประการที่ถูกนำมาพิจารณาและประยุกต์ใช้เพื่อเพิ่มประสิทธิภาพ ความน่าเชื่อถือ และความสามารถในการค้นพบ Edge-Case ของระบบ

3.3.1 การเสริมสร้างความน่าเชื่อถือของการสกัดข้อมูล

การแก้ไขปัญหาด้านข้อมูลและความน่าเชื่อถือของการสกัดข้อมูล มีสมมติฐานและแนวทางแก้ไขดังนี้

- 1.) การใช้เทคนิค Multi-Step Prompting สำหรับ LLM: เพื่อแก้ไขปัญหาความผิดพลาดในการอนุมานของ LLM และความไม่สมบูรณ์ของข้อมูล มีการตั้งสมมติฐานว่าการแยกกระบวนการสกัดข้อมูลที่ซับซ้อนออกเป็นขั้นตอนย่อย ๆ เช่น สกัดเอนทิตี สกัดความสัมพันธ์ ตรวจสอบความสอดคล้องเชิงฟิสิกส์ จะช่วยให้ LLM มีความแม่นยำสูงขึ้นในการสกัดข้อมูลและการสร้างความสัมพันธ์เชิงเหตุผล
- 2.) การใช้ Cross-Validation โดยผู้เชี่ยวชาญ: กำหนดให้มีการตรวจสอบความถูกต้องของข้อมูล (Data Fidelity) ที่ถูกสกัดจาก LLM โดยผู้เชี่ยวชาญด้านการวิเคราะห์อุบัติเหตุหรือวิศวกรรมความปลอดภัย เพื่อปรับปรุง Schema และกฎการสกัดข้อมูลให้มีความแม่นยำสูงขึ้นก่อนนำเข้า Knowledge Graph
- 3.) การสร้าง Ontology สำหรับอุบัติเหตุ: พัฒนาระบบ Ontology ที่มีรายละเอียดเฉพาะสำหรับ Domain อุบัติเหตุจราจร เพื่อใช้เป็น Schema ที่เข้มงวดและเป็นมาตรฐานในการกำหนดนิยามเอนทิตีและความสัมพันธ์ใน Knowledge Graph ซึ่งจะช่วยลดปัญหาความไม่สม่ำเสมอของโครงสร้างกราฟ

3.3.2 การเพิ่มประสิทธิภาพการค้นพบ Edge-Case

การแก้ไขปัญหาด้านการจัดการ Knowledge Graph และ ODD มีสมมติฐานและแนวทางแก้ไขดังนี้

- 1.) การใช้กฎ ODD แบบลำดับชั้น (Hierarchical ODD Rules): เพื่อแก้ไขปัญหาความซับซ้อนในการกำหนดกฎ ODD มีสมมติฐานว่าการจัดโครงสร้างกฎ ODD ให้เป็นลำดับชั้น (เช่น เงื่อนไขทั่วไป, เงื่อนไขเฉพาะ, เงื่อนไขข้อยกเว้น) จะช่วยให้ Inference Engine สามารถประมวลผลการกรอง Edge-Case ได้อย่างมีประสิทธิภาพมากขึ้น และลดโอกาสที่จะเกิดการกรองที่ผิดพลาด (False Filtering)
- 2.) การใช้ Partitioning และ Indexing ใน Knowledge Graph: เพื่อจัดการกับปัญหาประสิทธิภาพของการประมวลผลกราฟขนาดใหญ่ มีการนำเทคนิคการแบ่งส่วนข้อมูล (Partitioning) หรือการสร้างดัชนี (Indexing) เฉพาะสำหรับเอนทิตีที่เกี่ยวข้องกับ ODD และ Edge-Case เข้ามาใช้ในการค้นหา Knowledge Graph เพื่อลดภาระการคำนวณของ Inference Engine ในระหว่างการสืบค้น (Query)
- 3.) การพัฒนา Metric ในการให้คะแนน Edge-Case (Edge-Case Scoring Metric): สร้างมาตรวัดเชิงปริมาณ (Quantitative Metric) เพื่อให้คะแนนความร้ายแรง (Severity) ของ Scenario ที่สร้างขึ้น ซึ่งจะทำให้สามารถจัดลำดับความสำคัญของ Scenario ที่ถูกสร้างขึ้น และมุ่งเน้นการสร้างซ้ำเฉพาะในกลุ่มที่มีคะแนน Edge-Case สูง เพื่อให้การค้นพบเคสใหม่มีความรวดเร็วและเป็นไปตามวัตถุประสงค์ของการวิจัย

3.3.3 การปรับปรุงการส่งออก Scenario

การพัฒนาระบบ Mapping อัตโนมัติ: พัฒนาเครื่องมือ Mapping อัตโนมัติที่แข็งแกร่งเพื่อแปลงความสัมพันธ์และคุณสมบัติต่าง ๆ จาก Knowledge Graph ให้เป็นรูปแบบ ASAM OpenSCENARIO ที่ถูกต้องแม่นยำ โดยมีการตรวจสอบความสอดคล้องกับ Schema ของมาตรฐาน ASAM เพื่อลดข้อผิดพลาดในการแปลความหมายของ Scenario ก่อนนำไปใช้ในการจำลอง

3.4 ข้อจำกัดของการศึกษา

การวิจัยนี้มุ่งเน้นการพัฒนากรอบการทำงานที่เป็นแนวคิดใหม่ในการสร้างชุดทดสอบ แต่ก็มีข้อจำกัดหลายประการที่ต้องนำมาพิจารณา ซึ่งส่วนใหญ่เกี่ยวข้องกับคุณภาพของข้อมูลนำเข้า ความจำกัดของเทคโนโลยีที่ใช้ และขอบเขตการดำเนินงานที่ถูกกำหนดไว้ล่วงหน้า ดังนี้:

3.4.1 ข้อจำกัดด้านข้อมูลและเทคโนโลยี

ข้อจำกัดหลักที่พบในด้านข้อมูลและเทคโนโลยี มีดังนี้

- 1.) การพึ่งพาข้อมูลอุบัติเหตุในอดีต: การศึกษานี้ขึ้นอยู่กับรายงานอุบัติเหตุจริงจากฐานข้อมูลสาธารณะ เช่น CIREN และ GIDAS ซึ่งเป็นข้อมูลในอดีตและมีลักษณะที่ไม่สมบูรณ์ รวมถึงมีความเป็นอัตวิสัย (Subjectivity) ในการบันทึกของผู้รายงาน ข้อจำกัดนี้ส่งผลโดยตรงต่อคุณภาพและความแม่นยำของ Knowledge Graph ที่ถูกสร้างขึ้น
- 2.) ความท้าทายด้านความน่าเชื่อถือของ LLM: แม้จะมีการใช้ Schema-guided LLM เพื่อสกัดข้อมูล แต่โมเดลภาษายังคงมีแนวโน้มที่จะสร้างข้อมูลที่ผิดพลาด (Hallucination) หรือความสัมพันธ์เชิงเหตุผลที่ไม่ถูกต้อง โดยเฉพาะในสถานการณ์อุบัติเหตุที่มีความซับซ้อน ซึ่งทำให้ต้องอาศัยการตรวจสอบและปรับแก้จากผู้เชี่ยวชาญเพิ่มเติม
- 3.) ข้อจำกัดในการสรุปผล ODD: Operational Design Domain (ODD) ที่ใช้ในการวิจัยนี้อ้างอิงตามมาตรฐานของ JAMA เป็นหลัก ดังนั้นชุดทดสอบและผลลัพธ์ที่ได้จึงอาจไม่สามารถนำไปสรุปผลหรือนำไปประยุกต์ใช้โดยตรงกับระบบขับเคลื่อนอัตโนมัติ (ADS) ที่ถูกออกแบบมาภายใต้มาตรฐาน ODD ของผู้ผลิตหรือองค์กรอื่นที่มีนิยามที่แตกต่างกัน
- 4.) ปัญหาด้านการประมวลผลของ Knowledge Graph: เมื่อ Knowledge Graph เติบโตขึ้นตามจำนวนรายงานอุบัติเหตุที่เพิ่มขึ้น ประสิทธิภาพในการประมวลผลของ Inference Engine เพื่อสืบค้นและประเมินกฎ ODD จะลดลง ซึ่งอาจเป็นข้อจำกัดในการนำกรอบการทำงานนี้ไปใช้งานในระดับอุตสาหกรรมขนาดใหญ่ที่ต้องการความเร็ว

3.4.2 ข้อจำกัดด้านขอบเขตการดำเนินงาน

ข้อจำกัดด้านขอบเขตการดำเนินงานของการวิจัยนี้ มีดังนี้

- 1.) การขาดการประเมินในสภาพแวดล้อมจริง: ขอบเขตของโครงการสิ้นสุดที่การสร้างไฟล์ Scenario ที่มีโครงสร้างมาตรฐาน (เช่น ASAM OpenSCENARIO) และไม่ได้รวมถึงการดำเนินการจำลองสถานการณ์ (Simulation) หรือการทดสอบภาคสนามจริง ดังนั้น การประเมินผลกระทบที่แท้จริงของชุดทดสอบต่อประสิทธิภาพของระบบ ADS จึงอยู่นอกเหนือขอบเขตของการศึกษานี้
- 2.) การละเลยปัจจัยมนุษย์ในระดับละเอียด: Scenario ที่สร้างขึ้นเน้นการจับภาพเหตุการณ์ทางกายภาพและสภาพแวดล้อมเป็นหลัก แม้จะมีการเก็บข้อมูลพฤติกรรม แต่การวิเคราะห์และจำลองปัจจัยด้านมนุษย์ (Human Factors) เช่น ความผิดพลาดทางสติปัญญา หรือการตอบสนองทางอารมณ์ของผู้ขับขี่อย่างละเอียด ยังคงเป็นสิ่งที่ซับซ้อนและไม่ได้เป็นจุดเน้นหลักของกรอบการทำงานนี้

บทที่ 4

ขั้นตอนวิธี

4.1 ภาพรวมของขั้นตอนวิธี

กระบวนการดำเนินงานของโครงการวิจัยนี้เป็นไปตามกรอบการทำงาน KGs-Augmented Testsuite Generator Framework ซึ่งถูกออกแบบมาเพื่อเปลี่ยนรายงานอุบัติเหตุที่เป็นข้อความ (Unstructured Text) ให้กลายเป็นชุดทดสอบ (Test Suite) ที่มีโครงสร้างและมุ่งเน้นการค้นหา Edge-Case อย่างมีประสิทธิภาพ หัวใจสำคัญของขั้นตอนวิธีคือการทำงานร่วมกันของเทคโนโลยีสามส่วนหลัก ได้แก่ Schema-guided LLM, Knowledge Graph (KG) และ Inference Engine ที่ใช้กฎของ Operational Design Domain (ODD) โดยเฉพาะอย่างยิ่งการใช้เทคนิค Query Rotation ผ่านกลุ่มของ ODD ที่เรียกว่า ODD Modular เพื่อให้การค้นหามีความครอบคลุมและเป็นระบบ ผลลัพธ์สุดท้ายของกระบวนการนี้ไม่ใช่ไฟล์สถานการณ์จำลองที่สมบูรณ์ แต่เป็นชุดของ พารามิเตอร์ (Parameters) ที่พร้อมสำหรับนำไปใช้กับ Scenario Template ที่มีอยู่แล้วในขั้นตอนการทดสอบจริง โดยกระบวนการทั้งหมดสามารถสรุปเป็นอัลกอริทึมได้ดังแสดงใน Algorithm 1

Algorithm 1 KGs-Augmented Testsuite Generation Framework with Modular Query

```
1: Input: AccidentReports (ชุดรายงานอุบัติเหตุ), ODDModularGroups (กลุ่มของกฎ ODD)
2: Output: GeneratedParameters (ชุดของพารามิเตอร์สำหรับ Scenario Templates)
3: procedure GenerateTestsuite(AccidentReports, ODDModularGroups)
4:   StructuredDataList  $\leftarrow$  []
5:   KnowledgeGraph  $\leftarrow$  InitializeEmptyGraph()
6:   for all report in AccidentReports do
7:     structuredData  $\leftarrow$  ExtractStructuredData(report)
8:     StructuredDataList.add(structuredData)
9:   for all data in StructuredDataList do
10:    BuildKnowledgeGraph(KnowledgeGraph, data)
11:   AllEdgeCaseEvents  $\leftarrow$  []
12:   for all modularGroup in ODDModularGroups do
13:     foundEvents  $\leftarrow$  QueryCasesByModular(KnowledgeGraph, modularGroup)
14:     AllEdgeCaseEvents.addRange(foundEvents)
15:   GeneratedParameters  $\leftarrow$  []
16:   for all event in AllEdgeCaseEvents do
17:     params  $\leftarrow$  GenerateParametersFromEvent(event)
18:     GeneratedParameters.add(params)
19:   return GeneratedParameters
```

▷ ขั้นที่ 1: การสกัดข้อมูลอุบัติเหตุ (Data Extraction)

▷ ขั้นที่ 2: การสร้าง Knowledge Graph (KG Modeling)

▷ ขั้นที่ 3: การค้นหา Edge-Case ด้วย Query Rotation

▷ ขั้นที่ 4: การสร้างชุดพารามิเตอร์จาก Edge-Case

4.2 ขั้นตอนการดำเนินงานโดยละเอียด

4.2.1 ขั้นที่ 1: การสกัดข้อมูลอุบัติเหตุที่มีโครงสร้าง (Structured Data Extraction)

ขั้นตอนแรกคือการแปลงรายงานอุบัติเหตุที่ไม่มีโครงสร้างให้เป็นข้อมูลที่มีโครงสร้างที่ชัดเจน โดยใช้โมเดลภาษาขนาดใหญ่ (LLM) ที่ถูกควบคุมทิศทางด้วย Schema ที่ออกแบบไว้ล่วงหน้า เพื่อให้มั่นใจได้ว่าข้อมูลสำคัญทั้งหมดจะถูกสกัดออกมาอย่างครบถ้วนและสม่ำเสมอ กระบวนการนี้สรุปได้ดัง Function ExtractStructuredData

```
1: function ExtractStructuredData(report)
2:   worldData  $\leftarrow$  LLM.extract(report, worldSchema)
3:   actorData  $\leftarrow$  LLM.extract(report, actorSchema)
4:   sequenceData  $\leftarrow$  LLM.extract(report, sequenceSchema)
5:   return {world: worldData, actors: actorData, sequence: sequenceData}
```

▷ ใช้เทคนิค Multi-Step Prompting เพื่อความแม่นยำ

ผลลัพธ์จากขั้นตอนนี้คือชุดข้อมูลที่มีโครงสร้าง (เช่น ในรูปแบบ JSON) ซึ่งแยกองค์ประกอบของอุบัติเหตุออกเป็น 3 ส่วนหลัก ได้แก่ World, Actors, และ Sequence ดังแสดงตัวอย่างในรูปที่ 4.1

```
{
  "Scenario": {
    "name": "Frontal Collision Incident",
    "description": "A 2014 Ford Focus collided head-on with a 2010 Honda Civic on a three-lane road during predawn hours."
  },
  "World": {
    "map_name": "Town03",
    "weather": {
      "precipitation": 0.0,
      "cloudiness": 0.0,
      "sun_azimuth_angle": 0.0,
      "sun_altitude_angle": -5.0
    },
    "lighting": {
      "intensity": 0.0,
      "street_lights_on": false
    },
    "road_properties": [
      {
        "segment_id": "1",
        "lane_count_total": 3,
        "lane_configuration": "1E - 2W",
        "center_line_markings": "solid double yellow",
        "speed_limit_kmh": 80,
        "lanes": [
          {
            "lane_id": "1",
            "direction": "eastbound",
            "grade_percentage": -3.0
          }
        ]
      }
    ]
  }
}
```

รูปที่ 4.1: ตัวอย่างโครงสร้างข้อมูลที่ได้จากการสกัดรายงานอุบัติเหตุ C00013 โดย Schema-guided LLM

4.2.2 ขั้นที่ 2: การสร้าง Knowledge Graph (KG Modeling)

ข้อมูลที่มีโครงสร้างจากขั้นตอนที่ 1 จะถูกนำมาสร้างเป็น Knowledge Graph (KG) ซึ่งทำหน้าที่เป็น Semantic Backbone ของข้อมูลอุบัติเหตุทั้งหมด โดยการแปลงข้อมูลแต่ละส่วนให้เป็น โหนด (Nodes) และ ความสัมพันธ์ (Relationships) ดัง กระบวนการใน Function BuildKnowledgeGraph

- 1: **function** BuildKnowledgeGraph(*graph*, *data*) ▷ แปลงข้อมูล JSON เป็น Nodes และ Relationships
- 2: Create Nodes for actors, events, environment from *data*
- 3: Create Relationships (e.g., :CAUSED_BY, :OCCURRED_IN) between nodes
- 4: Add nodes and relationships to *graph*

ผลลัพธ์ที่ได้คือ Knowledge Graph ที่สามารถแสดงความเชื่อมโยงที่ซับซ้อนของปัจจัยต่างๆ ในอุบัติเหตุได้อย่างชัดเจน ดังตัวอย่างในรูปที่ 4.2

4.2.3 ขั้นที่ 3: การบูรณาการ ODD และการค้นหา Edge-Case ด้วย Query Rotation

ขั้นตอนนี้คือหัวใจสำคัญของกรอบการทำงานซึ่งใช้เทคนิค Query Rotation เพื่อค้นหาสถานการณ์ที่ท้าทายระบบ (Edge-Case) อย่างเป็นระบบ โดยใช้ ODD Modular ซึ่งเป็นกลุ่มของเงื่อนไข ODD ที่ถูกกำหนดไว้ล่วงหน้าเพื่อแทนสถานการณ์อันตรายประเภทต่างๆ (เช่น กลุ่ม "การชนท้าย") จากนั้น อัลกอริทึมจะวนลูปเพื่อสืบค้น (Query) เหตุการณ์ใน Knowledge Graph ที่ละ Modular ทำให้มั่นใจได้ว่าจะมีการค้นหาที่ครอบคลุมในทุกมิติของความเสี่ยง กระบวนการนี้สรุปได้ดัง Function QueryCasesByModular



```

1: function QueryCasesByModular(graph, modularGroup)
2:   InferenceEngine ← InitializeEngine(graph)
3:   rules ← modularGroup.getRules()
4:   MatchingEvents ← InferenceEngine.query(rules)           ▷ เช่น ค้นหา Event ที่ตรงตามเงื่อนไขของ Modular ที่กำหนด
5:   return MatchingEvents

```

เมื่อระบบทำงานกับ Modular "การฝ่าฝืนสัญญาณจราจร" Inference Engine จะค้นหาเหตุการณ์ทั้งหมดใน KG ที่เข้าข่ายเงื่อนไขนี้ เช่น 'Event_RunRedLight' ในกรณี C00013 และระบุว่าเป็น Edge-Case ที่ตรงกับ Modular ดังกล่าว ดังแสดงในรูปที่ 4.3

M_lanechange_left -[has_safety_violation]-> Out_of_ODD

รูปที่ 4.3: Knowledge Graph หลังจากผ่าน Inference Engine โดยมีการสร้างความสัมพันธ์ใหม่ (เส้นสีแดง) เพื่อระบุว่าเหตุการณ์ฝ่าไฟแดงเป็น Edge-Case ที่ตรงกับ ODD Modular "การฝ่าฝืนสัญญาณจราจร"

4.2.4 ขั้นที่ 4: การสร้างชุดพารามิเตอร์สำหรับ Scenario Template

ในขั้นตอนสุดท้าย กรอบการทำงานไม่ได้สร้างไฟล์ '.xosc' ออกมาโดยตรง แต่จะดำเนินการในลักษณะที่ยืดหยุ่นกว่า คือการสร้าง ชุดพารามิเตอร์ (Parameter Set) จากข้อมูล Edge-Case ที่ค้นพบในขั้นตอนที่ 3 พารามิเตอร์เหล่านี้คือค่าตัวแปรที่สำคัญของสถานการณ์ เช่น ความเร็วเริ่มต้นของรถ, ตำแหน่ง, ประเภทของยานพาหนะ, สภาพถนน เป็นต้น

```

1: function GenerateParametersFromEvent(eventData)           ▷ Map ข้อมูลจาก KG node ไปเป็นโครงสร้าง Key-Value
2:   params ← new Dictionary()
3:   params["initial_speed_v1"] ← eventData.getVehicle(1).speed
4:   params["road_friction"] ← eventData.getEnvironment().surfaceFriction
5:   params["maneuver_actor"] ← eventData.getActor().id
6:   return params

```

ชุดพารามิเตอร์ที่ได้นี้จะถูกจัดเก็บไว้ และในขั้นตอนการทดสอบจริง ผู้ใช้จะเลือก Scenario Template (เช่น Template สำหรับสถานการณ์ Cut-in, Template สำหรับสถานการณ์ Unsignalized Left-Turn) ซึ่งเป็นไฟล์ '.xosc' ที่มีโครงสร้างทั่วไปและมีช่องว่างสำหรับรับค่าพารามิเตอร์ จากนั้นจึงนำชุดพารามิเตอร์ที่ Framework สร้างขึ้นไปเติมใน Template เพื่อสร้างเป็น Test Case ที่สมบูรณ์และพร้อมใช้งานต่อไป วิธีการนี้ช่วยแยกส่วนระหว่าง "ข้อมูล" (Parameters) และ "ตรรกะของสถานการณ์" (Template) ออกจากกัน ทำให้สามารถสร้าง Test Case ที่หลากหลายได้อย่างมีประสิทธิภาพและนำกลับมาใช้ซ้ำได้ง่าย

4.3 ขั้นตอนการประเมินผล: Scenario Completeness Score

เพื่อให้สามารถประเมินคุณภาพของสถานการณ์จำลองที่สร้างขึ้นได้อย่างเป็นรูปธรรมและมีมาตรฐาน กรอบการทำงานนี้ได้กำหนดวิธีการประเมินเชิงปริมาณที่เรียกว่า **Scenario Completeness Score** (หรือ R-score) ขึ้นมา โดยมีวัตถุประสงค์เพื่อวัดคุณภาพเชิงฟังก์ชัน (Functional Quality) ของ Knowledge Graph ที่ได้จากระบบ เปรียบเทียบกับกราฟต้นฉบับ (Ground Truth) ที่สร้างขึ้นจากรายงานอุบัติเหตุจริง

หัวใจสำคัญของการประเมินคือการให้น้ำหนัก (Weighting) กับความสัมพันธ์ (Edges/Relationships) แต่ละประเภทตามความสำคัญที่มีต่อความสมจริงของสถานการณ์ (Scenario Fidelity) โดยคำนวณจากสูตรดังสมการที่ 4.1

$$\text{Score}_{\text{Weighted}} = \frac{\sum_{\text{Common Edges}} W_i}{\sum_{\text{All Edges in Both Graphs}} W_i} \tag{4.1}$$

โดยที่:

- **ตัวเศษ** ($\sum_{\text{Common Edges}} W_i$): คือผลรวมของค่าน้ำหนัก (W_i) ของความสัมพันธ์ทั้งหมดที่ปรากฏ **ร่วมกัน** ทั้งในกราฟต้นฉบับและกราฟที่ระบบสร้างขึ้น ซึ่งสะท้อนถึงองค์ประกอบของสถานการณ์ที่ระบบสามารถสร้างได้อย่างถูกต้อง
- **ตัวส่วน** ($\sum_{\text{All Edges in Both Graphs}} W_i$): คือผลรวมของค่าน้ำหนัก (W_i) ของความสัมพันธ์ทั้งหมดที่ไม่ซ้ำกันที่ปรากฏในกราฟใดกราฟหนึ่งหรือทั้งสองกราฟรวมกัน ซึ่งสะท้อนถึงข้อมูลที่เป็นไปได้ทั้งหมดของสถานการณ์

ค่าน้ำหนัก (W_i) ถูกกำหนดขึ้นโดยแบ่งตามประเภทและความสำคัญของความสัมพันธ์ ดังแสดงในตารางที่ 4.1

ตารางที่ 4.1: ค่าน้ำหนักของความสัมพันธ์ประเภทต่างๆ ตามความสำคัญต่อความสมจริงของสถานการณ์

Relationship Type	Weight (W_i)	Importance to Scenario Fidelity
Temporal/Causal (เช่น followed_by, M_follow)	3	จำเป็นอย่างยิ่งต่อการกำหนดลำดับเหตุการณ์และความเป็นเหตุเป็นผลของอุบัติเหตุ
Positional/Topological (เช่น is_on, adjacent_left)	2	จำเป็นต่อการกำหนดบริบทเชิงพื้นที่และขอบเขตของ ODD ที่แม่นยำ
Proximity/Trigger (เช่น near_coll, very_near)	1	จำเป็นต่อการกำหนดเงื่อนไขเริ่มต้น (Start Trigger) ของเหตุการณ์วิกฤต

ค่าคะแนนที่ได้จะมีค่าอยู่ระหว่าง 0 ถึง 1 โดยคะแนนที่เข้าใกล้ 1 หมายถึงกราฟที่ระบบสร้างขึ้นมีความสมบูรณ์และความสมจริงสูง สามารถจำลององค์ประกอบเชิงฟังก์ชันที่สำคัญของอุบัติเหตุต้นฉบับได้อย่างครบถ้วน

4.4 ข้อจำกัดของการศึกษา

การวิจัยนี้มุ่งเน้นการพัฒนากรอบการทำงานที่เป็นแนวคิดใหม่ในการสร้างชุดทดสอบ แต่ก็มีข้อจำกัดหลายประการที่ต้องนำมาพิจารณา ซึ่งส่วนใหญ่เกี่ยวข้องกับคุณภาพของข้อมูลนำเข้า ความจำกัดของเทคโนโลยีที่ใช้ และขอบเขตการดำเนินงานที่ถูกกำหนดไว้ล่วงหน้า ดังนี้:

4.4.1 ข้อจำกัดด้านข้อมูลและเทคโนโลยี

1. **การพึ่งพาข้อมูลอุบัติเหตุในอดีต:** การศึกษาขึ้นอยู่กับรายงานอุบัติเหตุจริงจากฐานข้อมูลสาธารณะ เช่น CIREN และ GIDAS ซึ่งเป็นข้อมูลในอดีตและมีลักษณะที่ไม่สมบูรณ์ รวมถึงมีความเป็นอัตวิสัย (Subjectivity) ในการบันทึกของผู้รายงาน ข้อจำกัดนี้ส่งผลโดยตรงต่อคุณภาพและความแม่นยำของ Knowledge Graph ที่ถูกสร้างขึ้น
2. **ความท้าทายด้านความน่าเชื่อถือของ LLM:** แม้จะมีการใช้ Schema-guided LLM เพื่อสกัดข้อมูล แต่โมเดลภาษายังคงมีแนวโน้มที่จะสร้างข้อมูลที่ผิดพลาด (Hallucination) หรือความสัมพันธ์เชิงเหตุผลที่ไม่ถูกต้อง โดยเฉพาะในสถานการณ์อุบัติเหตุที่มีความซับซ้อน ซึ่งทำให้ต้องอาศัยการตรวจสอบและปรับแก้จากผู้เชี่ยวชาญเพิ่มเติม
3. **ข้อจำกัดในการสรุปผล ODD และการออกแบบ Modular:** Operational Design Domain (ODD) ที่ใช้ในการวิจัยนี้อ้างอิงตามมาตรฐานของ JAMA เป็นหลัก ดังนั้นผลลัพธ์ที่ได้จึงอาจไม่สามารถนำไปประยุกต์ใช้โดยตรงกับระบบ ADS ที่มีนิยาม ODD แตกต่างกัน นอกจากนี้ การจัดกลุ่มเงื่อนไขเป็น ODD Modular เพื่อใช้ในเทคนิค Query Rotation อาจมีความเป็นอัตวิสัยในการออกแบบ ซึ่งอาจส่งผลกระทบต่อประเภทและลำดับความสำคัญของ Edge-Case ที่ถูกค้นพบ
4. **ปัญหาด้านการประมวลผลของ Knowledge Graph:** เมื่อ Knowledge Graph เติบโตขึ้นตามจำนวนรายงานอุบัติเหตุที่เพิ่มขึ้น ประสิทธิภาพในการประมวลผลของ Inference Engine เพื่อสืบค้นและประเมินกฎ ODD ในแต่ละ Modular จะลดลง ซึ่งอาจเป็นข้อจำกัดในการนำกรอบการทำงานนี้ไปใช้งานในระดับอุตสาหกรรมขนาดใหญ่ที่ต้องการความรวดเร็ว

4.4.2 ข้อจำกัดด้านขอบเขตการดำเนินงาน

1. **ผลลัพธ์สิ้นสุดที่การสร้างพารามิเตอร์:** ขอบเขตของโครงการสิ้นสุดที่การสร้าง ชุดพารามิเตอร์ (Parameter Set) สำหรับนำไปใช้กับ Scenario Template และไม่ได้รวมถึงการดำเนินการจำลองสถานการณ์ (Simulation) หรือการทดสอบภาคสนามจริง ดังนั้น การประเมินผลกระทบที่แท้จริงของชุดทดสอบต่อประสิทธิภาพของระบบ ADS จึงอยู่นอกเหนือขอบเขตของการศึกษา
2. **การพึ่งพาคุณภาพของ Scenario Template:** ประสิทธิภาพของ Test Case สุดท้ายที่สร้างขึ้น ไม่ได้ขึ้นอยู่กับคุณภาพของพารามิเตอร์ที่กรอบการทำงานนี้สร้างขึ้นเท่านั้น แต่ยังขึ้นอยู่กับคุณภาพ ความถูกต้อง และความครอบคลุมของ Scenario Template เช่น ไฟล์ '.xosc' ที่มีอยู่ก่อนแล้ว หาก Template มีข้อบกพร่องหรือไม่ครอบคลุมสถานการณ์ที่หลากหลาย ก็จะจำกัดประโยชน์ของพารามิเตอร์ที่สร้างขึ้น
3. **การละเลยปัจจัยมนุษย์ในระดับละเอียด:** Scenario ที่สร้างขึ้นเน้นการจับภาพเหตุการณ์ทางกายภาพและสภาพแวดล้อมเป็นหลัก แม้จะ

มีการเก็บข้อมูลพฤติกรรม แต่การวิเคราะห์และจำลองปัจจัยด้านมนุษย์ (Human Factors) เช่น ความผิดพลาดทางสติปัญญา หรือการตอบสนองทางอารมณ์ของผู้ขับขี่ยังละเอียด ยังคงเป็นสิ่งที่ซับซ้อนและไม่ได้เป็นจุดเน้นหลักของกรอบการทำงานนี้

บทที่ 5

ผลการศึกษา

บทนี้จะนำเสนอผลการดำเนินงานของโครงการวิจัย KGs-Augmented Testsuite Generator Framework โดยจะแสดงให้เห็นว่ากรอบการทำงานที่พัฒนาขึ้นสามารถบรรลุวัตถุประสงค์ที่ตั้งไว้ได้อย่างไร พร้อมทั้งนำเสนอตัวอย่างผลลัพธ์ที่ได้จากระบบ การเปรียบเทียบกระบวนการก่อนและหลังการพัฒนา และรายงานผลการประเมินประสิทธิภาพของกรอบการทำงาน

5.1 ผลการดำเนินงานตามวัตถุประสงค์

กรอบการทำงานที่พัฒนาขึ้นสามารถดำเนินงานได้สำเร็จและสอดคล้องกับวัตถุประสงค์หลักทั้ง 3 ข้อที่ได้ตั้งไว้ ดังนี้

1. วัตถุประสงค์ข้อที่ 1: พัฒนารอบการสร้างชุดทดสอบที่น่าเชื่อถือ (KGs-Augmented Testsuite Generator)

- **ผลการดำเนินงาน:** ประสบความสำเร็จในการพัฒนารอบการทำงานที่สมบูรณ์ ซึ่งสามารถสกัดข้อมูลจากรายงานอุบัติเหตุ (Unstructured Text) ด้วย Schema-guided LLM และสร้างเป็น Knowledge Graph (KG) เพื่อใช้เป็นรากฐานเชิงความหมายของข้อมูลได้จริง ซึ่งแสดงให้เห็นถึงการบูรณาการเทคโนโลยี LLM และ KG เข้าด้วยกันอย่างเป็นระบบ

2. วัตถุประสงค์ข้อที่ 2: เพิ่มประสิทธิภาพการค้นพบ Edge-Case ด้วยการบูรณาการ ODD

- **ผลการดำเนินงาน:** บรรลุวัตถุประสงค์หลักของงานวิจัย โดยได้พัฒนากลไกการค้นหา Edge-Case ที่มีประสิทธิภาพผ่านการใช้ ODD Modular และเทคนิค Query Rotation ผลลัพธ์จากการดำเนินงานสามารถจำแนกรายงานอุบัติเหตุจริงจำนวน 318 กรณีศึกษา ออกเป็นกลุ่ม ODD Modular ที่มีความหมายได้ถึง 21 กลุ่ม ซึ่งเป็นการยืนยันว่ากรอบการทำงานสามารถกรองและมุ่งเป้าการสร้างสถานการณ์ไปยังขอบเขตที่ท้าทายระบบได้อย่างเป็นรูปธรรม ช่วยลดการสร้างเหตุการณ์ที่ไม่จำเป็นลงได้อย่างมีนัยสำคัญ

3. วัตถุประสงค์ข้อที่ 3: สร้างผลลัพธ์ที่มีโครงสร้างและเป็นมาตรฐาน

- **ผลการดำเนินงาน:** กรอบการทำงานสามารถสร้างผลลัพธ์สุดท้ายในรูปแบบของชุดพารามิเตอร์ (Parameter Set) ที่มีโครงสร้างสมบูรณ์และถูกต้องตามหลักเหตุผล ซึ่งพร้อมสำหรับนำไปใช้งานร่วมกับ Scenario Template ในมาตรฐานอุตสาหกรรมอย่าง ASAM OpenSCENARIO ได้ทันที ดังที่ได้อธิบายไว้ในขั้นตอนวิธี (บทที่ 4)

5.2 ตัวอย่างผลลัพธ์

5.2.1 ผลการจำแนกประเภทอุบัติเหตุด้วย ODD Modular

หัวใจสำคัญของกรอบการทำงานคือความสามารถในการจัดหมวดหมู่สถานการณ์อุบัติเหตุตามกลุ่ม ODD Modular ที่กำหนดไว้ล่วงหน้า จาก การประมวลผลรายงานอุบัติเหตุทั้งหมด 318 กรณีศึกษา ระบบสามารถจำแนกและนับจำนวนเคสที่เข้าข่ายแต่ละกลุ่มได้อย่างแม่นยำ ดังแสดงใน ตารางที่ ?? ซึ่งแสดงให้เห็นถึงการกระจายตัวของสถานการณ์ประเภทต่างๆ

ตารางที่ 5.1: ผลการจำแนกประเภทอุบัติเหตุ 318 กรณีศึกษาตามกลุ่ม ODD Modular ทั้ง 21 กลุ่ม

ODD Modular Group	Percentage (%)	Case Count
1. Intersections / Junctions (I) - High Complexity		
I-1: Signalized Conflict	3.91	12
I-2: Unsignalized Left-Turn	9.09	29
I-3: Roundabout Conflict	5.42	17
I-4: Intersection Queue Mgmt	4.25	14
I-5: Crosswalk Pedestrian Conflict	3.07	10
I-6: Four-Way Stop Misinterpretation	13.70	44
I-7: Grade/Curvature Intersection	5.06	16
2. Traffic Maneuvers (T) - High Frequency		
T-1: Rear-End Collision	6.62	21
T-2: Aggressive Cut-In	5.38	17
T-3: Unsafe Lane Change	2.88	9
T-4: Following Too Closely	2.55	8
T-5: Wrong-Way Driving	7.52	24
T-6: Unexpected Lane Departure	7.95	25
T-7: Cyclist/Motorcyclist Close Pass	2.94	9
3. Adverse Environment / Structure (E) - High Severity		
E-1: Heavy Rainfall / Low Friction	4.00	13
E-2: Nighttime / Poor Illumination	2.74	9
E-3: Sun Glare / Low Sun Angle	3.49	11
E-4: Construction Zone Conflict	2.28	7
E-5: Fog / Dust Storm	3.33	11
E-6: Road Obstacle / Debris	1.69	5
E-7: Toll/Entrance Gate Merge	2.13	7

5.2.2 กรณีศึกษา C00013: Intersection Signalized Conflict

เพื่อแสดงให้เห็นภาพการทำงานตั้งแต่ต้นจนจบ ขอนำเสนอกรณีศึกษา C00013 ซึ่งเป็นอุบัติเหตุ ณ ทางแยกที่มีสัญญาณไฟ กรอบการทำงาน ได้สกัดข้อมูลจากรายงานที่เป็นข้อความ และสร้างเป็นชุดพารามิเตอร์ที่มีโครงสร้างดังรูปที่ 5.1 ซึ่งพารามิเตอร์เหล่านี้ถูกนำไปใช้สร้างสถานการณ์ จำลองที่สมจริงได้ในท้ายที่สุด ดังแสดงในรูปที่ 5.2

```

{
  "event_id": "approach_and_obstruction",
  "description": "TARGET (Fire Truck) enters on green but stops, causing obstruction. E60 (SUV) approaches at speed to",
  "start_trigger": {
    "type": "TrafficLightChange",
    "parameters": {"light_status": "Green for TARGET's path"}
  },
  "actions": [
    {
      "actor_ref": "Vehicle1_TARGET",
      "action": "Enter intersection, then execute full, unexpected stop at intersection center (Obstruction).",
      "relation_type": "is_on"
    },
    {
      "actor_ref": "Vehicle2_E60",
      "action": "Maintain speed toward intersection, failing to recognize the stationary obstruction and red signal",
      "relation_type": "very_near"
    }
  ]
},

```

รูปที่ 5.1: ตัวอย่างชุดพารามิเตอร์ที่มีโครงสร้างซึ่งถูกสกัดจากรายงานอุบัติเหตุ C00013



รูปที่ 5.2: ภาพจากสถานการณ์จำลองของกรณีศึกษา C00013 ที่สร้างขึ้นจากพารามิเตอร์ของระบบ (ซ้าย: มุมมองด้านหน้า, ขวา: มุมมองด้านหลัง)

5.3 การเปรียบเทียบก่อนและหลังการพัฒนา

การนำกรอบการทำงาน KGs-Augmented Testsuite Generator มาใช้ได้เปลี่ยนแปลงกระบวนการสร้างชุดทดสอบจากการพยายามแบบไร้ทิศทางไปสู่กระบวนการที่เป็นระบบและมุ่งเน้นเป้าหมายอย่างชัดเจน ดังนี้

- **ก่อนการพัฒนา:** การใช้ LLM โดยตรงเพื่อสร้างสถานการณ์จากรายงานอุบัติเหตุมีลักษณะเป็นการ "สุ่ม" ซึ่งต้องสร้างสถานการณ์ที่ไม่ทำอันตราย (Normal Safe Scenarios) จำนวนมากเพื่อที่จะพบ Edge-Case ที่มีความหมายเพียงไม่กี่กรณี ทำให้มีประสิทธิภาพการค้นพบกรณีขอบเขต (Edge-Case Discovery Efficiency) ที่ต่ำ และสิ้นเปลืองทรัพยากรอย่างมาก
- **หลังการพัฒนา:** กรอบการทำงานใหม่ใช้ KG เป็นฐานความรู้และใช้ ODD Modular เป็นตัวกรอง ทำให้กระบวนการสร้างสถานการณ์มีเป้าหมายที่ชัดเจน (Goal-Oriented) โดยมุ่งเน้นไปที่การค้นหาเคสที่ตรงตามเงื่อนไขความเสี่ยงที่กำหนดไว้เท่านั้น ส่งผลให้ประสิทธิภาพการค้นพบกรณีขอบเขตสูงขึ้นอย่างมีนัยสำคัญ และลดจำนวนครั้งในการสร้างเหตุการณ์ซ้ำซ้อนลงได้

5.4 การประเมินผล

เพื่อประเมินคุณภาพและความสมจริงของผลลัพธ์ ได้มีการใช้แนวคิดการประเมินเชิงเทคนิคที่เรียกว่า Scenario Completeness Score หรือ R-score (Realism Score) ซึ่งเป็นการวัดความคล้ายคลึงกันระหว่าง Scene Graph ของสถานการณ์ในอุบัติเหตุจริง กับ Scene Graph ที่สร้างขึ้นจากพารามิเตอร์ของกรอบการทำงาน

ผลการประเมินเบื้องต้นพบว่าค่า R-score มีความแตกต่างกันไปในแต่ละ ODD Modular ซึ่งชี้ให้เห็นว่ากรอบการทำงานมีความสามารถในการสร้างสถานการณ์ที่มีความซับซ้อนแตกต่างกันได้ดี ดังแสดงในตารางที่ 5.2

ตารางที่ 5.2: ตัวอย่างผลการประเมิน R-score ในกลุ่ม ODD Modular ต่างๆ

ODD Modular Group	Average R-score
T-1: Rear-End Collision	0.9577 (สูง)
E-6: Road Obstacle - Debris	0.6305 (ต่ำ)

จากตาราง ผลการประเมินชี้ว่าสถานการณ์ที่มีปฏิสัมพันธ์ระหว่างยานพาหนะที่ไม่ซับซ้อน เช่น "การชนท้าย" (Rear-End Collision) สามารถสร้างได้อย่างสมจริงและได้ R-score ที่สูง ในขณะที่สถานการณ์ที่เกี่ยวข้องกับวัตถุบนถนนแบบสุ่ม เช่น "สิ่งกีดขวาง" (Road Obstacle) ยังคงมีความท้าทายในการสกัดข้อมูลและสร้างให้สมจริง ซึ่งเป็นแนวทางสำหรับการพัฒนาต่อไปในอนาคต

บทที่ 6

สรุปผลการศึกษาและวิจารณ์ผลการศึกษา

บทนี้เป็นการสรุปภาพรวมทั้งหมดของโครงการวิจัย KGs-Augmented Testsuite Generator Framework ตั้งแต่ผลการดำเนินงานที่สำเร็จ ลุล่วงตามวัตถุประสงค์ ข้อสังเกตและข้อวิจารณ์ที่ได้จากการดำเนินงาน ข้อเสนอแนะสำหรับการพัฒนาต่อยอดในอนาคต ไปจนถึงประสบการณ์ที่ได้รับจากการเข้าร่วมโครงการสหกิจศึกษา

6.1 สรุปผลการดำเนินงาน

โครงการวิจัยนี้ประสบความสำเร็จในการพัฒนา KGs-Augmented Testsuite Generator Framework ซึ่งเป็นกรอบการทำงานที่สามารถแก้ไข ปัญหาประสิทธิภาพในการค้นพบกรณีขอบเขต (Edge-Case Discovery Efficiency) สำหรับการทดสอบระบบขับเคลื่อนอัตโนมัติ (ADS) ได้อย่างเป็นรูปธรรม โดยกรอบการทำงานได้บูรณาการเทคโนโลยีสามส่วนหลักเข้าด้วยกัน คือ 1) Schema-guided LLM สำหรับการสกัดข้อมูลที่มีโครงสร้างจากรายงานอุบัติเหตุจริง 2) Knowledge Graph (KG) เพื่อทำหน้าที่เป็นแกนหลักเชิงความหมายที่ช่วยรักษาความต่อเนื่องเชิงเหตุผลและอนุมานข้อมูลได้ และ 3) การใช้ ODD Modular ร่วมกับเทคนิค Query Rotation เพื่อมุ่งเป้าการค้นหาไปยังสถานการณ์ที่ท้าทายระบบโดยตรง ผลลัพธ์สุดท้ายของกรอบการทำงานคือ ชุดพารามิเตอร์ (Parameter Set) คุณภาพสูง ที่พร้อมสำหรับนำไปใช้กับ Scenario Template มาตรฐานอุตสาหกรรม (ASAM OpenSCENARIO) ซึ่งถือเป็นการบรรลุวัตถุประสงค์ของโครงการที่ต้องการสร้างกระบวนการทดสอบที่เป็นระบบและมีประสิทธิภาพได้อย่างครบถ้วน

6.2 ข้อสังเกตและข้อวิจารณ์

จากการดำเนินโครงการ พบข้อสังเกตและประเด็นที่น่าสนใจหลายประการ ประการแรก การใช้ Knowledge Graph เป็นแกนหลักของข้อมูลพิสูจน์ให้เห็นว่ามีประสิทธิภาพสูงกว่าการจัดเก็บข้อมูลแบบตารางทั่วไปอย่างมีนัยสำคัญ เนื่องจากโครงสร้างกราฟเอื้อให้สามารถทำการสืบค้นเชิงความสัมพันธ์ที่ซับซ้อนและทำการอนุมาน (Inference) เพื่อค้นหา Edge-Case ที่ละเมิดกฎ ODD ได้โดยตรง ซึ่งเป็นหัวใจสำคัญของกรอบการทำงานนี้

ประการที่สอง แม้ว่า LLM จะเป็นเครื่องมือที่ทรงพลังในการสกัดข้อมูล แต่ยังคงต้องการ "นั่งร้าน" (Scaffolding) ที่แข็งแกร่ง กล่าวคือต้องอาศัยการออกแบบ Schema ที่ดีเยี่ยมและเทคนิค Multi-Step Prompting เพื่อควบคุมให้ผลลัพธ์มีความน่าเชื่อถือและลดปัญหา Hallucination ซึ่ง

เป็นการตอกย้ำว่าความสำเร็จของโครงการไม่ได้ขึ้นอยู่กับตัวโมเดลภาษาเพียงอย่างเดียว แต่ขึ้นอยู่กับสถาปัตยกรรมของกรอบการทำงานทั้งหมดที่ออกแบบมาเพื่อควบคุมและใช้งาน LLM อย่างมีประสิทธิภาพ

อย่างไรก็ตาม กรอบการทำงานยังมีจุดที่ควรปรับปรุง จากผลการประเมิน Scenario Completeness Score (R-score) พบว่าระบบสามารถสร้างสถานการณ์ที่มีปฏิสัมพันธ์ชัดเจน (เช่น การชนท้าย) ได้อย่างสมจริง แต่ยังคงมีความท้าทายในการสร้างสถานการณ์ที่ขึ้นอยู่กับปัจจัยที่กำกวมในรายงาน (เช่น สิ่งกีดขวางบนถนน) ซึ่งชี้ให้เห็นว่า คุณภาพของผลลัพธ์ยังคงขึ้นอยู่กับคุณภาพและความละเอียดของรายงานอุบัติเหตุต้นฉบับ เป็นอย่างมาก

6.3 ข้อเสนอแนะในการพัฒนาต่อไป

เพื่อให้กรอบการทำงานนี้มีศักยภาพสูงขึ้นในอนาคต มีแนวทางการพัฒนาต่อยอดที่น่าสนใจดังนี้:

1. **การพัฒนากระบวนการตรวจสอบ KG อัตโนมัติ (Automated KG Validation):** พัฒนากลไกที่สามารถตรวจสอบความถูกต้องของข้อมูลใน Knowledge Graph ได้แบบกึ่งอัตโนมัติ เช่น การตรวจสอบความสอดคล้องกับกฎทางฟิสิกส์เบื้องต้น เพื่อลดภาระการตรวจสอบโดยผู้เชี่ยวชาญและเพิ่มความน่าเชื่อถือของข้อมูล
2. **การขยายคลัง ODD Modular และการค้นพบอัตโนมัติ:** ขยายคลังของ ODD Modular ให้ครอบคลุมประเภทของ Edge-Case ที่มีความเฉพาะเจาะจงมากยิ่งขึ้น และอาจนำเทคนิค Machine Learning มาใช้เพื่อวิเคราะห์ KG และค้นหารูปแบบความเสี่ยงใหม่ๆ ที่สามารถนำมาสร้างเป็น ODD Modular ได้โดยอัตโนมัติ
3. **การบูรณาการแบบครบวงจร (End-to-End Integration):** พัฒนาระบบให้ครบวงจร โดยเชื่อมต่อผลลัพธ์ (Parameter Set) เข้ากับระบบจำลองสถานการณ์ (เช่น CARLA) โดยตรง เพื่อให้สามารถสร้างและรัน Test Case ได้โดยอัตโนมัติ พร้อมทั้งเก็บผลการทดสอบและนำมาวิเคราะห์ได้ทันที
4. **การจำลองปัจจัยมนุษย์ (Human Factors):** เพิ่มความสามารถในการวิเคราะห์และจำลองปัจจัยมนุษย์ในระดับที่ละเอียดขึ้น เช่น การจำลองความเหนื่อยล้า, การเสียสมาธิ, หรือเวลาในการตอบสนอง (Reaction Time) ของผู้ขับขี่เข้าไปใน Ontology ของ KG เพื่อสร้างสถานการณ์ที่สมจริงยิ่งขึ้น

6.4 ประสพการณ์จากการเข้าร่วมโครงการสหกิจศึกษา

การเข้าร่วมโครงการสหกิจศึกษา ณ Japan Advanced Institute of Science and Technology (JAIST) เป็นประสบการณ์อันล้ำค่าที่มอบความรู้และทักษะที่สำคัญอย่างยิ่ง ทั้งในด้านเทคนิค การวิจัย และการทำงานในระดับสากล ข้าพเจ้าได้เรียนรู้และลงมือปฏิบัติจริงกับเทคโนโลยีขั้นสูงอย่าง Knowledge Graphs และ Large Language Models ได้ฝึกฝนการออกแบบและพัฒนากรอบการทำงานวิจัยตั้งแต่การทบทวนวรรณกรรม การระบุปัญหา การออกแบบขั้นตอนวิธี ไปจนถึงการประเมินผลและเขียนรายงานฉบับสมบูรณ์ การได้ทำงานร่วมกับ Professor Toshiaki Aoki และ

Associate Professor Natthawut Kertkeidkachorn ทำให้ข้าพเจ้าได้เรียนรู้กระบวนการแก้ปัญหาที่เป็นระบบ การคิดเชิงวิพากษ์ และได้รับคำแนะนำที่เป็นประโยชน์อย่างยิ่ง ประสบการณ์ทั้งหมดนี้ไม่เพียงแต่พัฒนาทักษะทางวิชาชีพ แต่ยังสร้างแรงบันดาลใจและเป็นรากฐานที่แข็งแกร่งสำหรับการทำงานหรือศึกษาต่อในสายงานด้านปัญญาประดิษฐ์และระบบอัตโนมัติในอนาคต

บรรณานุกรม

- [1] L. Zhang, M. Tang, J. Ma, J. Duan, X. Sun, J. Hu, X. Xu, and X. Suchuan, "Analysis of traffic accident based on knowledge graph," *Journal of Advanced Transportation*, vol. 2022, 2022.
- [2] Japan Automobile Manufacturers Association, Inc., "Automated Driving Safety Evaluation Framework Ver 3.0," tech. rep., Japan Automobile Manufacturers Association, Inc., Dec 2022. Accessed: Aug 29, 2025.
- [3] C. Chang, S. Wang, J. Zhang, J. Ge, and L. Li, "Llmsenario: Large language model driven scenario generation," *arXiv preprint arXiv:2310.19639*, 2023.
- [4] T. Khot, S. G. Ugare, M. Goenka, S. Singh, H. R. Trivedi, A. Sabharwal, *et al.*, "Prompting large language models with divide-and-conquer program for discerning problem solving." *arXiv preprint arXiv:2310.03153*, 2024. Accessed: Aug 31, 2025.
- [5] National Highway Traffic Safety Administration (NHTSA), "Crash Injury Research and Engineering Network (CIREN) Database." U.S. Department of Transportation, 2025. Accessed: Aug 28, 2025.
- [6] German In-Depth Accident Study (GIDAS), "German In-Depth Accident Study (GIDAS)," 2025. Accessed: Aug 28, 2025.
- [7] G. Bagschik, T. Menzel, and M. Maurer, "Ontology based scene creation for the development of automated vehicles," in *2018 21st International Conference on Intelligent Transportation Systems (ITSC)*, pp. 756--761, IEEE, 2018.
- [8] P. Koopman and M. Wagner, "Autonomous vehicle safety: An interdisciplinary challenge," in *2017 IEEE International Conference on Vehicular Electronics and Safety (ICVES)*, pp. 1--6, IEEE, 2017.
- [9] OpenAI, "Gpt-4o." <https://openai.com/index/hello-gpt-4o/>, 2024. Accessed: October 15, 2025.
- [10] Neo4j, Inc., "Neo4j Graph Database Platform." <https://neo4j.com>, 2025. Accessed: Oct 15, 2025.